FACULTE DES SCIENCES BEN M'SICK
UNIVERSITÉ HASSAN II DE CASABLANCA

Département de Mathématiques et Informatique
Licence d'excellence intelligence artificielle

PROJET DE FIN D'ÉTUDES

Système intelligent de prédiction de la réussite académique

Présenté par :

- **Assafa Aya**
- **El Asri Hind**
- **Elalami Sara**

Encadré par:

- **Pr .KANDALI KHALID**

Devant le jury:

- **PR .AHAJJAM TARIK**
- **PR .SADIQ MOUNIR**
- **PR .NOUH SAID**
- **PR .KANDALI KHALID**

Année Universitaire 2025-2026

Plan de présentation

01 Contexte, Problématique

02 Présentation du dataset

03 Méthodologie

04 Analyse Exploratoire (EDA)

05 Prétraitement des Données

06 Modèles Développés et Résultats

07 Démonstration

08 Conclusion et Perspectives

Contexte, Problématique et Objectifs

CONTEXTE

01. DIGITALISATION DE L'ENSEIGNEMENT

02. EXPLOITATION DES DONNÉES ÉTUDIANTES

03. PRÉDICTION DE LA RÉUSSITE ACADÉMIQUE

PROBLÉMATIQUE

La détection tardive des étudiants en difficulté constitue un obstacle à la réussite académique. Les approches traditionnelles, principalement réactives, ne permettent pas une intervention précoce et efficace.

OBJECTIFS

01. Développer un système intelligent de prédiction

Développer un système basé sur des techniques de machine learning capable d'analyser les données des étudiants

02. Prédire la réussite académique des étudiants.

Anticiper les performances des étudiants afin d'identifier rapidement ceux susceptibles de rencontrer des difficultés

03. Identifier les facteurs influençant la réussite

Analyser les variables académiques, afin de déterminer les facteurs ayant le plus d'impact sur la réussite

04. Aider les responsables pédagogiques

Fournir un outil d'aide à la décision permettant aux responsables pédagogiques de mettre en place des actions préventives adaptées

Présentation du dataset

SOURCE DES DONNÉES

Le dataset "Predict Students' Dropout and Academic Success" provient d'un établissement d'enseignement supérieur portugais.
Il contient des informations sur les étudiants inscrits dans différents cursus

DESCRIPTION DU DATASET

VARIABLE

LE DATASET CONTIENT 4 424 ÉTUDIANTS DÉCRITS PAR 36 VARIABLES DÉMOGRAPHIQUES, ACADÉMIQUES ET SOCIO-ÉCONOMIQUES.

VARIABLE CIBLE

LA VARIABLE TARGET COMPORTE 3 CLASSES : GRADUATE, DROPOUT ET ENROLLED, CORRESPONDANT À UN PROBLÈME DE CLASSIFICATION MULTICLASSE AVEC UN DÉSÉQUILIBRE DES CLASSES

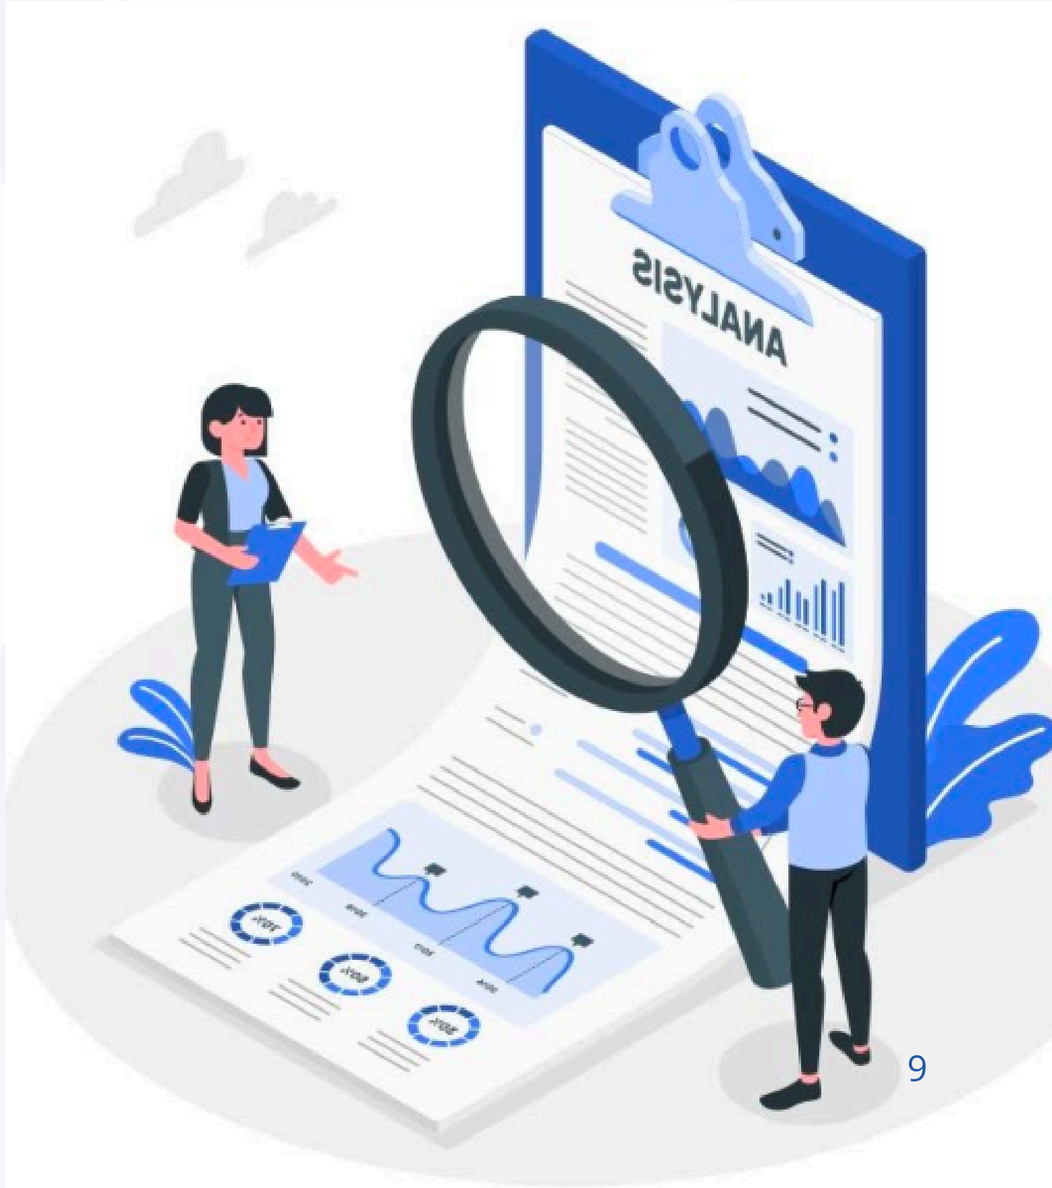

Méthodologie

PIPELINE DU PROJET

01. DATASET

02. ANALYSE EXPLOIRATOIRE

03. PRETRAITEMENT

04. MODELISATION

05. EVALUATION

06. PREDICTION

MODÈLES UTILISÉS

LOGISTIC REGRESSION .

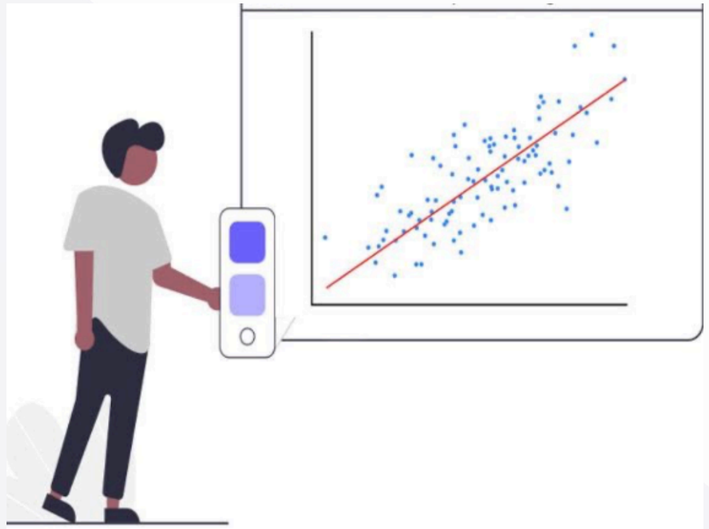

MODÈLE LINÉAIRE SIMPLE ET INTERPRÉTABLE.

DECISION TREE.

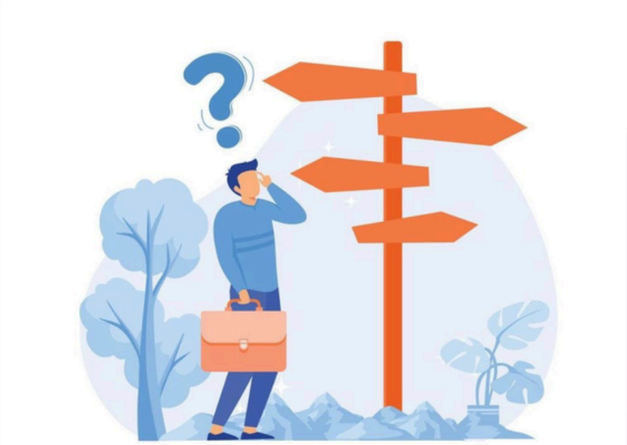

K-NEAREST NEIGHBORS (KNN) .

MODÈLE BASÉ SUR DES RÈGLES DE DÉCISION.

–MODÈLE BASÉ SUR LA PROXIMITÉ DES OBSERVATIONS.

TECHNOLOGIES UTILISÉES

LANGAGE DE PROGRAMMATION

MACHINE LEARNING

ANALYSE ET MANIPULATION DES DONNÉES

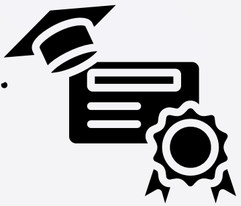

VISUALISATION DES DONNÉES

INTERFACE GRAPHIQUE

ANALYSE EXPLORATOIRE

Variable cible

Distribution des classes :

- Déséquilibre entre les classes
- Graduate plus représentée
- Dropout moins représentée
- Enrolled supprimée pour la modélisation

Interpretation :

- Le dataset nécessite une adaptation pour la classification

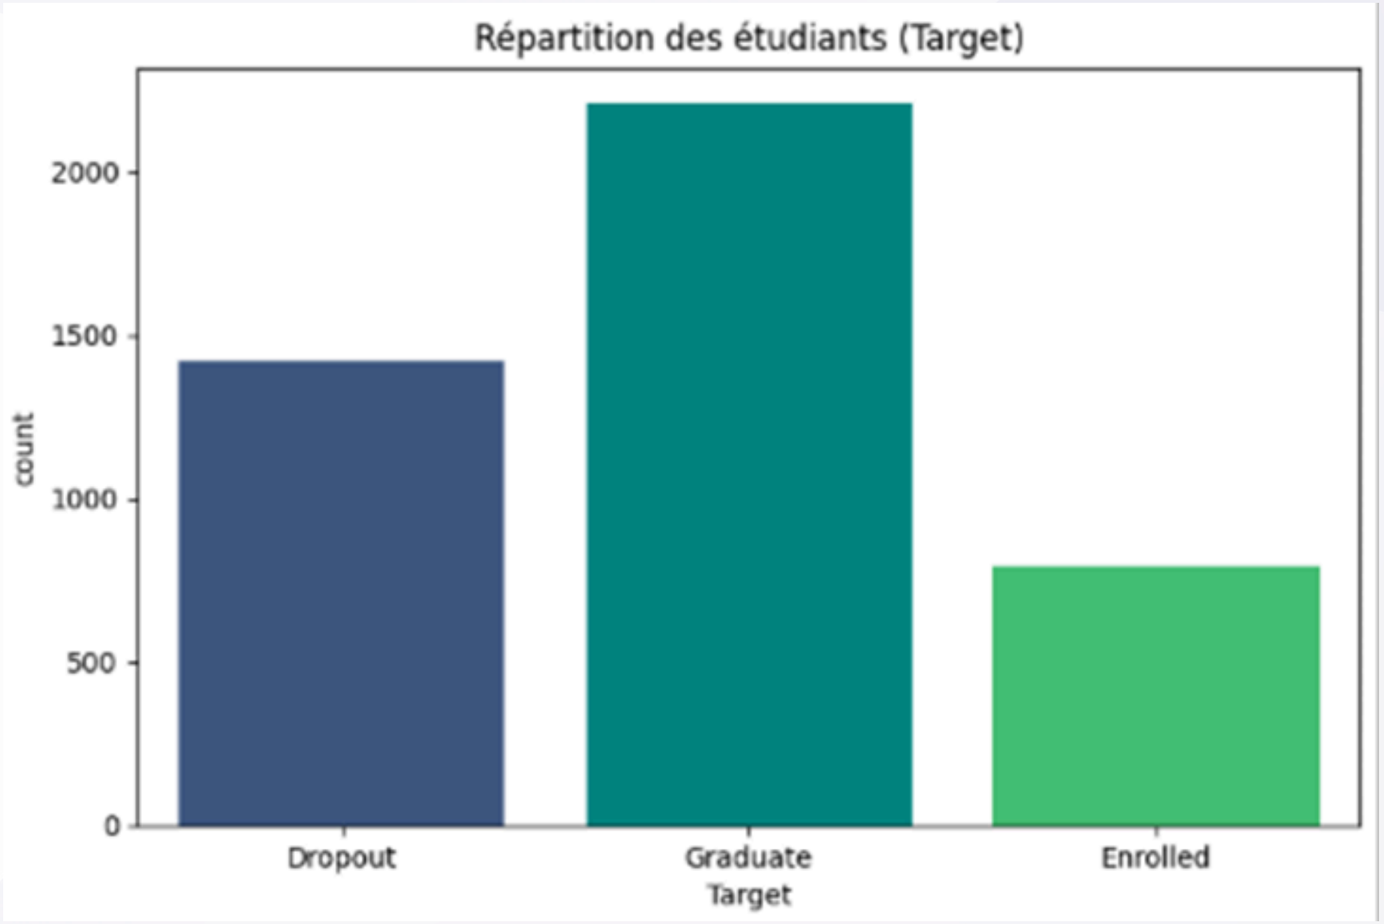

Qualité des données et détection des outliers

QUALITÉ DES DONNÉES

DATASET COMPLET AVEC 4 424 OBSERVATIONS EXPLOITABLES
37 VARIABLES DISPONIBLES
AUCUNE VALEUR MANQUANTE
ABSENCE DE DOUBLONS
AUCUNE DONNÉE SUPPRIMÉE

GESTION DES VALEURS ABERRANTES

PRÉSENCE D'OUTLIERS DANS LES NOTES ET L'ÂGE
DÉTECTION VIA LA MÉTHODE IQR
TRAITEMENT PAR CLIPPING
CONSERVATION DE L'ENSEMBLE DES OBSERVATIONS

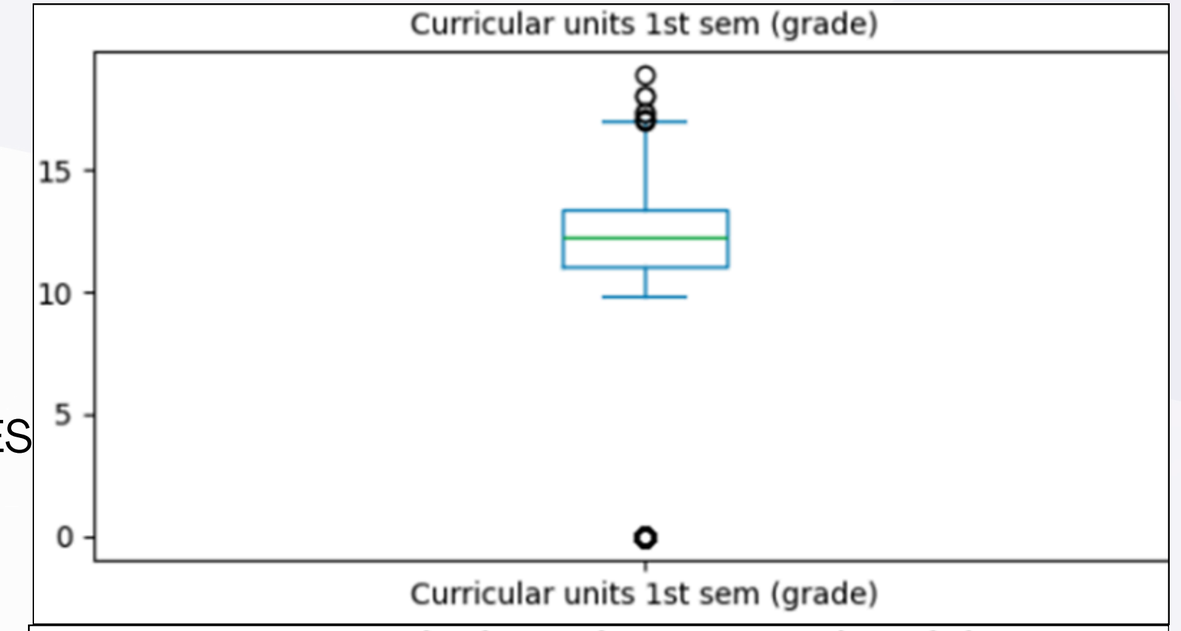

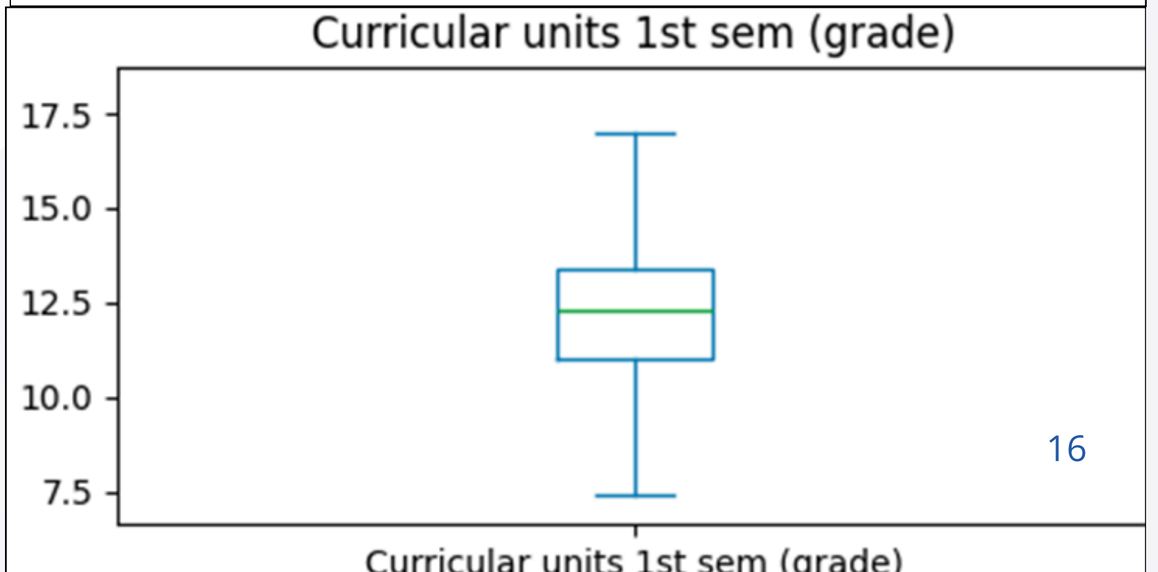

Corrélations entre variables

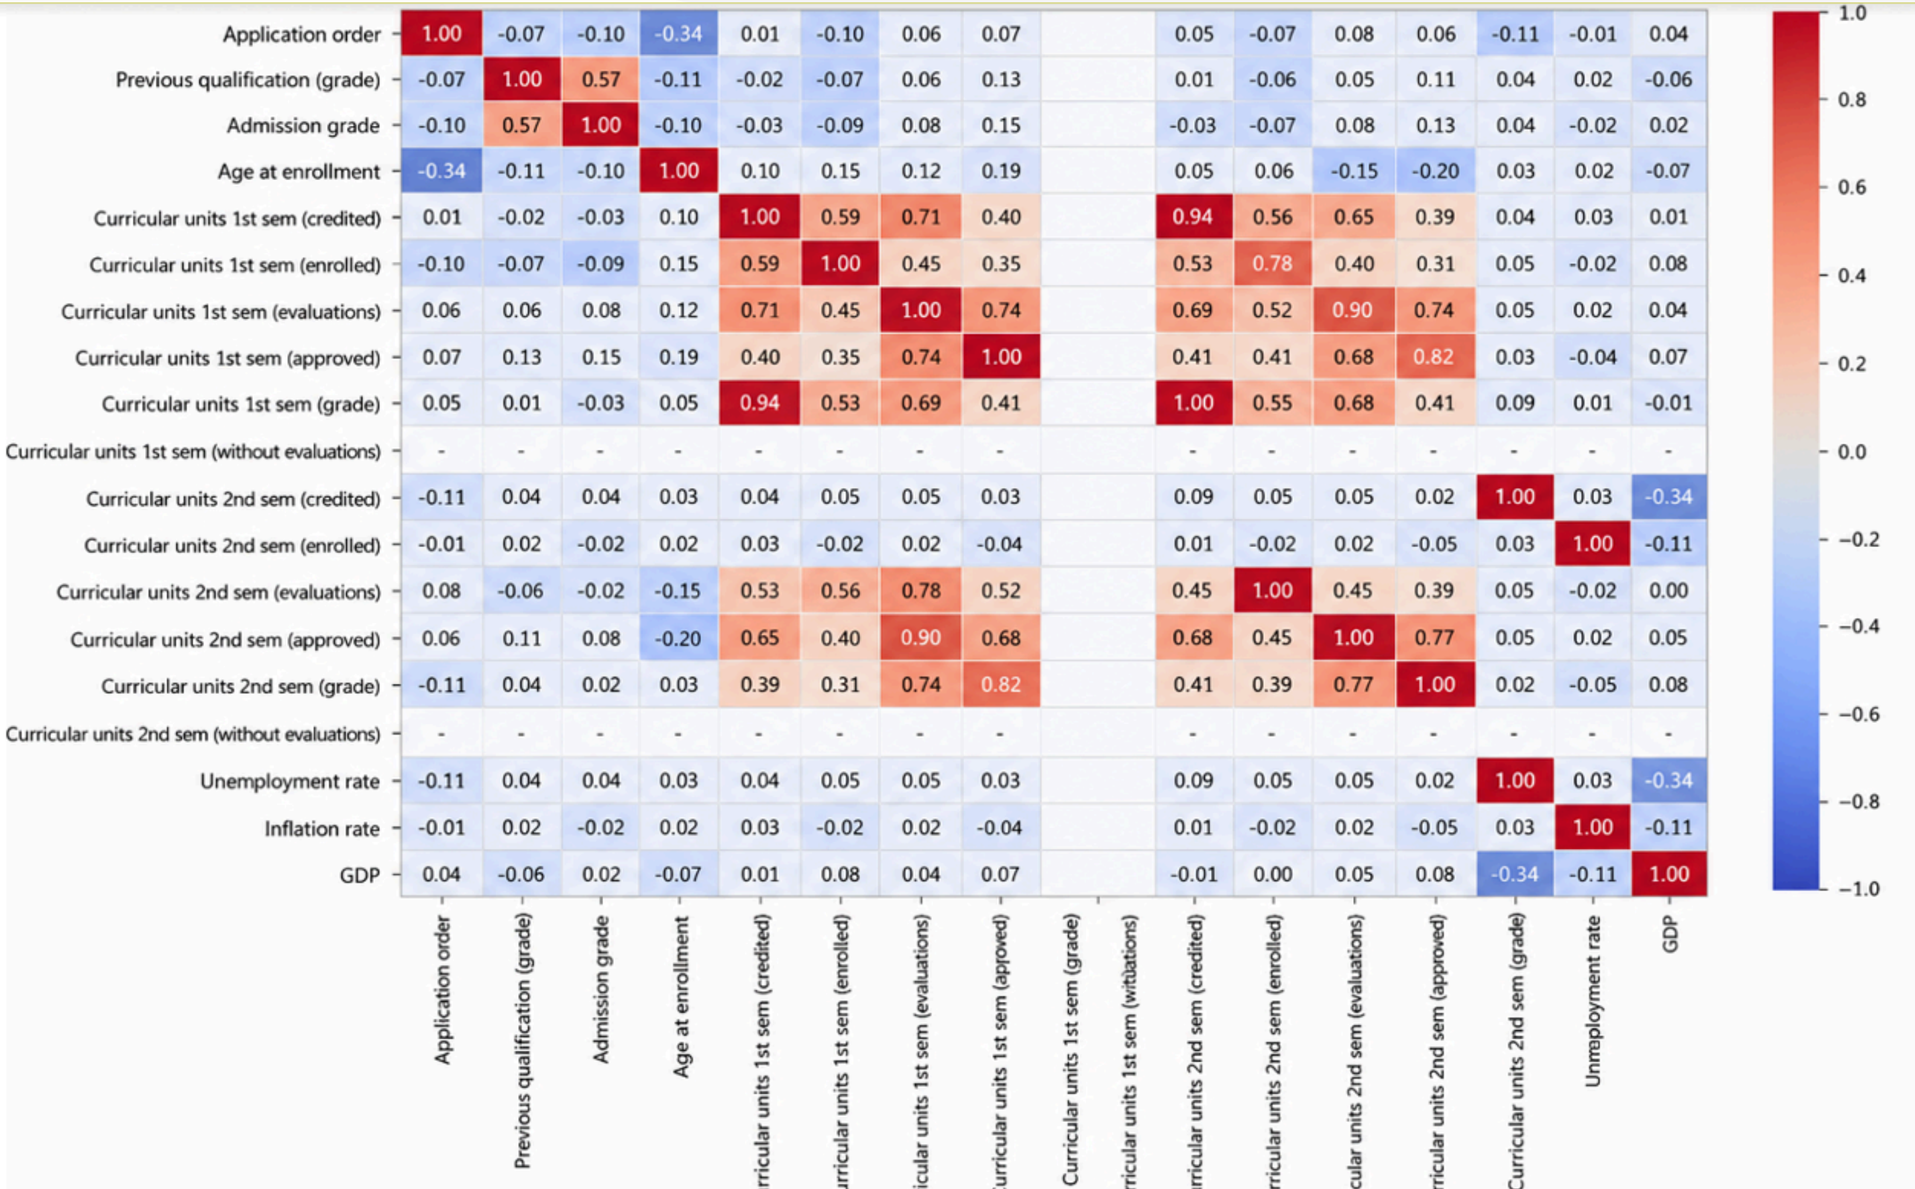

Corrélations fortes entre variables académiques.

Relations importantes entre notes et unités validées.

Variables académiques étroitement liées.

Présence de redondance entre certaines variables.

Relation notes / réussite

- Les étudiants diplômés obtiennent généralement de meilleures notes.
- Les notes du 2ème semestre distinguent clairement les étudiants Graduate et Dropout.
- Une meilleure performance académique est associée à la réussite.
- Les étudiants en réussite présentent des notes plus élevées.
- Les résultats du 2ème semestre constituent un indicateur important de réussite.
- Les écarts de notes entre Graduate et Dropout sont significatifs.

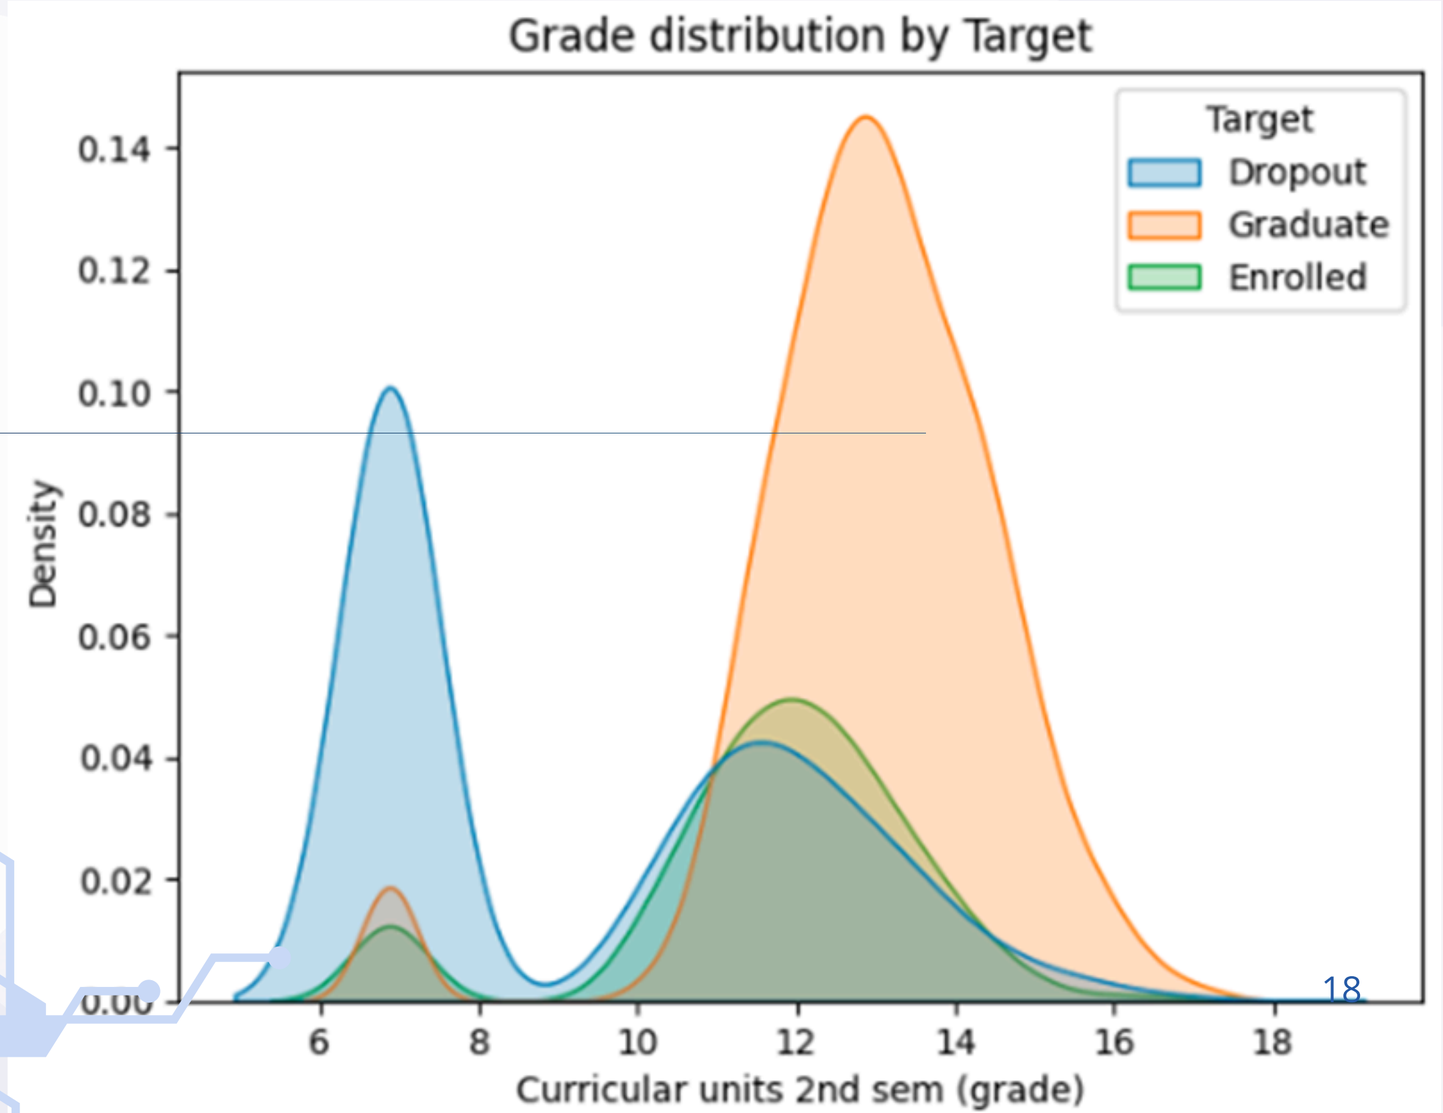

PRÉTRAITEMENT DES DONNÉES

Étapes réalisées

- Suppression de la classe Enrolled
- Transformation en classification binaire
- Graduate = 1
- Dropout = 0
- Encodage des variables catégorielles
- Traitement des valeurs aberrantes
- Normalisation des données
- Séparation Train/Test

MODÈLES DÉVELOPPÉS ET RÉSULTATS

Résultat et Modèle retenu

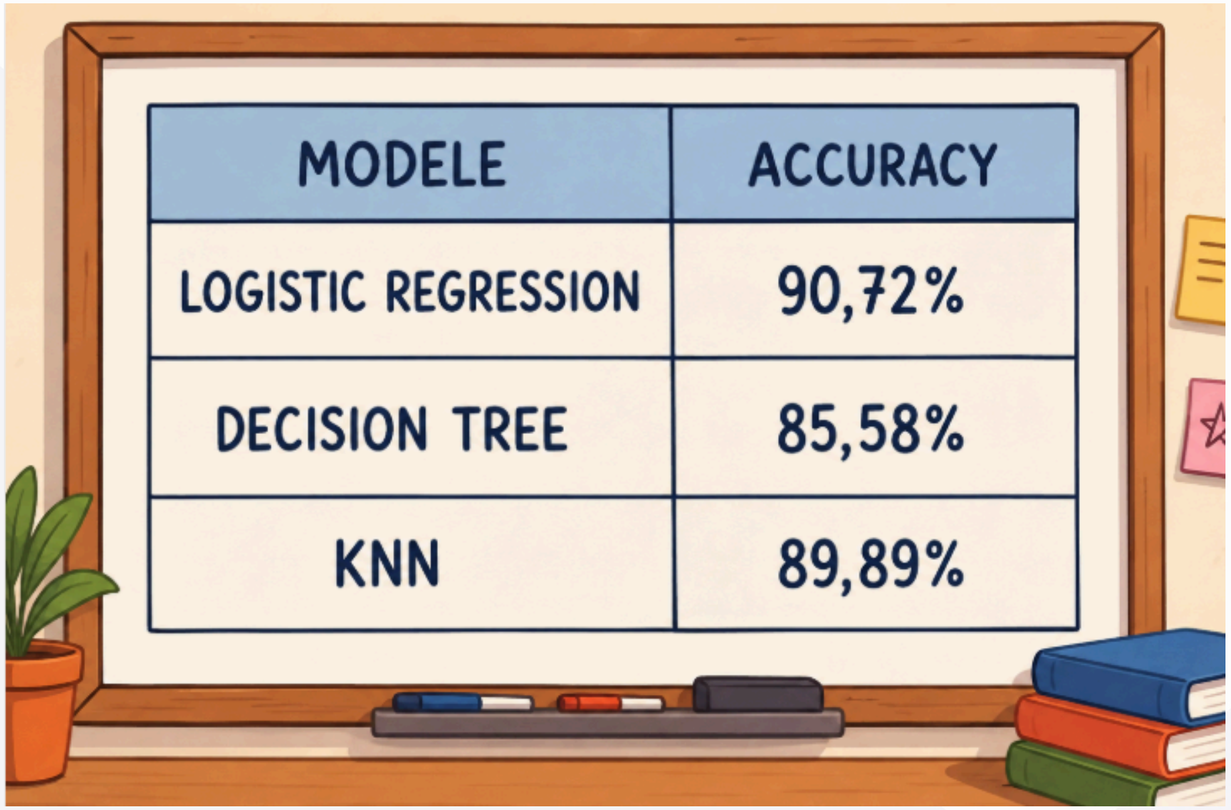

MODELE	ACCURACY
LOGISTIC REGRESSION	90,72%
DECISION TREE	85,58%
KNN	89,89%

Le meilleur modèle

Régression Logistique (Logistic Regression)

Facteurs les plus influents

Notes du 2ème semestre

Unités validées

Notes du 1er semestre

Âge à l'inscription

DÉMONSTRATION

cette démonstration présente les principales fonctionnalités de la platforme EDUPREDICT ainsi que le processus de la prediction du réussite

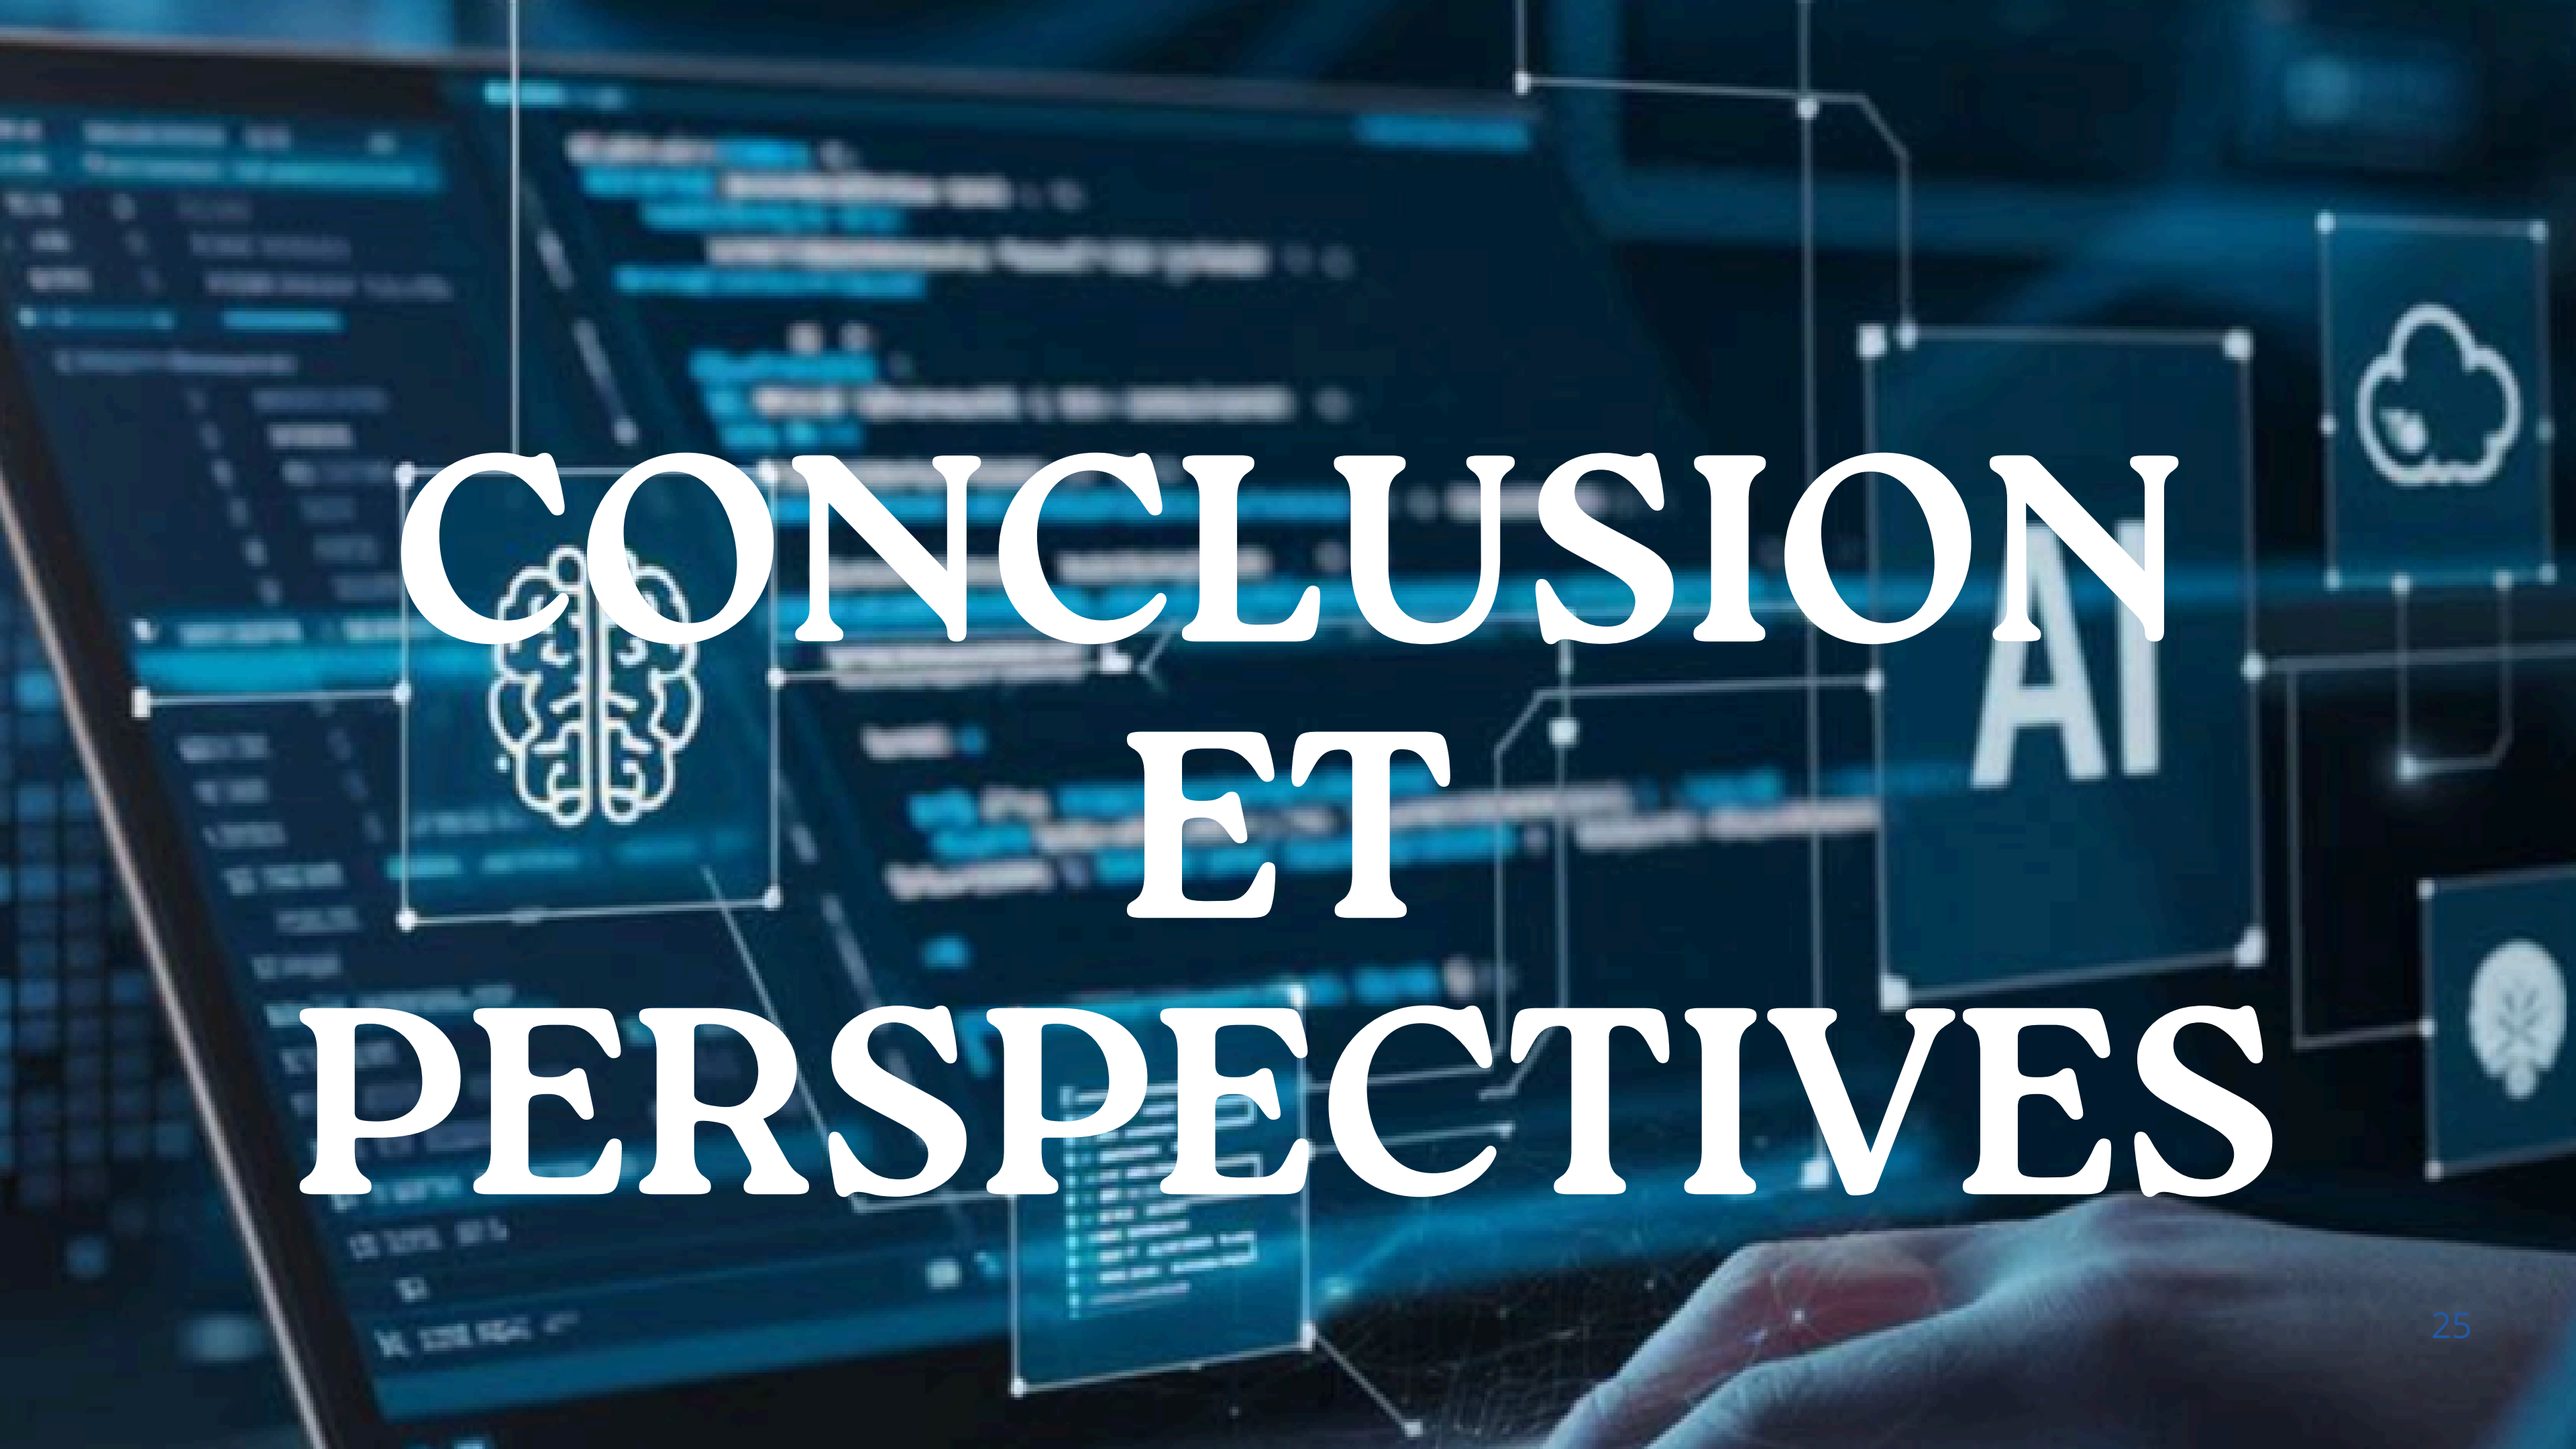

CONCLUSION ET PERSPECTIVES

CONCLUSION

En conclusion, ce projet a permis de développer un système intelligent capable de prédire la réussite académique des étudiants à partir de leurs données académiques, démographiques et socio-économiques. Après les différentes étapes de préparation des données, d'analyse exploratoire et d'entraînement de plusieurs modèles de Machine Learning, le modèle Logistic Regression s'est révélé le plus performant avec une accuracy de 90,72 %, devant KNN (89,89 %) et Decision Tree (85,58 %).

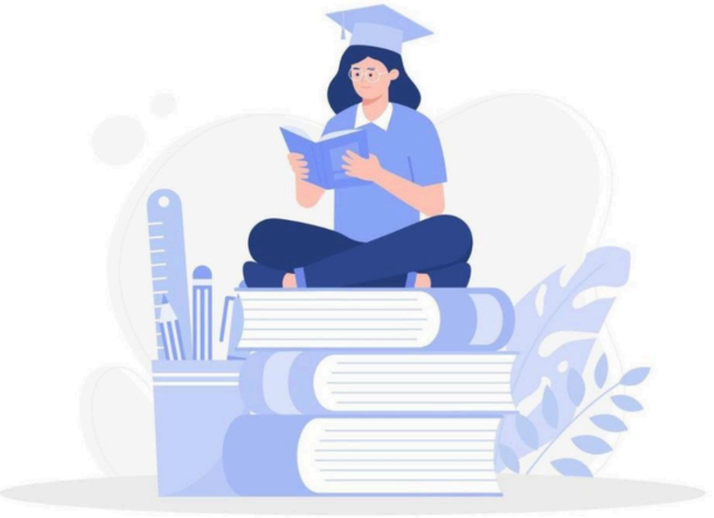

Perspectives

Tester des modèles plus performants (Random Forest, XGBoost, Deep Learning).
Intégrer de nouvelles données académiques et comportementales.
Développer une application web d'aide à la décision.
Améliorer continuellement le modèle grâce à de nouvelles données.

CITATION:

PRÉDIRE AUJOURD'HUI, C'EST MIEUX AGIR DEMAIN

MERCI

POUR VOTRE ATTENTION

TEMPS D'ÉCHANGES

AVEZ-VOUS DES QUESTIONS ?