RAPPORT DE PROJET DE FIN D'ÉTUDE

En vue de l'obtention

Du diplôme de Licence d'Excellence

En

Intelligence Artificielle

Sous le thème

Système intelligent de prédiction de la réussite académique

Réalisé par :

- ELALAMI Sara
- EL ASRI Hind
- ASSAFA Aya

Présenté le 20 Juin 2026 Devant le jury composé de :

Pr. AHAJJAM TARIK	Professeur à FSBM	Président
Pr . SADIQ MOUNIR	Professeur à FSBM	Examinateur
Pr. NOUH SAID	Professeur à FSBM	Examinateur
Pr. KANDALI KHALID	Professeur à FSBM	Encadrant

Année universitaire: 2025-2026


بسم الله الرحمن الرحيم

Dédicace

À nos très chers parents,
pour leur amour inconditionnel, leur soutien, leurs sacrifices et leurs encouragements tout au long de notre parcours.

À nos familles,
qui ont toujours cru en nous et nous ont donné la force de continuer malgré les difficultés.

À nos amis et à toutes les personnes qui nous ont soutenues de près ou de loin durant la réalisation de ce projet.

Enfin, à tous nos professeurs,
qui ont contribué à notre formation et à notre réussite académique.

Nous dédions ce travail avec respect, gratitude et affection.

Remerciements

Au terme de ce travail, nous tenons à exprimer notre sincère gratitude à toutes les personnes ayant contribué, de près ou de loin, à la réalisation de ce projet.

Nous adressons nos remerciements à Monsieur le Doyen de la Faculté pour son engagement en faveur de la qualité de l'enseignement et du développement académique.

Nous remercions également les membres du jury pour le temps consacré à l'évaluation de ce travail ainsi que pour leurs remarques constructives.

Nos remerciements les plus sincères vont à notre encadrant, Professeur Khalid Kandali, pour son accompagnement, sa disponibilité et la qualité de ses conseils tout au long de ce projet.

Enfin, nous exprimons notre reconnaissance à nos familles, amis et camarades pour leur soutien et leurs encouragements durant cette expérience.

Résumé

Ce rapport présente le développement d'un système intelligent de prédiction de la réussite académique des étudiants, basé sur des techniques de Machine Learning. Dans un contexte où la réussite universitaire constitue un enjeu majeur pour les établissements d'enseignement, cette solution vise à anticiper les performances des étudiants afin de mieux orienter les actions pédagogiques et prévenir les situations d'échec.

Le système repose sur l'analyse de données académiques contenant différentes caractéristiques liées aux étudiants (notes, assiduité, facteurs socio-académiques, etc.). Ces données sont d'abord prétraitées afin de corriger les valeurs manquantes, normaliser les variables et encoder les données catégorielles. Une analyse exploratoire est ensuite réalisée pour identifier les relations entre les variables et les facteurs influençant la réussite.

Plusieurs modèles de Machine Learning sont implémentés, notamment la régression logistique, les k plus proches voisins (KNN) et les arbres de décision. Ces modèles sont entraînés sur un ensemble de données d'apprentissage puis évalués à l'aide de métriques telles que l'accuracy, la précision, le recall et la matrice de confusion, afin de sélectionner le modèle le plus performant.

Une fois le modèle optimal choisi, le système permet de prédire le résultat académique d'un nouvel étudiant, en indiquant s'il est susceptible de réussir ou d'échouer, accompagné d'un niveau de confiance. Les résultats sont également présentés sous forme de visualisations pour faciliter leur interprétation.

Ce projet s'inscrit dans une démarche d'aide à la décision et d'amélioration du suivi pédagogique. Il offre une base pour le développement de systèmes intelligents capables d'accompagner les établissements dans l'optimisation de la réussite des étudiants. Des perspectives d'évolution incluent l'intégration de nouvelles variables, l'utilisation de modèles plus avancés et l'adaptation à différents contextes éducatifs.

Mots-clés :

Machine Learning, réussite étudiante, prédiction académique, classification binaire, évaluation des performances.

Abstract

This report presents the development of an intelligent system for predicting students' academic success using Machine Learning techniques. In a context where academic achievement is a major concern for educational institutions, this solution aims to anticipate student performance in order to better guide pedagogical actions and prevent failure.

The system is based on the analysis of academic data containing various features related to students (grades, attendance, socio-academic factors, etc.). These data are first preprocessed to handle missing values, normalize variables, and encode categorical data. An exploratory data analysis is then conducted to identify relationships between variables and determine the factors influencing academic success.

Several Machine Learning models are implemented, including Logistic Regression, K-Nearest Neighbors (KNN), and Decision Trees. These models are trained on a training dataset and evaluated using performance metrics such as accuracy, precision, recall, and confusion matrix, in order to select the most effective model.

Once the optimal model is selected, the system is able to predict the academic outcome of a new student, indicating whether they are likely to succeed or fail, along with a confidence level. The results are also presented through visualizations to facilitate interpretation.

This project is part of a decision-support approach aimed at improving academic monitoring. It provides a foundation for the development of intelligent systems that can assist educational institutions in optimizing student success. Future improvements may include the integration of additional features, the use of more advanced models, and adaptation to different educational contexts.

Keywords:

Machine Learning, academic prediction, data preprocessing, binary classification, model evaluation.

ملخص

يقدم هذا التقرير نظامًا ذكيًا للتنبؤ بنجاح أو فشل الطلاب دراسيًا، وذلك بالاعتماد على تقنيات التعلم الآلي. في ظل التحديات التي تواجه المؤسسات التعليمية في تحسين مستوى النجاح الجامعي، تهدف هذه المنظومة إلى تحليل أداء الطلاب والتنبؤ بنتائجها من أجل دعم اتخاذ القرار وتحسين المتابعة البيداغوجية.

يعتمد النظام على تحليل بيانات أكاديمية تحتوي على مجموعة من الخصائص المرتبطة بالطلاب مثل النقاط، نسبة الحضور، والعوامل الاجتماعية والأكاديمية. يتم في البداية معالجة هذه البيانات من خلال تنظيفها، معالجة القيم الناقصة، وتطبيعها، بالإضافة إلى ترميز المتغيرات النوعية. بعد ذلك، يتم إجراء تحليل استكشافي للبيانات بهدف فهم العلاقات بين المتغيرات وتحديد العوامل المؤثرة على النجاح الدراسي.

تم تطبيق عدة نماذج من التعلم الآلي، من بينها الانحدار اللوجستي، خوارزمية أقرب الجيران (KNN)، وأشجار القرار. يتم تدريب هذه النماذج باستخدام بيانات التدريب، ثم تقييمها اعتمادًا على مقاييس مثل الدقة (Accuracy)، الدقة النوعية (Precision)، الاسترجاع (Recall)، ومصفوفة الالتباس، وذلك لاختيار النموذج الأفضل أداءً.

بعد اختيار النموذج الأمثل، يمكن للنظام التنبؤ بنتيجة طالب جديد، مع تحديد ما إذا كان من المتوقع أن ينجح أو يرسب، بالإضافة إلى نسبة الثقة في التنبؤ. كما يتم عرض النتائج باستخدام رسوم بيانية لتسهيل تفسيرها.

يندرج هذا المشروع ضمن إطار أنظمة دعم القرار، حيث يساهم في تحسين جودة التعليم من خلال مساعدة المؤسسات التعليمية على تتبع أداء الطلاب واتخاذ قرارات مبنية على البيانات. كما يمكن تطوير هذا النظام مستقبلًا بإضافة متغيرات جديدة واستخدام نماذج أكثر تقدمً

الكلمات المفتاحية:

التعلّم الآلي، التنبؤ الأكاديمي، نجاح الطلبة، التصنيف الثنائي، تقييم النماذج.

Table de matiere

Dédicace....3
Remerciements....4
Résumé....5
Abstract....6
ملخص....7
Table de matiere....8
Liste des figures....12
Liste des tableaux....13
Liste des équations....14
Liste des abreviations....15
Introduction....16
Chapitre 1: Contexte général....17
1. Introduction....18
2. Contexte général du projet....18
3. Problématique....18
4. Objectifs du projet....19
5. Cahier des charges du projet....19
   5.1 Besoins fonctionnels....19
   5.2 Architecture technique....20
   5.3 Contraintes techniques....20
6. Planification du projet et organisation des taches....20
   6.1 planification du projet....20
   6.2 Répartition des tâches....21
7. Organisation du rapport....22
8. Conclusion....22
Chapitre 2 : État de l'art....23
1. Introduction....24
2. Travaux existants....24
3. Analyse critique des travaux existants....26
4. Positionnement du projet....27
5. Conclusion....28

Chapitre 3 : Présentation des données 29
1. Introduction 30
2. Description du dataset 30
3. Description des variables 31
3.1 Variables démographiques 31
3.2 Variables académiques 31
3.3 Variables socio-économiques 31
3.4 Variables liées à la performance académique 31
3.5 Variables économiques externes 32
3.6 Variable cible 32
4. Problèmes rencontrés 32
4.1 Valeurs manquantes 32
4.2 Données catégorielles 32
4.3 Déséquilibre des classes 32
4.4 Données bruitées 33
5. Conclusion 33
Chapitre 4 : Analyse exploratoire des données (EDA) 34
1. Introduction 35
2. Analyse descriptive des données 35
3. Analyse des valeurs aberrantes et étude de leur impact 35
3.1 Problématique et objectifs 35
3.2 Méthode de détection : IQR 35
3.3 Identification des valeurs aberrantes 36
3.4 Visualisation des distributions avant traitement 37
3.5 *Stratégie de traitement : méthode du clipping* 37
3.6 Validation des résultats après traitement 38
3.7 Impact du traitement sur la qualité des données 38
4. Analyse des distributions 39
4.1 Objectifs de l'analyse 39
4.2 Analyse de l'asymétrie 39
4.3 Analyse de l'aplatissement 40
4.4 *Visualisation des distributions par histogrammes* 41
5. Analyse des variables catégorielles 42

5.1 Étude de la variable cible (Target) 42
5.2 Analyse des variables catégorielles 43
6. Analyse des relations entre variables 44
6.1 Influence des performances académiques 44
6.2 Influence des facteurs socio-démographiques 45
6.3 Influence de l'âge à l'inscription 46
7. Analyse multivariée 47
7.1 Analyse des distributions sur la diagonale 47
7.2 Analyse des relations entre variables 48
8. Conclusion 49
Chapitre 5 : Prétraitement des données 50
1. Introduction 51
2. Chargement et exploration initiale du dataset 51
3. Traitement de la variable cible 51
4. Encodage des variables catégorielles 52
5. Sélection des caractéristiques (Feature Selection) 53
6. Séparation des variables explicatives et de la variable cible 55
7. Division du dataset 55
8. Équilibrage des classes (SMOTE) 55
9. Normalisation des variables numériques 57
10. Conclusion 58
Chapitre 6 : Modélisation 59
1. Introduction 60
2. Modèle de Régression Logistique 60
2.1 Optimisation du modèle 60
2.2 Configuration finale du modèle 61
3. Modèle K-Nearest Neighbors (KNN) 62
3.1 Optimisation du modèle KNN 62
3.2 Configuration finale du modèle 63
4. Modèle Arbre de Décision 63
4.1 Optimisation avec GridSearchCV 64
4.2 Configuration finale du modèle 64
5. Conclusion 64

Chapitre 7 : Évaluation des modèles 65
1. Introduction 66
2. Métriques d'évaluation utilisées 66
2.1 Accuracy (Exactitude) 66
2.2 Precision (Précision) 66
2.3 Recall (Rappel) 67
2.4 Matrice de confusion 67
3. Entraînement et évaluation des modèles 67
3.1 Régression Logistique 67
3.2 Decision Tree (Arbre de Décision) 69
3.3 Decision Tree Tuned (Arbre de Décision optimisé) 70
3.4 K-Nearest Neighbors (KNN) 71
4. Analyse comparative des modèles 72
4.1 Comparaison des métriques 72
4.2 Comparaison graphique des performances 73
4.3 Analyse du surapprentissage (Overfitting) 74
5. Sélection du modèle final 76
6. Conclusion 77
Chapitre 8 : Résultats et discussion 78
1. Introduction 79
2. Présentation générale de l'interface 79
3. Architecture technique de l'application 80
4. Fonctionnalités principales de l'application 80
5. Simulation d'une prédiction pour un nouvel étudiant 83
6. Affichage du résultat et du niveau de confiance 84
7. Recommandations personnalisées 84
8. Apport de l'interface dans le système proposé 85
9. Accès à l'application 86
10. Conclusion 86
Conclusion générale 87
Bibliographie 89

Liste des figures

Figure 1: Workflow général du projet 20
Figure 2:Diagramme de Gantt 21
Figure 3:Nombre de valeurs aberrantes par variable 36
Figure 4:Boxplot avant clipping : Age at enrollment 37
Figure 5:Boxplot avant clipping : Curricular units 1st sem (grade) 37
Figure 6:Boxplot après clipping : variables académiques 38
Figure 7:Boxplot après clipping : âge à l'inscription 38
Figure 8: Analyse du skewness des variables numériques 40
Figure 9: Analyse du kurtosis des variables numériques 41
Figure 10:Histogrammes des principales variables numériques 42
Figure 11:Répartition de la variable cible (Target) 43
Figure 12:Distribution des notes selon la variable cible 44
Figure 13:Matrice de corrélation des variables numériques 45
Figure 14: Répartition de la réussite selon le statut de boursier et le genre 46
Figure 15: Relation entre l'âge à l'inscription et la variable cible 47
Figure 16:Pairplot des principales variables numériques 48
Figure 17: Pipeline de prétraitement des données 51
Figure 18: Variables supprimées suite à l'analyse de corrélation (|corrélation| < 0,18) 54
Figure 19: Distribution des classes de la variable cible avant l'application de SMOTE 56
Figure 20: Distribution des classes de la variable cible après application de SMOTE 57
Figure 21: Effet de la normalisation sur la distribution des variables 57
Figure 22: Optimisation du modèle Régression Logistique selon le paramètre max_iter 61
Figure 23: Optimisation du modèle KNN selon le nombre de voisins K. 63
Figure 24: Matrice de confusion de la Régression Logistique 68
Figure 25: Matrice de confusion du Decision Tree 69
Figure 26: Matrice de confusion du Decision Tree Tuned 70
Figure 27:Matrice de confusion du modèle KNN 72
Figure 28: Comparaison de l'Accuracy et du Recall 73
Figure 29: Courbes ROC et Precision-Recall pour la classe Échec 74
Figure 30: Comparaison entre Train Accuracy et Test Accuracy 75
Figure 31:Matrice de confusion de la Régression Logistique 76
Figure 32: Page d'accueil du tableau de bord de l'application 80
Figure 33: Module d'importation et d'aperçu du jeu de données 81
Figure 34: Module de prétraitement : encodage, équilibrage SMOTE et sélection des variables 81
Figure 35: distribution de la cible, corrélations et valeurs aberrantes 82
Figure 36: Module de modélisation : comparaison des modèles et matrice de confusion 83
Figure 37: Formulaire de prédiction et résultat obtenu pour un nouvel étudiant 84
Figure 38: Module de recommandations personnalisées selon le résultat de la prédiction 85

Liste des tableaux

Tableau 1: Répartition des tâches entre les membres de l'équipe 21
Tableau 2: Tableau comparatif des travaux existants 26
Tableau 3: Résultats de performance de la Régression Logistique 68
Tableau 4: Performances du modèle Decision Tree 69
Tableau 5: Performances du modèle Decision Tree Tuned 70
Tableau 6: Performances du modèle KNN 71
Tableau 7:Comparaison des performances des modèles 72

Liste des équations

Équation 1: Calcul de l'intervalle interquartile (IQR) 35
Équation 2: Calcul de la borne inférieure 36
Équation 3: Calcul de la borne supérieure 36
Équation 4: Calcul de Skewness 39
Équation 5: Calcul de Kurtosis 41
Équation 6: Calcul de l'Accuracy 66
Équation 7: Calcul de la Precision 67
Équation 8:Calcul deRecall 67

Liste des abreviations

Abréviation	Signification
IA	Intelligence Artificielle
ML	Machine Learning (Apprentissage automatique)
EDA	Exploratory Data Analysis (Analyse exploratoire des données)
CSV	Comma-Separated Values (Format de fichier de données tabulaires)
KNN	K-Nearest Neighbors (k plus proches voisins)
DT	Decision Tree (Arbre de décision)
LR	Logistic Regression (Régression logistique)
ACC	Accuracy (Exactitude du modèle)
PRE	Precision (Précision)
REC	Recall (Rappel)
CM	Confusion Matrix (Matrice de confusion)
DS	Data Science (Science des données)
SKL	Scikit-learn (Bibliothèque Python de Machine Learning)
PD	Pandas (Bibliothèque de manipulation de données)
NP	NumPy (Bibliothèque de calcul numérique)

Introduction

L'augmentation du nombre d'étudiants dans l'enseignement supérieur représente aujourd'hui un défi important pour les établissements universitaires, notamment en matière de réussite académique et de prévention du décrochage. Parallèlement, la numérisation croissante des processus éducatifs a conduit à la production d'un volume important de données relatives aux parcours étudiants.

Dans ce contexte, l'Intelligence Artificielle, et plus particulièrement le Machine Learning, constitue une approche prometteuse pour l'analyse et l'exploitation de ces données. Contrairement aux méthodes descriptives classiques, ces techniques permettent d'identifier des relations complexes entre variables et de construire des modèles capables d'anticiper certains comportements ou résultats académiques.

Appliquée au domaine éducatif dans le cadre des Learning Analytics, l'analyse prédictive offre de nouvelles perspectives pour accompagner les établissements dans leurs processus décisionnels. Elle permet notamment d'identifier précocement les étudiants susceptibles de rencontrer des difficultés académiques et de soutenir la mise en place d'actions d'accompagnement adaptées.

C'est dans cette perspective que s'inscrit ce projet de fin d'études, dont l'objectif est de développer un système de prédiction du statut académique des étudiants à partir de données éducatives. Pour atteindre cet objectif, une démarche complète de Data Science a été mise en œuvre, incluant l'analyse exploratoire des données, le prétraitement, la modélisation, l'évaluation comparative des modèles et le développement d'une interface applicative.

Ce rapport présente la méthodologie adoptée ainsi que les résultats obtenus au cours des différentes phases du projet. Il met en évidence l'apport du Machine Learning dans l'exploitation des données académiques afin de produire des outils d'aide à la décision orientés vers l'amélioration du suivi étudiant.

Chapitre 1: Contexte général

1. Introduction

L'évolution des technologies de l'information et le développement des outils numériques ont favorisé l'émergence de nouvelles approches dans le domaine de l'éducation, notamment pour l'analyse des données académiques et le suivi des parcours étudiants.

Dans ce contexte, ce premier chapitre présente le cadre général du projet de fin d'études. Il expose le contexte du sujet et les principaux défis rencontrés dans l'enseignement supérieur, avant de formuler la problématique étudiée. Il présente également les objectifs du projet, le cahier des charges du système proposé ainsi que la méthodologie adoptée pour sa réalisation.

2. Contexte général du projet

L'intelligence artificielle occupe aujourd'hui une place importante dans le développement des systèmes d'aide à la décision. Dans le domaine de l'enseignement supérieur, l'un des principaux enjeux consiste à améliorer la réussite académique tout en réduisant les situations d'abandon et d'échec.

La numérisation des parcours universitaires permet désormais de disposer d'un volume important de données académiques et socio-économiques relatives aux étudiants (notes, âge, statut de bourse, informations administratives, etc.). L'exploitation de ces données à travers les méthodes de Machine Learning offre de nouvelles possibilités d'analyse et de prédiction.

Ces approches permettent d'identifier les facteurs associés à la réussite académique et de développer des modèles capables d'estimer le statut futur des étudiants afin de soutenir les processus d'aide à la décision dans le contexte éducatif.

3. Problématique

Les établissements d'enseignement supérieur disposent généralement de mécanismes de suivi pédagogique destinés à accompagner les étudiants tout au long de leur parcours universitaire. Néanmoins, les taux d'échec et d'abandon demeurent élevés dans de nombreux contextes académiques, ce qui soulève la question de l'efficacité des dispositifs d'intervention actuels.

L'une des principales limites des approches traditionnelles réside dans leur caractère rétrospectif : les difficultés des étudiants ne sont souvent identifiées qu'une fois les résultats académiques constatés, c'est-à-dire à un stade où les possibilités d'intervention précoce sont réduites. Par ailleurs, ces approches reposent fréquemment sur des analyses descriptives univariées ou sur l'appréciation subjective des enseignants, ce qui limite leur capacité à capturer les relations complexes et multidimensionnelles entre les différentes variables influençant le parcours académique.

À cela s'ajoute le fait que les données académiques disponibles au sein des établissements sont rarement structurées et exploitées de manière systématique. La multiplicité des variables en jeu —

notes, assiduité, contexte socio-économique, profil démographique — rend difficile l'identification des facteurs les plus déterminants dans la réussite ou l'abandon des étudiants, sans recours à des méthodes d'analyse adaptées.

Dans ce contexte, la question de recherche centrale de ce projet est la suivante :

Comment concevoir un système intelligent basé sur le Machine Learning, capable de prédire la réussite ou l'échec des étudiants à partir de leurs données académiques, tout en fournissant une interprétation exploitable pour l'aide à la décision ?

4. Objectifs du projet

Afin de répondre à cette problématique, ce projet a pour objectif principal de concevoir, développer et évaluer un système de prédiction du statut académique des étudiants basé sur les techniques de Machine Learning.

Cet objectif général se décline en plusieurs objectifs spécifiques :

• **Objectif analytique :** réaliser une analyse exploratoire des données académiques afin d'identifier les variables les plus associées à la réussite et au décrochage.

• **Objectif technique :** mettre en place un pipeline de préparation des données comprenant le prétraitement, l'encodage, la normalisation, l'équilibrage des classes et la sélection des variables pertinentes.

• **Objectif de modélisation :** entraîner, évaluer et comparer plusieurs algorithmes de classification (Régression Logistique, K-Nearest Neighbors et Arbre de Décision) afin de sélectionner le modèle le plus adapté au problème étudié.

• **Objectif applicatif :** développer une interface web interactive permettant d'exploiter le modèle pour effectuer des prédictions sur de nouveaux profils étudiants et restituer les résultats de manière accessible.

5. Cahier des charges du projet

Le développement du système de prédiction proposé repose sur un ensemble de spécifications fonctionnelles, non fonctionnelles et techniques.

5.1 Besoins fonctionnels

Le système doit permettre :

- Le chargement de données académiques sous formats tabulaires (CSV/Excel).

- L’exécution du pipeline de préparation des données (encodage, normalisation, équilibrage et sélection des variables).
- • L’exploitation du modèle entraîné pour effectuer une prédiction du statut académique d’un nouvel étudiant.
- • L’affichage du résultat accompagné d’un niveau de confiance.
- • La visualisation des principales étapes du pipeline et des résultats obtenus via une interface graphique.

5.2 Architecture technique

Le système repose sur une architecture en pipeline de Machine Learning structurant le processus de traitement des données en plusieurs étapes successives et cohérentes.

Ce pipeline suit le schéma suivant :

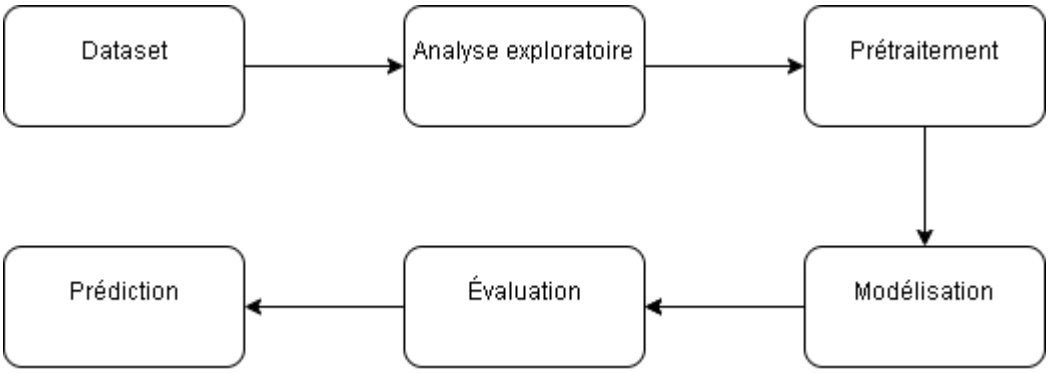


Figure 1: Workflow général du projet

Cette architecture permet d’assurer la modularité du système, la reproductibilité des expérimentations ainsi qu’une séparation claire entre les différentes étapes du processus de data science.

5.3 Contraintes techniques

Le projet est développé dans un environnement reposant sur :

- Python pour le traitement des données et la modélisation.
- Des bibliothèques open-source dédiées au Machine Learning et à la visualisation.
- Une architecture modulaire séparant le traitement des données et l’interface utilisateur.

6. Planification du projet et organisation des taches

6.1 planification du projet

Le projet s’étale sur une période de dix semaines couvrant les différentes étapes du cycle de data science.

Les premières semaines sont consacrées à la compréhension du problème et à l'analyse des données. Une phase d'exploration approfondie permet ensuite d'identifier les relations entre variables.

La phase suivante concerne le prétraitement et la préparation des données pour la modélisation. Plusieurs modèles sont ensuite entraînés et comparés afin de sélectionner le plus performant.

Enfin, les dernières semaines sont dédiées à l'évaluation des résultats, à leur interprétation ainsi qu'à la finalisation du rapport et à la préparation de la soutenance.

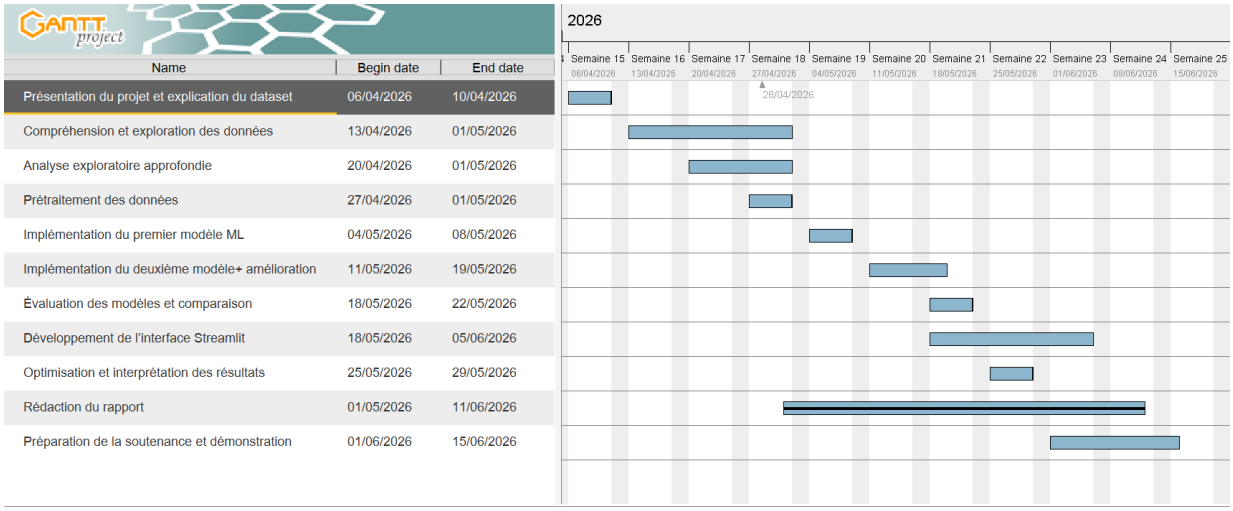


Figure 2:Diagramme de Gantt

6.2 Répartition des tâches

Dans le cadre de ce projet en équipe, les tâches ont été réparties de manière équilibrée afin d'assurer une bonne organisation et une progression cohérente du travail.
Cette organisation a permis une meilleure coordination entre les membres et une couverture complète des différentes étapes du projet.
La répartition des tâches est présentée dans le tableau ci-dessous :

Tableau 1: Répartition des tâches entre les membres de l'équipe

Tâches	Sara Elalami	Hind El Asri	Aya Assafa
Collecte et compréhension des données	X	X	X
Analyse exploratoire des données (EDA)	X		
Prétraitement des données			X
Modélisation Machine Learning		X	
Évaluation et comparaison des modèles	X		
Développement du pipeline global		X	X
Rédaction du rapport et préparation de la soutenance	X	X	X

Cette organisation a permis une meilleure coordination entre les membres de l'équipe et une couverture complète des étapes du projet.

7. Organisation du rapport

Afin de présenter de manière claire et structurée les différentes étapes de ce projet, ce rapport est organisé comme suit :

• **Chapitre 1 : Contexte général**
Présente le contexte du projet, la problématique ainsi que les objectifs visés.

• **Chapitre 2 : État de l'art**
Présente une synthèse des travaux existants, des approches et des recherches liées au domaine étudié.

• **Chapitre 3 : Présentation des données**
Décrit le dataset utilisé, ses caractéristiques ainsi que les différentes variables étudiées.

• **Chapitre 4 : Analyse exploratoire des données (EDA)**
Présente les analyses statistiques et les visualisations réalisées afin de mieux comprendre les données.

• **Chapitre 5 : Prétraitement des données**
Détaille les étapes de nettoyage, de transformation et de préparation des données pour la modélisation.

• **Chapitre 6 : Modélisation**
Présente les modèles de Machine Learning mis en œuvre pour la prédiction.

• **Chapitre 7 : Évaluation des modèles**
Compare les performances des différents modèles à l'aide de métriques adaptées.

• **Chapitre 8 : Résultats et discussion**
Analyse les résultats obtenus, leurs limites ainsi que les perspectives d'amélioration du système.

8. Conclusion

Ce chapitre a présenté le contexte général du projet ainsi que ses objectifs. L'approche proposée repose sur la conception d'un pipeline de Machine Learning permettant d'exploiter les données académiques afin de produire des prédictions fiables et interprétables.

Ce chapitre constitue la base méthodologique du projet. Le chapitre suivant sera consacré à la présentation et à l'analyse du jeu de données.

Chapitre 2 : État de l'art

1. Introduction

L'utilisation du Machine Learning dans le domaine de l'éducation a connu un développement important au cours des dernières années, notamment grâce à la disponibilité croissante des données académiques. Les établissements d'enseignement disposent aujourd'hui de nombreuses informations relatives aux étudiants, telles que leurs résultats scolaires, leurs caractéristiques démographiques, leur parcours académique ainsi que leur contexte socio-économique.

L'exploitation de ces données permet de développer des modèles prédictifs capables d'anticiper les performances académiques, d'identifier les étudiants susceptibles de rencontrer des difficultés et de détecter ceux qui présentent un risque de décrochage. Ces modèles peuvent ainsi contribuer à la mise en place de systèmes d'alerte précoce et à l'amélioration de l'accompagnement pédagogique.

Plusieurs recherches ont montré que les techniques d'apprentissage automatique constituent des outils efficaces pour analyser les facteurs associés à la réussite académique et soutenir la prise de décision au sein des établissements d'enseignement supérieur.

Ce chapitre présente les principaux travaux réalisés dans le domaine de la prédiction de la réussite académique et du décrochage universitaire. Il propose également une comparaison des approches existantes, une analyse de leurs principales limites ainsi que le positionnement du présent projet.

2. Travaux existants

Parmi les travaux pionniers dans ce domaine, Kotsiantis et al. (2004) ont étudié l'utilisation de plusieurs techniques de Machine Learning afin de prédire les performances académiques des étudiants inscrits dans un dispositif d'enseignement à distance.

Leur étude s'est appuyée sur des données démographiques ainsi que sur les résultats obtenus par les étudiants au début de leur parcours académique. Plusieurs algorithmes de classification ont été comparés, notamment les arbres de décision, K-Nearest Neighbors et les méthodes bayésiennes.

Les résultats obtenus ont montré que ces modèles pouvaient être utilisés pour identifier précocement les étudiants susceptibles de rencontrer des difficultés scolaires. Cette détection permet aux responsables pédagogiques de mettre en place des actions d'accompagnement adaptées.

Cortez et Silva (2008) se sont intéressés à la prédiction des performances scolaires d'élèves de l'enseignement secondaire portugais. Leur étude s'est appuyée sur des données académiques, démographiques, familiales et sociales.

Les auteurs ont appliqué plusieurs techniques de classification et de régression, notamment les arbres de décision et les réseaux de neurones, afin de prédire les résultats obtenus en mathématiques et en langue portugaise.

Leur analyse a mis en évidence l'importance des résultats académiques antérieurs dans la prédiction des performances futures. Elle a également montré que les facteurs sociaux et familiaux pouvaient contribuer à améliorer la qualité des prédictions.

Dans le domaine de la prédiction du décrochage universitaire, Dekker et al. (2009) ont développé plusieurs modèles de classification afin d'identifier les étudiants susceptibles d'abandonner leurs études.

Leur étude concernait des étudiants inscrits dans un programme de génie électrique et reposait sur des données préuniversitaires ainsi que sur les premiers résultats obtenus durant le parcours universitaire.

Plusieurs algorithmes ont été comparés, parmi lesquels les arbres de décision CART et C4.5, la Régression Logistique, Random Forest, les réseaux bayésiens et les méthodes basées sur des règles.

Les résultats ont montré que les données disponibles au début du parcours universitaire pouvaient être utilisées pour construire des systèmes d'alerte précoce. Les modèles développés ont permis d'identifier les étudiants à risque avec une précision satisfaisante.

Aulck et al. (2016) ont, quant à eux, exploité les données académiques et démographiques de plus de 32 000 étudiants inscrits dans une grande université publique.

L'objectif de leur étude était de prédire le décrochage universitaire à partir des informations disponibles durant les premières étapes du parcours académique. Les auteurs ont notamment utilisé la Régression Logistique et Random Forest.

Les résultats obtenus ont montré que le risque de décrochage pouvait être prédit de manière satisfaisante à partir des données académiques et démographiques. L'étude a également démontré l'importance des résultats obtenus au cours du premier semestre.

Les recherches plus récentes confirment l'intérêt croissant du Machine Learning dans le domaine éducatif. Les études utilisent principalement des algorithmes de classification tels que la Régression Logistique, les Arbres de Décision, Random Forest, K-Nearest Neighbors, Support Vector Machine et les réseaux de neurones.

Ces travaux montrent également que les performances des modèles dépendent de plusieurs facteurs, notamment la qualité des données, les variables sélectionnées, les méthodes de prétraitement et les métriques d'évaluation utilisées.

Par conséquent, aucun algorithme ne peut être considéré comme systématiquement supérieur dans tous les contextes éducatifs. La comparaison de plusieurs modèles reste donc nécessaire afin d'identifier l'approche la mieux adaptée aux caractéristiques du jeu de données étudié.

Tableau 2: Tableau comparatif des travaux existants

Référence	Objectif	Algorithmes utilisés	Principaux résultats
Kotsiantis et al. (2004)	Prédiction des performances académiques des étudiants	Arbres de décision, KNN, méthodes bayésiennes	Identification précoce des étudiants susceptibles de rencontrer des difficultés
Cortez et Silva (2008)	Prédiction des performances scolaires	Arbres de décision, réseaux de neurones, techniques de régression	Mise en évidence de l'importance des résultats académiques antérieurs
Dekker et al. (2009)	Prédiction du décrochage universitaire	Régression logistique, arbres de décision, Random Forest et réseaux bayésiens	Détection précoce des étudiants présentant un risque d'abandon

3. Analyse critique des travaux existants

L'analyse des travaux présentés montre que les techniques de Machine Learning permettent d'obtenir des résultats encourageants dans la prédiction des performances académiques et du décrochage universitaire.

Cependant, plusieurs limites peuvent être relevées.

Tout d'abord, certaines études sont réalisées à partir de jeux de données provenant d'un seul établissement ou d'un nombre limité d'étudiants. Cette limitation peut réduire la capacité de généralisation des modèles à d'autres populations ou à d'autres contextes éducatifs.

Ensuite, plusieurs recherches se concentrent principalement sur les performances prédictives des algorithmes sans accorder suffisamment d'importance à l'interprétabilité des résultats. Or, dans le domaine éducatif, les responsables pédagogiques doivent pouvoir comprendre les facteurs qui conduisent un modèle à classer un étudiant comme étant à risque.

De plus, les travaux existants utilisent des variables, des méthodes de prétraitement et des métriques d'évaluation différentes. Cette diversité rend parfois difficile la comparaison directe des résultats obtenus.

Certaines études se limitent également à l'utilisation d'un seul algorithme ou à la comparaison d'un nombre restreint de modèles. Il devient alors difficile de déterminer si les performances obtenues sont réellement dues à l'algorithme utilisé ou aux choix effectués durant le prétraitement des données.

Ces limites montrent l'importance de mettre en place une démarche comparative dans laquelle plusieurs algorithmes sont entraînés et évalués sur le même jeu de données, en utilisant les mêmes techniques de prétraitement et les mêmes métriques d'évaluation.

4. Positionnement du projet

Les travaux existants démontrent l'efficacité des techniques de Machine Learning pour prédire la réussite académique et détecter les étudiants présentant un risque de décrochage.

Toutefois, certaines études se limitent à un nombre restreint de variables, à un seul modèle de classification ou à un seul contexte éducatif.

Dans le cadre de ce projet, nous proposons une démarche complète reposant sur l'exploitation de données démographiques, académiques et socio-économiques.

La première étape consiste à réaliser une analyse exploratoire des données afin de comprendre leur structure, d'étudier la répartition des différentes catégories d'étudiants et d'identifier les relations entre les variables.

Une phase de prétraitement est ensuite réalisée. Elle comprend notamment le traitement des valeurs manquantes, l'encodage des variables catégorielles et la normalisation des variables numériques lorsque celle-ci est nécessaire.

Plusieurs modèles de classification sont ensuite entraînés et comparés, notamment :

- la Régression Logistique ;
- K-Nearest Neighbors ;
- l'Arbre de Décision.

La Régression Logistique est choisie pour sa simplicité et son interprétabilité. K-Nearest Neighbors permet de classer les étudiants en fonction de leur proximité avec les observations déjà connues. L'Arbre de Décision est utilisé pour sa capacité à produire des règles de classification facilement compréhensibles.

Les performances des modèles sont comparées à l'aide de plusieurs métriques d'évaluation, notamment l'accuracy, la précision et le rappel.

L'utilisation de plusieurs métriques permet d'obtenir une évaluation plus complète des modèles, particulièrement lorsque les différentes classes du jeu de données ne sont pas représentées de manière équilibrée.

L'objectif principal du projet est d'identifier le modèle offrant le meilleur compromis entre performance prédictive, simplicité et interprétabilité pour prédire le statut académique des étudiants.

Le modèle retenu est ensuite intégré dans une application d'aide à la décision destinée aux responsables pédagogiques. Cette application permet de faciliter l'analyse des données et d'identifier les étudiants nécessitant éventuellement un accompagnement spécifique.

L’outil développé ne vise pas à remplacer le jugement des enseignants ou des responsables universitaires. Il constitue plutôt un système d’assistance permettant de soutenir la prise de décision et d’améliorer le suivi pédagogique des étudiants.

5. Conclusion

L’analyse de la littérature montre que le Machine Learning constitue une approche pertinente pour la prédiction de la réussite académique et du décrochage universitaire.

Les recherches existantes soulignent l’importance des données académiques, démographiques et socio-économiques dans la construction de modèles prédictifs performants.

Elles montrent également que les performances des algorithmes varient selon la nature du jeu de données, les variables sélectionnées, les techniques de prétraitement et les métriques d’évaluation utilisées.

Il est donc nécessaire de comparer plusieurs modèles dans les mêmes conditions expérimentales avant de sélectionner la solution la plus adaptée.

Le présent projet s’inscrit dans cette continuité en proposant une démarche basée sur l’analyse, le prétraitement et l’exploitation des données relatives aux étudiants.

Il compare la Régression Logistique, K-Nearest Neighbors et l’Arbre de Décision afin d’identifier le modèle le plus performant pour prédire le statut académique des étudiants.

Le chapitre suivant présente la méthodologie adoptée, le jeu de données utilisé, les différentes étapes de prétraitement ainsi que les algorithmes de classification mis en œuvre.

Chapitre 3 : Présentation des données

1. Introduction

La qualité des résultats obtenus par un modèle de Machine Learning dépend en grande partie de la qualité et de la compréhension des données utilisées lors de son apprentissage. Avant toute phase de modélisation, il est donc essentiel d'examiner en détail le jeu de données afin d'identifier sa structure, ses caractéristiques et les éventuelles contraintes pouvant influencer les analyses futures.

Dans le cadre de ce projet, nous avons utilisé un dataset dédié à la prédiction de la réussite académique des étudiants. Ce jeu de données regroupe des informations variées portant sur le profil démographique, le parcours académique et le contexte socio-économique des apprenants. L'étude de ces données constitue une étape préliminaire indispensable pour mieux comprendre les facteurs susceptibles d'influencer la réussite ou l'échec académique.

Ce chapitre présente tout d'abord le dataset retenu ainsi que ses principales caractéristiques. Il décrit ensuite les différentes catégories de variables qui le composent et met en évidence les principaux défis rencontrés lors de son exploitation. Cette analyse permet de préparer les étapes suivantes du projet, notamment l'analyse exploratoire des données, le prétraitement et la construction des modèles de prédiction.

2. Description du dataset

Dans le cadre de ce projet, nous avons utilisé un dataset provenant de la plateforme UCI Machine Learning Repository, intitulé *"Predict Students Dropout and Academic Success"*. Ce dataset est largement utilisé dans le domaine de la science des données pour l'analyse et la prédiction de la réussite académique.

Le jeu de données contient des informations relatives aux étudiants inscrits dans un établissement d'enseignement supérieur, avec pour objectif de prédire leur statut académique final. Chaque instance représente un étudiant, décrit par un ensemble de variables académiques, démographiques et socio-économiques.

Le dataset utilisé comporte **4424 observations (étudiants)** et **37 variables (features)**. La variable cible, nommée **"Target"**, indique le résultat académique de l'étudiant et prend généralement des valeurs telles que :

- *Graduate* (réussite);
- *Dropout* (abandon);
- *Enrolled* (inscrit).

Le jeu de données est distribué sous licence Creative Commons Attribution 4.0 International (CC BY 4.0) , laquelle autorise le partage, l'adaptation et l'utilisation, y compris à des fins commerciales, sous réserve de citer la source d'origine.

Bien que le dataset soit initialement prétraité, certaines modifications ont été apportées afin de l'adapter aux besoins du projet, notamment pour faciliter l'analyse et améliorer la qualité des données. Ces transformations seront détaillées dans le chapitre consacré au prétraitement.

3. Description des variables

Le dataset comprend plusieurs types de variables, que l'on peut regrouper en différentes catégories :

3.1 Variables démographiques

Ces variables décrivent les caractéristiques personnelles des étudiants :

- **Gender** : sexe de l'étudiant;
- **Age at enrollment** : âge lors de l'inscription;
- **Marital status** : situation matrimoniale;
- **Nationality** : nationalité.

3.2 Variables académiques

Elles représentent le parcours scolaire et les performances des étudiants :

- **Previous qualification** : niveau d'études précédent;
- **Previous qualification (grade)** : note obtenue précédemment;
- **Admission grade** : note d'admission;
- **Course** : filière choisie;
- **Application mode / order** : mode et ordre de candidature;

3.3 Variables socio-économiques

Ces variables donnent des informations sur le contexte social de l'étudiant

- **Mother's qualification / Father's qualification** : niveau d'éducation des parents;
- **Mother's occupation /Father's occupation** : profession des parents;
- **Scholarship holder** : boursier ou non;
- **Debtor** : situation financière (dettes);
- **Tuition fees up to date** : paiement des frais.

3.4 Variables liées à la performance académique

Elles décrivent les résultats des étudiants durant leur formation :

- **Curricular units (1st sem / 2nd sem)** :
    - unités validées;
    - unités suivies;
    - évaluations;

    - notes moyennes.
- Ces variables sont essentielles pour la prédiction car elles reflètent directement la performance académique.

3.5 Variables économiques externes

- **Unemployment rate** : taux de chômage;
- **Inflation rate** : taux d'inflation;
- **GDP** : produit intérieur brut.

3.6 Variable cible

- **Target** : variable représentant le statut académique de l'étudiant

4. Problèmes rencontrés

Bien que le dataset soit relativement propre et déjà prétraité, plusieurs problèmes ont été identifiés lors de son analyse :

4.1 Valeurs manquantes

Une inspection systématique du jeu de données a été réalisée pour détecter d'éventuelles valeurs manquantes. Aucune valeur manquante n'a été identifiée dans l'ensemble des 37 variables. Le jeu de données est donc complet et ne nécessite pas d'étape d'imputation.

4.2 Données catégorielles

Plusieurs variables sont de type qualitatif (texte), comme :

- la filière (Course);
- la nationalité;
- les qualifications des parents.

Ces variables nécessitent un encodage pour être utilisées par les modèles de Machine Learning.

4.3 Déséquilibre des classes

La variable cible présente une distribution déséquilibrée :

- Graduate : 2 209 étudiants (49,9 %)
- Dropout : 1 421 étudiants (32,1 %)
- Enrolled : 794 étudiants (18,0 %)

La classe Graduate est surreprésentée par rapport à Dropout (ratio d'environ 1,55:1). Ce déséquilibre peut biaiser les modèles en faveur de la classe majoritaire.

4.4 Données bruitées

Certaines données peuvent contenir du bruit ou des valeurs incohérentes, notamment dans :

- les notes très faibles ou nulles;
- les unités non évaluées.

Ces anomalies peuvent impacter la performance des modèles.

5. Conclusion

Dans ce chapitre, nous avons présenté le jeu de données utilisé pour la réalisation de ce projet ainsi que les différentes catégories de variables qui le composent. Cette étape a permis d'obtenir une compréhension globale des informations disponibles et d'identifier les caractéristiques les plus pertinentes pour l'étude de la réussite académique.

L'examen du dataset a également mis en évidence plusieurs défis liés à la préparation des données, notamment la présence de variables catégorielles, le risque de déséquilibre entre les classes ainsi que certaines redondances potentielles entre les attributs. Ces observations constituent des éléments importants pour la suite du projet, car elles orientent les choix méthodologiques à adopter lors du traitement des données.

La compréhension approfondie du dataset constitue ainsi une base essentielle pour les étapes suivantes. Le chapitre suivant sera consacré à l'analyse exploratoire des données, dont l'objectif est d'étudier plus en détail les distributions, les relations entre les variables et les tendances susceptibles d'influencer la réussite académique des étudiants.

Chapitre 4 : Analyse exploratoire des données (EDA)

1. Introduction

Avant de procéder à la modélisation prédictive, une phase d'exploration approfondie du jeu de données s'avère indispensable. L'Analyse Exploratoire des Données (EDA - *Exploratory Data Analysis*) se positionne à la confluence de la compréhension brute du jeu de données et de la phase de préparation des variables.

Concrètement, cette étape poursuit quatre objectifs fondamentaux :

- Évaluer et modéliser la distribution statistique des variables continues et catégorielles ;
- Détecter les anomalies ainsi que les valeurs aberrantes afin de mesurer leur influence ;
- Analyser les relations d'interdépendance et de colinéarité entre les caractéristiques ;
- Isoler les facteurs discriminants ayant un impact significatif sur la réussite ou le décrochage des apprenants.

L'ensemble de ces observations guidera le choix des techniques de prétraitement et orientera la sélection des algorithmes de Machine Learning les plus adaptés.

2. Analyse descriptive des données

Le jeu de données contient 4424 étudiants et 37 variables, comprenant des variables numériques (âge, notes, unités validées) et catégorielles (genre, filière, bourse, etc.). L'âge à l'inscription varie entre 17 et 70 ans, avec une moyenne d'environ 23 ans, reflétant une diversité importante des profils. Les variables liées aux performances académiques présentent une dispersion élevée.

3. Analyse des valeurs aberrantes et étude de leur impact

3.1 Problématique et objectifs

Les valeurs aberrantes (outliers) peuvent influencer fortement les statistiques et perturber les modèles.

Cependant, dans notre cas, certaines valeurs extrêmes (âge élevé ou notes faibles) correspondent à des cas réels (reprise d'études, échecs, etc.). Il n'est donc pas pertinent de les supprimer.

L'objectif est plutôt de limiter leur impact.

3.2 Méthode de détection : IQR

La détection des valeurs aberrantes a été opérée par la méthode de l'Écart Interquartile (IQR). Cette approche robuste repose sur le calcul de la dispersion des 50% centraux de la distribution. Les équations sous-jacentes s'articulent ainsi :

$$IQR = Q_3 - Q_1 \qquad (1)$$

Où Q_1 et Q_3 représentent respectivement le premier et le troisième quartile. À partir de cet écart, les seuils de tolérance inférieur et supérieur sont définis par les formules suivantes :

$$Borne\ Inférieure = Q_1 - 1.5 \times IQR \quad (2)$$

$$Borne\ Supérieure = Q_3 + 1.5 \times IQR \quad (3)$$

Toute observation en dehors de cet intervalle est considérée comme une valeur aberrante.

3.3 Identification des valeurs aberrantes

L'analyse des valeurs aberrantes a été réalisée à l'aide de la méthode IQR afin d'identifier les observations extrêmes.

Les résultats obtenus sont illustrés dans la figure suivante :

	0
Application order	541
Previous qualification (grade)	179
Admission grade	86
Age at enrollment	441
Curricular units 1st sem (credited)	577
Curricular units 1st sem (enrolled)	424
Curricular units 1st sem (evaluations)	158
Curricular units 1st sem (approved)	180
Curricular units 1st sem (grade)	726
Curricular units 1st sem (without evaluations)	294
Curricular units 2nd sem (credited)	530
Curricular units 2nd sem (enrolled)	369
Curricular units 2nd sem (evaluations)	109
Curricular units 2nd sem (approved)	44
Curricular units 2nd sem (grade)	877
Curricular units 2nd sem (without evaluations)	282
Unemployment rate	0
Inflation rate	0
GDP	0

dtype: int64

Figure 3:Nombre de valeurs aberrantes par variable

Cette représentation met en évidence une concentration importante de valeurs aberrantes dans les variables académiques, notamment les notes et les unités validées. Cette situation est cohérente avec la variabilité des performances des étudiants.

3.4 *Visualisation des distributions avant traitement*

Avant toute correction, les distributions ont été analysées à l'aide de boxplots.

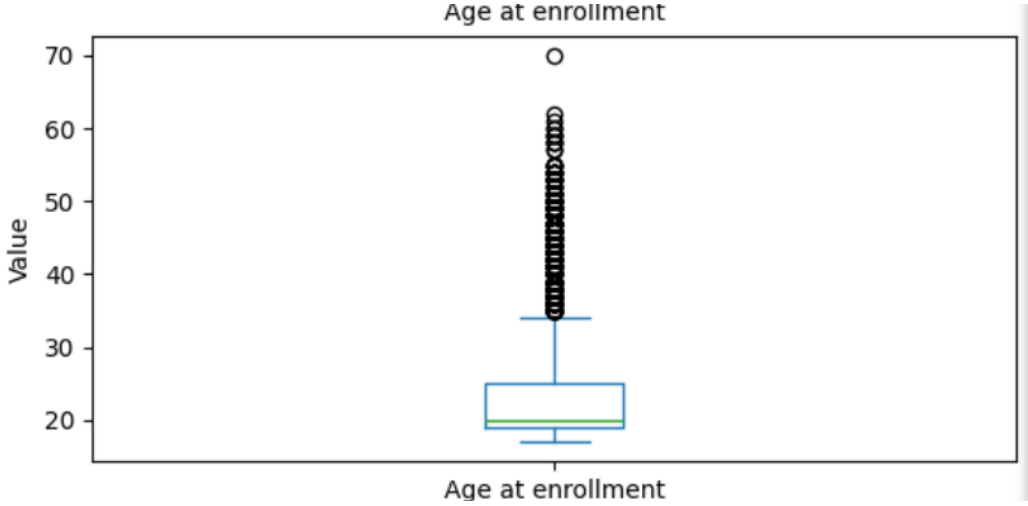


Figure 4:Boxplot avant clipping : Age at enrollment

Cette figure montre que la majorité des étudiants se situe entre 18 et 25 ans, avec la présence de valeurs extrêmes atteignant 70 ans.

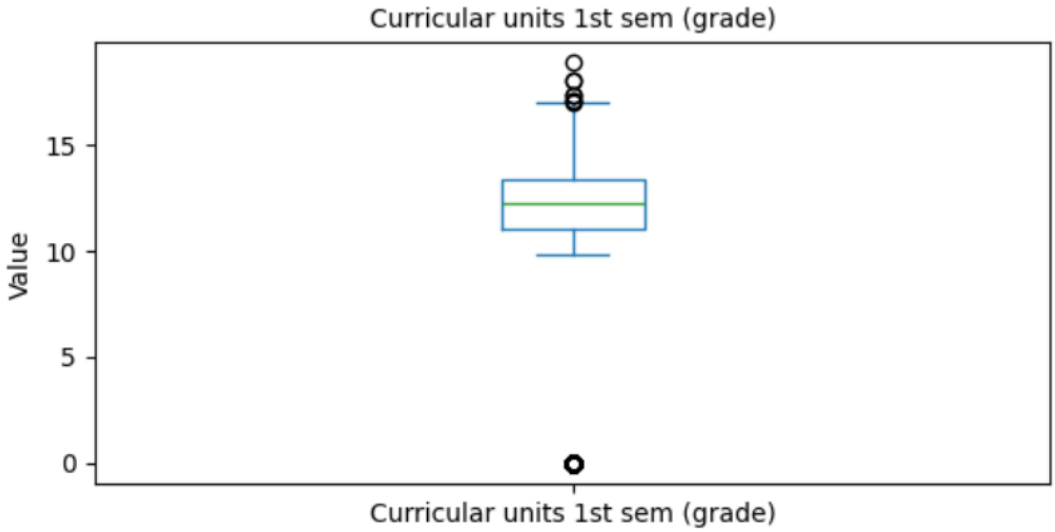


Figure 5:Boxplot avant clipping : Curricular units 1st sem (grade)

On observe une forte dispersion des notes, avec des valeurs nulles ainsi que des valeurs élevées correspondant aux meilleurs étudiants.

3.5 *Stratégie de traitement : méthode du clipping*

Afin de préserver l'ensemble des observations, une technique de clipping a été utilisée.

Cette méthode consiste à remplacer les valeurs extrêmes par les bornes définies par l'IQR.

Cette approche permet de réduire l'impact des valeurs aberrantes sans supprimer de données, ce qui est important pour maintenir la taille du dataset..

3.6 Validation des résultats après traitement

Après application du clipping, les distributions deviennent plus homogènes.

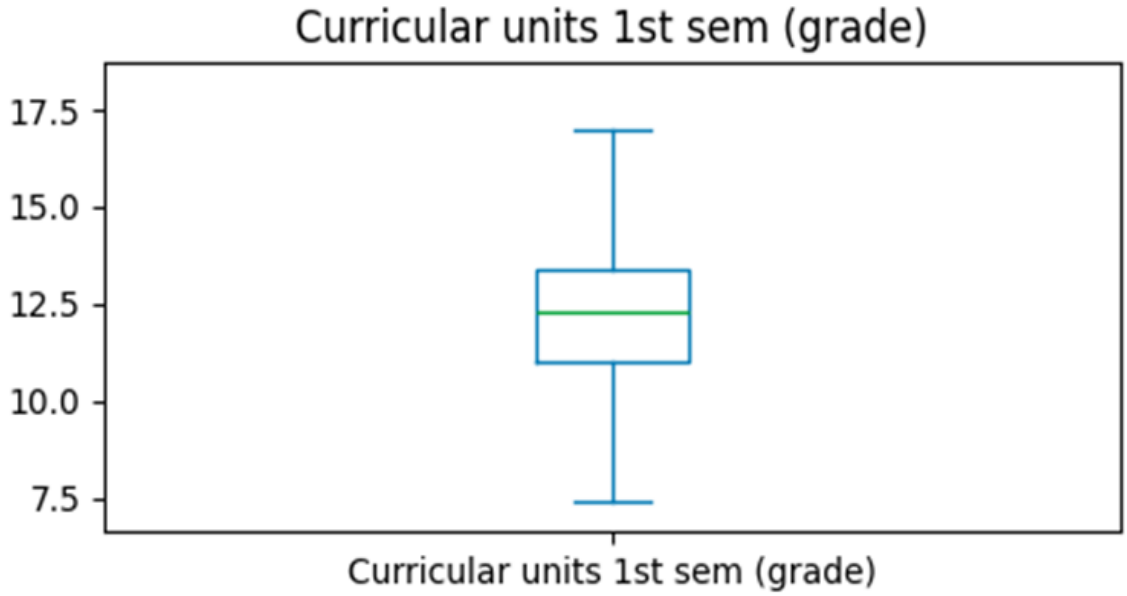


Figure 6:Boxplot après clipping : variables académiques

Cette figure montre une réduction significative des valeurs extrêmes tout en conservant la structure globale des données.

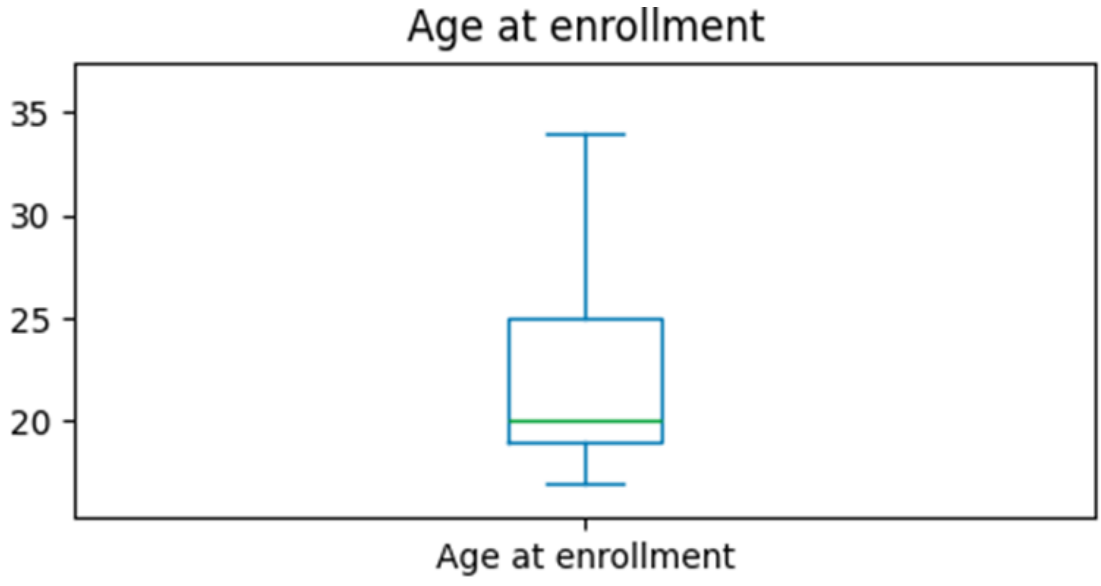


Figure 7:Boxplot après clipping : âge à l'inscription

Les valeurs extrêmes de l'âge ont été ramenées dans des bornes plus cohérentes, ce qui réduit leur impact sur les analyses statistiques.

3.7 Impact du traitement sur la qualité des données

Le traitement des valeurs aberrantes a permis d'améliorer la stabilité statistique du dataset sans supprimer d'observations.

- une réduction de l'asymétrie des distributions,
- une amélioration de la robustesse des futures modélisations,
- le maintien de l'intégralité des observations.

4. Analyse des distributions

4.1 Objectifs de l'analyse

À la suite du traitement des valeurs aberrantes, une analyse des distributions des variables a été réalisée afin d'étudier leur comportement statistique global. Cette étape permet d'évaluer la symétrie des distributions, d'identifier d'éventuelles anomalies statistiques et de vérifier la proximité des variables avec une distribution normale.

L'analyse des distributions constitue également une étape importante dans le cadre de la modélisation, dans la mesure où certains algorithmes de Machine Learning peuvent être sensibles à l'asymétrie et à la dispersion des données.

4.2 Analyse de l'asymétrie

Le coefficient d'asymétrie permet de mesurer la déviation d'une distribution par rapport à une distribution normale et symétrique. Il se calcule selon la formule suivante :

$$Skewness = \frac{\frac{1}{n}\sum_{i=0}^{n}(x_i-\bar{x})^3}{(\frac{1}{n}\sum_{i=0}^{n}(x_i-\bar{x})^2)^{3/2}} \qquad (4)$$

Une valeur proche de 0 indique une distribution symétrique. Une valeur positive révèle une asymétrie étalée vers la droite, tandis qu'une valeur négative indique un étalement vers la gauche.

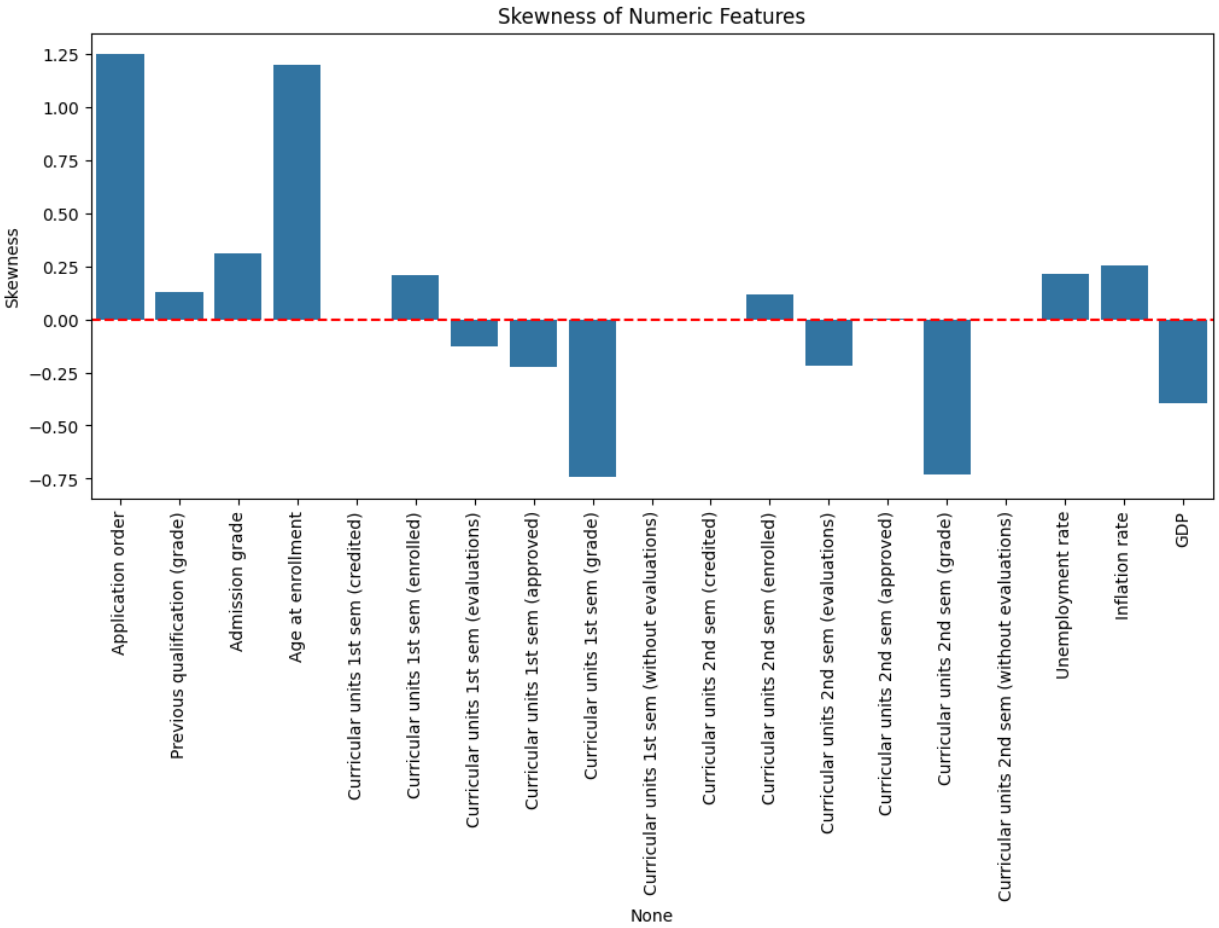


Figure 8: Analyse du skewness des variables numériques

L'analyse des coefficients de skewness met en évidence plusieurs comportements statistiques distincts.

Les variables *Age at enrollment* et *Application order* présentent une asymétrie positive marquée. Cela indique une concentration des observations autour de faibles valeurs, accompagnée d'une queue de distribution étendue vers les valeurs élevées.

À l'inverse, les variables académiques relatives aux notes des premier et deuxième semestres présentent une asymétrie négative. Cette configuration traduit une concentration des étudiants autour de performances moyennes ou relativement élevées, tandis qu'un nombre plus limité d'étudiants présente des résultats faibles.

Enfin, certaines variables macroéconomiques, telles que le taux de chômage et l'inflation, présentent des coefficients de skewness proches de zéro, ce qui reflète des distributions globalement symétriques et équilibrées.

4.3 Analyse de l'aplatissement

Le coefficient d'aplatissement évalue l'épaisseur des queues de distribution (et donc la propension à contenir des valeurs extrêmes). Sa formule s'exprime ainsi :

$$Kurtosis = \frac{\frac{1}{n}\sum_{i=0}^{n}(x_i-\bar{x})^4}{(\frac{1}{n}\sum_{i=0}^{n}(x_i-\bar{x})^2)^2} \qquad (5)$$

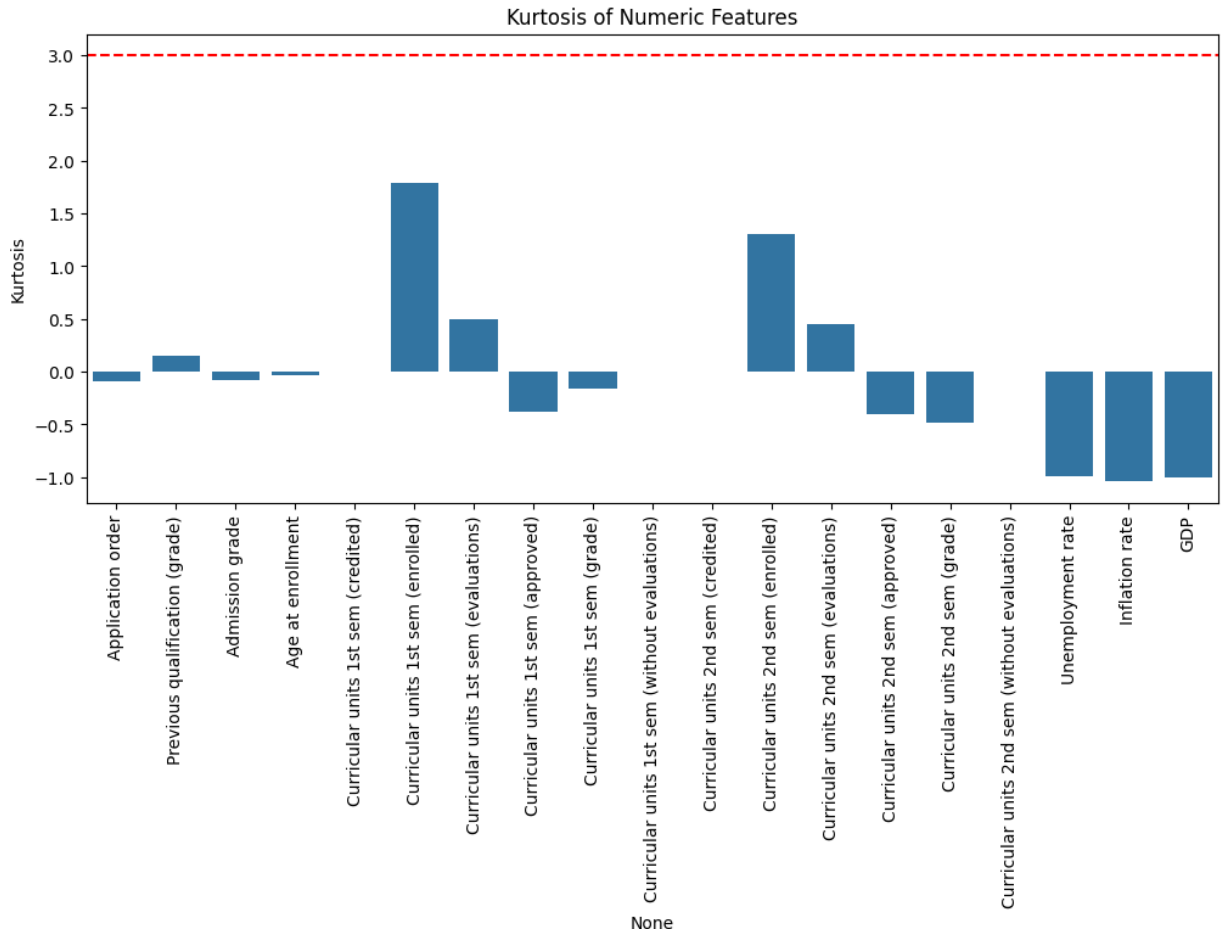


Figure 9: Analyse du kurtosis des variables numériques

Les résultats obtenus montrent que plusieurs variables présentent des valeurs de kurtosis relativement faibles, traduisant des distributions moins concentrées que la distribution normale de référence.

Par ailleurs, certaines variables liées aux unités curriculaires inscrites présentent des valeurs de kurtosis plus élevées. Cette observation indique une forte concentration des valeurs autour de certains niveaux spécifiques, ce qui peut s'expliquer par une standardisation du nombre d'unités suivies par les étudiants au cours des semestres.

4.4 *Visualisation des distributions par histogrammes*

Les histogrammes permettent de compléter l'analyse statistique en offrant une représentation visuelle des distributions des variables.

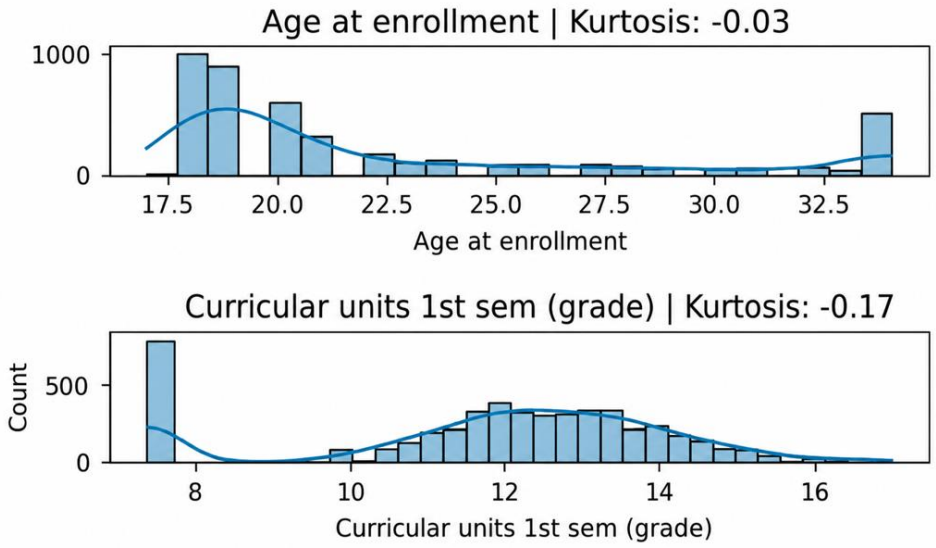


Figure 10:Histogrammes des principales variables numériques

L'analyse des histogrammes confirme les résultats obtenus précédemment en matière d'asymétrie et de dispersion des données.

Certaines variables académiques présentent des distributions multimodales, ce qui peut refléter l'existence de plusieurs groupes de performance au sein de la population étudiée.

Les variables liées aux notes montrent également une concentration importante autour des valeurs moyennes, associée à la présence de valeurs extrêmes correspondant soit à des situations d'échec, soit à des performances académiques élevées.

5. Analyse des variables catégorielles

5.1 Étude de la variable cible (Target)

La variable cible constitue l'élément central du problème de classification abordé dans ce projet. Son analyse permet d'étudier la répartition des différentes situations académiques des étudiants et d'évaluer la structure globale des classes à prédire.

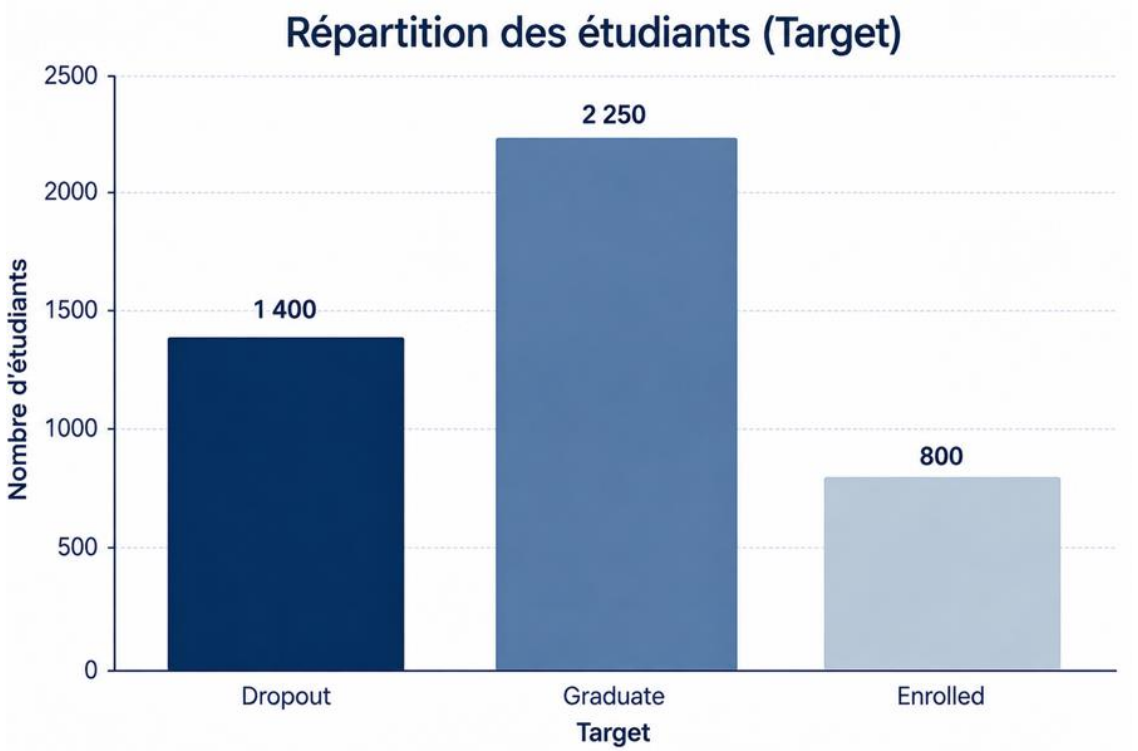


Figure 11:Répartition de la variable cible (Target)

L'analyse de la distribution met en évidence la présence de trois classes principales :

- **Graduate** : cette classe représente la catégorie majoritaire, avec plus de 2200 étudiants ayant obtenu leur diplôme.
- **Dropout** : elle regroupe environ 1400 étudiants ayant abandonné leur parcours universitaire.
- **Enrolled** : cette catégorie comprend près de 800 étudiants encore inscrits au moment de la collecte des données.

La distribution des classes met en évidence un déséquilibre modéré en faveur de la classe *Graduate*.

Dans le cadre de la phase de modélisation, la variable cible sera transformée en une classification binaire, par suppression de la classe *Enrolled*, afin de se concentrer exclusivement sur la distinction entre la réussite et l'abandon académique.

5.2 Analyse des variables catégorielles

Le jeu de données contient plusieurs variables catégorielles décrivant différents aspects démographiques, sociaux et administratifs liés au parcours académique des étudiants. L'analyse de ces variables permet de mieux comprendre la structure de la population étudiée ainsi que la diversité des profils présents.

Les variables liées au genre et à la nationalité permettent d'examiner d'éventuelles différences de comportement académique en fonction des caractéristiques individuelles des étudiants.

Les variables socio-économiques, notamment le statut de boursier (*Scholarship holder*), constituent également des facteurs potentiellement influents sur la réussite ou la persévérance académique.

Par ailleurs, les variables administratives relatives aux modalités d'admission et aux choix de formation mettent en évidence une diversité importante des parcours universitaires. Cette hétérogénéité peut influencer la performance des modèles de prédiction et devra être prise en compte lors de la phase de modélisation.

6. Analyse des relations entre variables

Cette section a pour objectif d'étudier les relations existantes entre les différentes variables du jeu de données afin d'identifier les facteurs les plus associés à la réussite ou à l'abandon des étudiants. Cette analyse permet de mieux comprendre l'influence des dimensions académiques, socio-économiques et démographiques sur le parcours universitaire.

6.1 Influence des performances académiques

Les performances académiques obtenues au cours des premiers semestres constituent des indicateurs déterminants dans l'analyse du parcours étudiant.

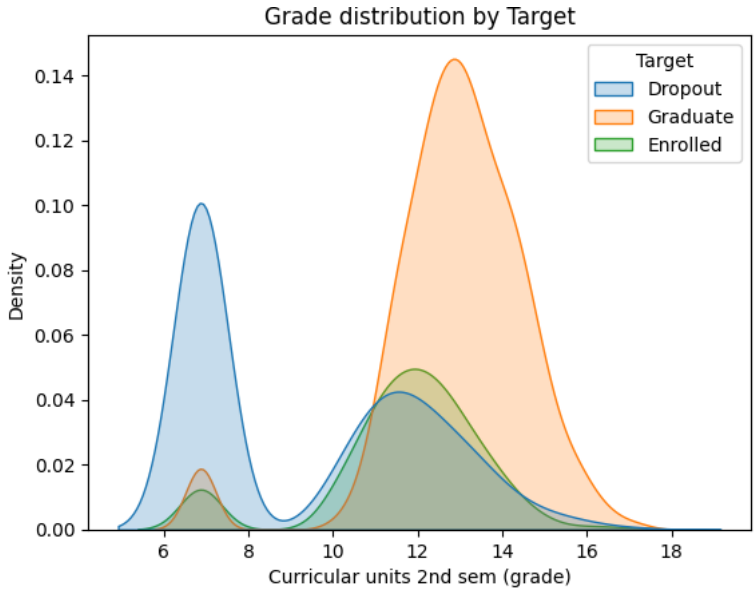


Figure 12:Distribution des notes selon la variable cible

L'analyse de cette figure met en évidence une différence significative entre les étudiants diplômés et ceux ayant abandonné leurs études. Les étudiants appartenant à la classe *Graduate* présentent des notes majoritairement concentrées autour de valeurs moyennes à élevées, tandis que les étudiants de la classe *Dropout* sont davantage associés à des performances académiques faibles.

Ces résultats suggèrent que les performances académiques initiales jouent un rôle déterminant dans la continuité et la réussite du parcours universitaire.

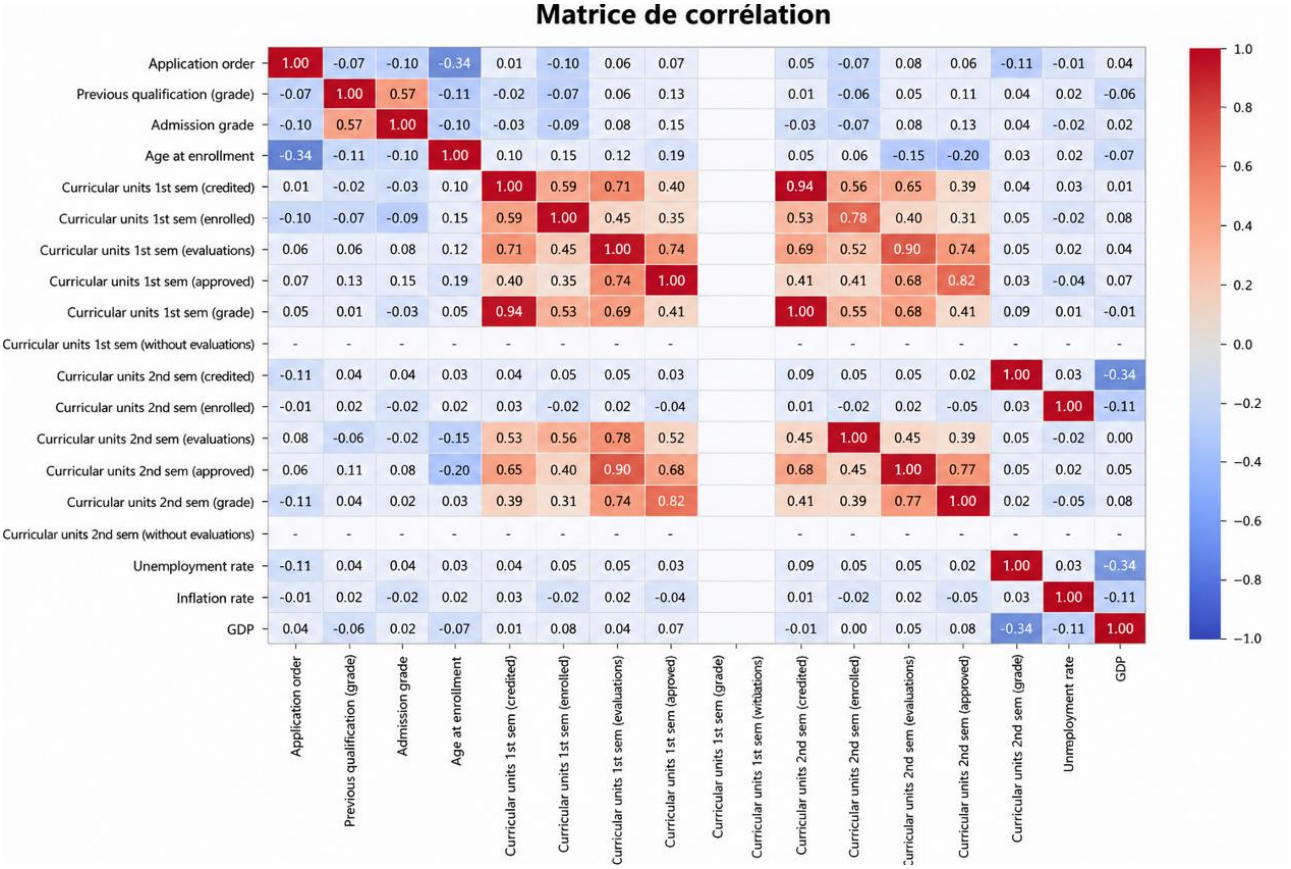


Figure 13:Matrice de corrélation des variables numériques

L'examen de la matrice de corrélation de Pearson (Figure 14) met en évidence une très forte corrélation linéaire ($r > 0.80$) entre les unités inscrites, évaluées et validées d'un semestre à l'autre. Cette interdépendance caractérise une forte multicolinéarité. Pour éviter des phénomènes de redondance qui nuisent à la stabilité des coefficients de la régression logistique, une sélection de variables s'imposera lors du Feature Engineering.

Note académique : Certaines variables apparaissent vierges sur la matrice de corrélation. Ce phénomène s'explique par une variance rigoureusement nulle (valeurs constantes sur l'ensemble de l'échantillon). N'apportant aucun pouvoir discriminant, ces colonnes seront systématiquement écartées du pipeline d'apprentissage.

6.2 Influence des facteurs socio-démographiques

En complément des performances académiques, certaines variables socio-démographiques peuvent également influencer le parcours des étudiants.



Figure 14: Répartition de la réussite selon le statut de boursier et le genre

L'analyse des résultats montre que les étudiants bénéficiant d'un statut de boursier présentent une proportion de réussite légèrement plus élevée que les étudiants non boursiers. Ce résultat suggère que le soutien financier peut constituer un facteur favorable à la persévérance académique.

Par ailleurs, des différences modérées sont observées selon le genre des étudiants, indiquant que certains comportements académiques peuvent varier en fonction des caractéristiques démographiques.

6.3 Influence de l'âge à l'inscription

L'âge au moment de l'inscription constitue une variable pertinente dans l'analyse du risque d'abandon académique.

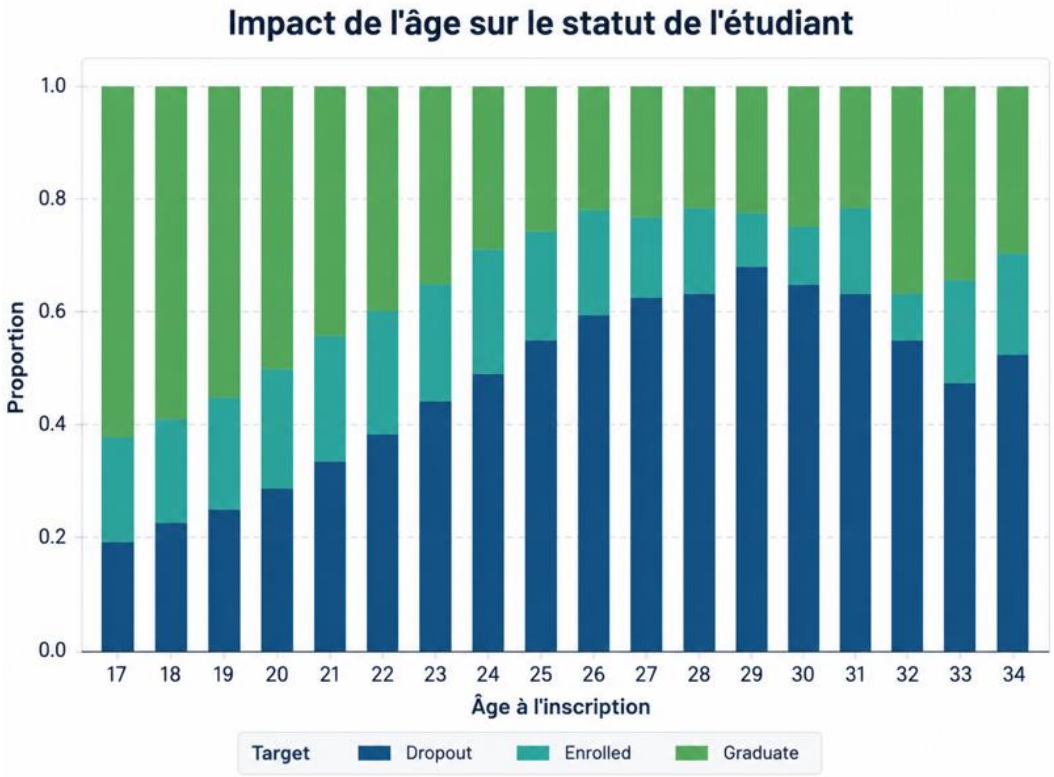


Figure 15: Relation entre l'âge à l'inscription et la variable cible

Les résultats montrent que les étudiants les plus jeunes présentent globalement des taux de réussite plus élevés. À l'inverse, la proportion d'étudiants en situation d'abandon tend à augmenter avec l'âge.

Cette tendance peut s'expliquer par la présence de contraintes personnelles, professionnelles ou familiales plus importantes chez les étudiants âgés, susceptibles d'influencer la continuité de leur parcours académique.

7. Analyse multivariée

Dans cette section, une analyse multivariée a été réalisée à l'aide d'une matrice de diagrammes de dispersion (pairplot). Cette représentation permet d'étudier simultanément les relations entre plusieurs variables numériques ainsi que leur comportement selon les différentes classes de la variable cible (Dropout, Graduate et Enrolled).

Les variables retenues correspondent principalement à des indicateurs susceptibles d'influencer le statut académique final des étudiants, notamment les notes d'admission, l'âge à l'inscription ainsi que certaines variables académiques représentatives du parcours universitaire.

7.1 Analyse des distributions sur la diagonale

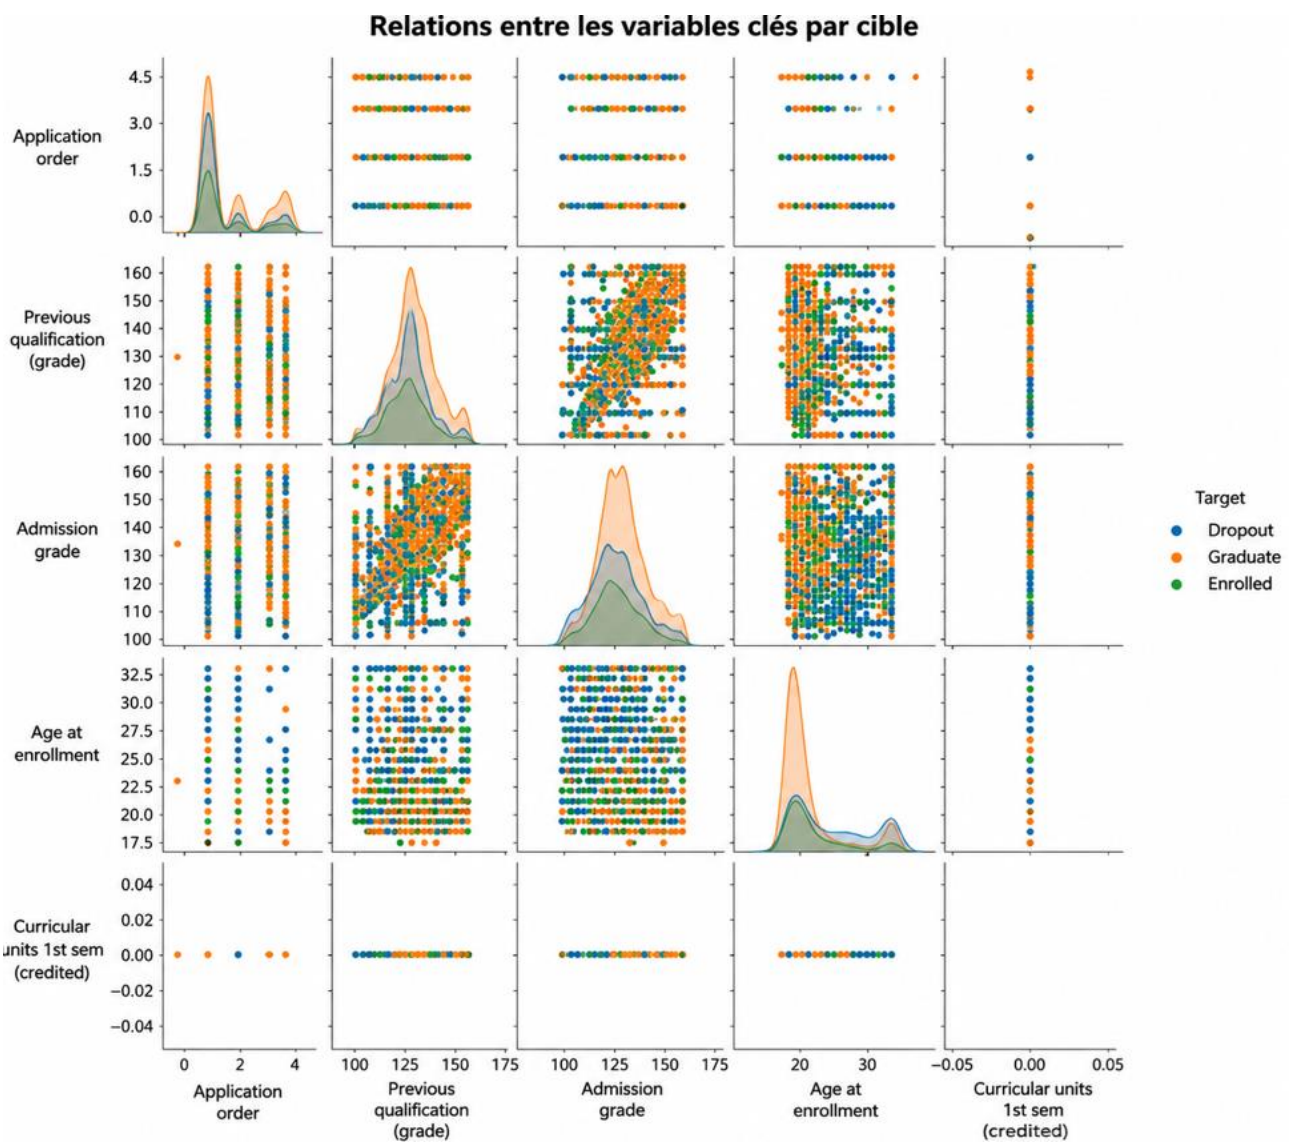


Figure 16:Pairplot des principales variables numériques

Les éléments situés sur la diagonale du pairplot correspondent aux distributions individuelles des variables selon les différentes classes de la variable cible.

Les variables académiques, telles que Admission grade et Previous qualification (grade), présentent des distributions globalement similaires entre les différentes catégories, bien que les étudiants appartenant à la classe Graduate affichent légèrement de meilleures performances.

La variable Age at enrollment présente une distribution fortement concentrée sur les étudiants jeunes, principalement âgés de 18 à 21 ans. Les étudiants plus âgés sont davantage représentés dans les catégories Dropout et Enrolled.

Par ailleurs, un chevauchement important des distributions est observé entre les différentes classes, ce qui indique qu'aucune variable prise isolément ne permet une séparation nette des profils étudiants.

7.2 Analyse des relations entre variables

Les diagrammes de dispersion situés hors diagonale permettent d'analyser les relations entre les différentes variables numériques.

Une corrélation positive modérée est observée entre les variables Admission grade et Previous qualification (grade), ce qui indique que les étudiants ayant obtenu de bons résultats antérieurs tendent également à présenter de meilleures performances lors de l'admission.

Cependant, les différentes classes de la variable cible restent fortement superposées dans la majorité des projections. Ce chevauchement met en évidence le fait que les phénomènes de réussite ou d'abandon académique ne peuvent pas être expliqués par un facteur unique, mais résultent probablement de l'interaction de plusieurs variables académiques, socio-économiques et démographiques.

Enfin, l'absence de séparation visuelle claire entre les classes suggère que la tâche de classification est complexe et nécessite l'utilisation de modèles capables de capturer des relations non linéaires entre les variables.

8. Conclusion

L'Analyse Exploratoire des Données a permis de dresser une cartographie statistique rigoureuse de notre dataset. Les performances académiques immédiates s'affirment comme les variables les plus prédictives, appuyées par des facteurs sociodemographiques clés comme l'âge et le soutien financier. Sur le plan technique, la mise en évidence d'une forte multicolinéarité, d'une asymétrie des distributions et de l'enchevêtrement des classes dicte directement notre feuille de route pour le chapitre suivant, dédié au prétraitement et au *Feature Engineering*.

Chapitre 5 : Prétraitement des données

1. Introduction

Après l'analyse exploratoire présentée dans le chapitre précédent, les données ont été préparées afin de les rendre compatibles avec les algorithmes de Machine Learning et de garantir leur qualité pour la phase de modélisation.

Ce chapitre présente les différentes opérations de prétraitement appliquées au jeu de données, notamment le nettoyage, la transformation des variables catégorielles, la sélection des caractéristiques pertinentes, la normalisation des variables numériques ainsi que la division des données en ensembles d'apprentissage et de test.

Ces étapes ont permis d'obtenir un dataset cohérent, structuré et adapté à l'entraînement et à l'évaluation des modèles de classification développés dans la suite du projet.

2. Chargement et exploration initiale du dataset

Le jeu de données a été chargé afin d'effectuer une première analyse exploratoire permettant de vérifier sa structure et sa cohérence.

Chaque observation représente un étudiant, tandis que chaque variable correspond à une caractéristique descriptive (académique, démographique ou socio-économique).

Cette étape a permis de confirmer l'absence de valeurs manquantes, ainsi que d'identifier les variables catégorielles nécessitant une transformation avant leur utilisation dans les modèles de Machine Learning.

Pipeline

Le processus global de prétraitement suit une suite d'étapes progressives allant de la donnée brute vers un dataset final exploitable par les modèles de machine learning :

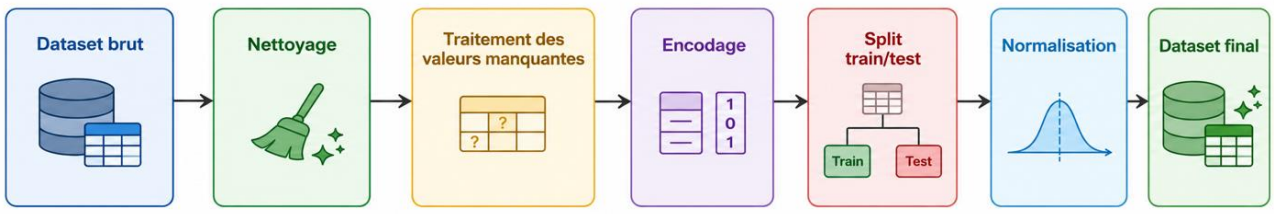


Figure 17: Pipeline de prétraitement des données

3. Traitement de la variable cible

La variable cible initiale comporte trois classes : Graduate, Dropout et Enrolled.

La classe Enrolled a été supprimée, car elle correspond à une situation intermédiaire ne permettant pas une classification supervisée claire. Le problème a ainsi été reformulé en une classification binaire : réussite (Graduate) ou échec (Dropout).

4. Encodage des variables catégorielles

Les algorithmes de Machine Learning opèrent exclusivement sur des représentations numériques des données. Les variables catégorielles présentes dans le jeu de données doivent donc être transformées en valeurs numériques avant toute phase de modélisation.

Identification des variables catégorielles

Le jeu de données comporte plusieurs variables qualitatives nominales, c'est-à-dire des variables dont les modalités ne présentent aucun ordre naturel ou hiérarchie intrinsèque. Il s'agit notamment des variables suivantes :

- Course : la filière choisie par l'étudiant
- Nationality : la nationalité de l'étudiant
- Mother's qualification / Father's qualification : le niveau d'éducation des parents
- Mother's occupation / Father's occupation : la profession des parents
- Marital status : la situation matrimoniale
- Previous qualification : la qualification antérieure

Choix de la méthode : One-Hot Encoding

Pour ces variables nominales, la technique du One-Hot Encoding a été adoptée. Cette méthode consiste à transformer chaque variable catégorielle en plusieurs variables binaires (0 ou 1), chacune représentant la présence ou l'absence d'une modalité donnée.

Ce choix est justifié par la nature des variables concernées. L'utilisation d'un encodage ordinal (LabelEncoder) sur des variables nominales introduirait un ordre artificiel entre les catégories, ce qui pourrait induire un biais structurel dans le modèle. Par exemple, coder des filières par des valeurs numériques pourrait suggérer une hiérarchie inexistante entre elles, ce qui peut dégrader les performances des modèles sensibles aux distances ou aux relations linéaires, tels que la régression logistique ou le KNN (Géron, 2022 ; Müller & Guido, 2016).

Le One-Hot Encoding permet au contraire de représenter chaque modalité de manière indépendante et équidistante dans l'espace des caractéristiques, sans introduire de relation d'ordre implicite.

Gestion de la multicolinéarité

Le One-Hot Encoding a été appliqué à l'aide de la classe OneHotEncoder de Scikit-learn avec l'option drop='first'. Cette option permet de supprimer une modalité par variable encodée afin d'éviter

la multicolinéarité parfaite entre les variables binaires générées (dummy variable trap), susceptible de perturber certains modèles linéaires.

Variable cible

La variable cible Target, reformulée en classification binaire (Graduate = 1, Dropout = 0) après suppression de la classe Enrolled, a été encodée à l'aide d'un encodage binaire simple, ce qui est approprié pour ce type de problème.

5. Sélection des caractéristiques (Feature Selection)

Le jeu de données initial comporte 37 variables explicatives. Afin de réduire la dimensionnalité du problème, de limiter le risque de surapprentissage et d'améliorer la stabilité des modèles de classification, une étape de sélection des caractéristiques a été réalisée par filtrage basé sur la corrélation avec la variable cible.

Méthode employée

Le coefficient de corrélation de Pearson a été calculé entre chaque variable explicative et la variable cible binaire encodée numériquement. Cette mesure permet de quantifier l'intensité de la relation linéaire entre chaque prédicteur et le statut académique de l'étudiant.

Détermination du seuil

La sélection du seuil de $|r| \geq 0{,}18$ repose sur une démarche empirique et analytique combinée, conduite en trois étapes :

Étape 1 — Analyse de la distribution des coefficients de corrélation.

L'examen de la distribution des 37 coefficients de corrélation absolus révèle une concentration bimodale : un groupe de variables présente des corrélations inférieures à 0,10 (variables essentiellement macroéconomiques et démographiques de faible pertinence discriminante), tandis qu'un second groupe dépasse 0,18. Le seuil de 0,18 correspond à la vallée naturelle séparant ces deux groupes, ce qui en fait un point de coupure analytiquement fondé plutôt qu'arbitraire.

Étape 2 — Validation par évaluation des performances.

Afin de valider ce seuil, plusieurs configurations ont été testées en faisant varier le seuil de corrélation de 0,10 à 0,30 par pas de 0,02, et en évaluant à chaque fois l'accuracy de la Régression Logistique sur l'ensemble de test. Les résultats montrent que les performances se stabilisent à partir d'un seuil d'environ 0,16–0,18 et commencent à se dégrader au-delà de 0,22, en raison de la perte de variables modérément corrélées mais informatives. Le seuil de 0,18 correspond ainsi à la zone de performance optimale.

Étape 3 — Référence à la littérature.

Dans les travaux de classification appliquée à des données académiques, un seuil de corrélation univariée compris entre 0,15 et 0,20 est fréquemment utilisé comme critère de présélection avant l'application de méthodes de sélection plus avancées (Cortez & Silva, 2008 ; Realinho et al., 2022). Ce seuil constitue un compromis reconnu entre la réduction de la dimensionnalité et la préservation de l'information prédictive.

Résultat

L'application de ce seuil a conduit à la rétention de **9 variables explicatives** sur les 37 initiales, listées dans le tableau suivant :

```
Target                                          1.000000
Curricular units 2nd sem (approved)             0.651990
Curricular units 2nd sem (grade)                0.590008
Curricular units 1st sem (approved)             0.581218
Curricular units 1st sem (grade)                0.510614
Tuition fees up to date                         0.425356
Scholarship holder                              0.277638
Curricular units 2nd sem (enrolled)             0.218186
Curricular units 1st sem (enrolled)             0.197799
Previous qualification                          0.181766
Admission grade                                 0.123929
Course                                          0.118396
Previous qualification (grade)                  0.106693
Curricular units 2nd sem (evaluations)          0.102287
Displaced                                       0.101473
Marital status                                  0.086331
Application order                               0.084910
GDP                                             0.055380
Curricular units 1st sem (evaluations)          0.053076
Educational special needs                       0.011157
Father's occupation                             0.010990
International                                   0.009322
Nacionality                                     0.005767
Mother's occupation                            -0.008021
Unemployment rate                              -0.009534
Mother's qualification                         -0.039477
Inflation rate                                 -0.045468
Daytime/evening attendance                     -0.072389
Father's qualification                         -0.072797
Gender                                         -0.228659
Application mode                               -0.245212
Debtor                                         -0.248215
Age at enrollment                              -0.294132
Curricular units 1st sem (credited)                  NaN
Curricular units 1st sem (without evaluations)       NaN
Curricular units 2nd sem (credited)                  NaN
Curricular units 2nd sem (without evaluations)       NaN
Name: Target, dtype: float64
```

Figure 18: Variables supprimées suite à l'analyse de corrélation (|corrélation| < 0,18)

Cette sélection confirme la prédominance des variables académiques du premier et du second semestre, en accord avec les observations de l'état de l'art sur l'importance des résultats précoces dans la prédiction du statut final des étudiants.

6. Séparation des variables explicatives et de la variable cible

Après la sélection des caractéristiques, les données ont été divisées en deux parties :

- les variables explicatives (features)
- la variable cible (target)

Les variables explicatives représentent les informations utilisées par les modèles pour effectuer les prédictions, tandis que la variable cible correspond au statut final de l'étudiant (réussite ou abandon).

Cette étape est indispensable dans tout problème de machine learning supervisé.

7. Division du dataset

Le jeu de données a été divisé en deux ensembles distincts :

- un ensemble d'apprentissage (80 % des données),
- un ensemble de test (20 % des données).

Cette séparation permet d'évaluer la capacité de généralisation des modèles sur des données non vues lors de l'entraînement.

8. Équilibrage des classes (SMOTE)

Après la division du jeu de données en ensembles d'apprentissage et de test, un déséquilibre a été observé au niveau de la variable cible. Cette situation pouvait entraîner un biais des modèles en faveur de la classe majoritaire et réduire leur capacité à bien apprendre la classe minoritaire.

Afin de remédier à ce problème, la technique SMOTE (Synthetic Minority Over-sampling Technique) a été appliquée uniquement sur l'ensemble d'apprentissage, afin d'éviter toute fuite d'information vers l'ensemble de test (data leakage).

SMOTE permet de générer des observations synthétiques pour la classe minoritaire à partir de ses k plus proches voisins, plutôt que de simplement dupliquer des exemples existants. Cette approche améliore la représentation de la classe minoritaire et permet un meilleur équilibre entre les classes.

À l'issue de cette étape, les classes sont devenues parfaitement équilibrées :

Dropout : 1534

Graduate : 1534

Cet équilibrage permet d'améliorer la capacité des modèles de classification à apprendre de manière plus équitable à partir des différentes classes, en réduisant le biais en faveur de la classe majoritaire. Il contribue ainsi à améliorer la robustesse globale des modèles et leur capacité de généralisation.

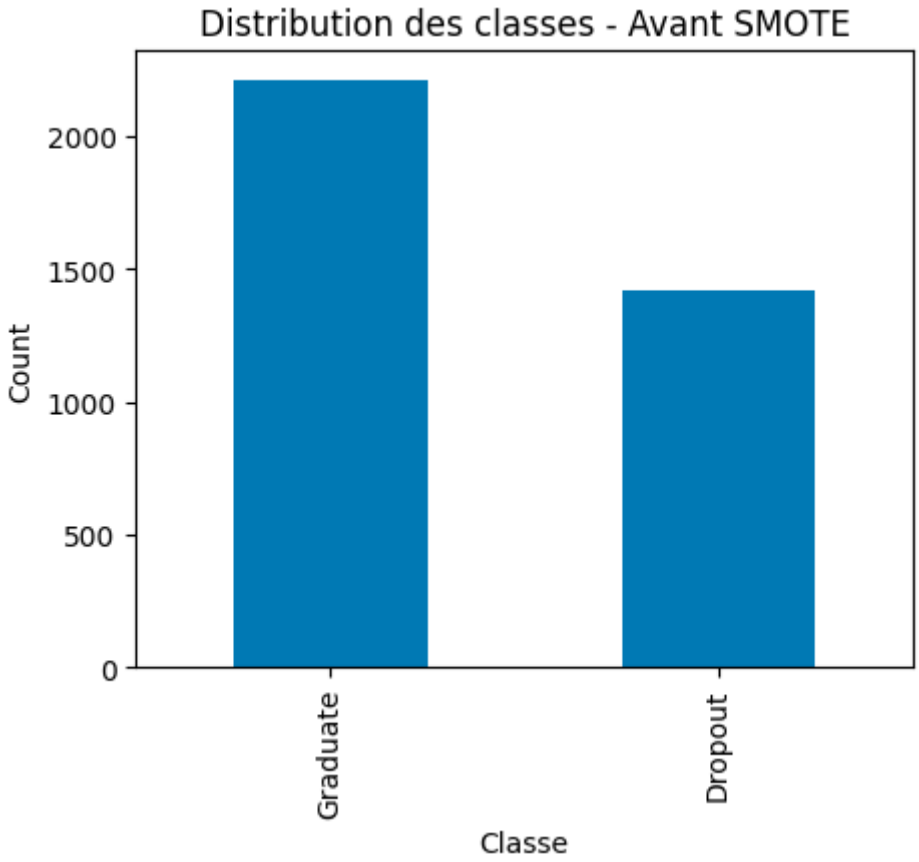


Figure 19: Distribution des classes de la variable cible avant l'application de SMOTE

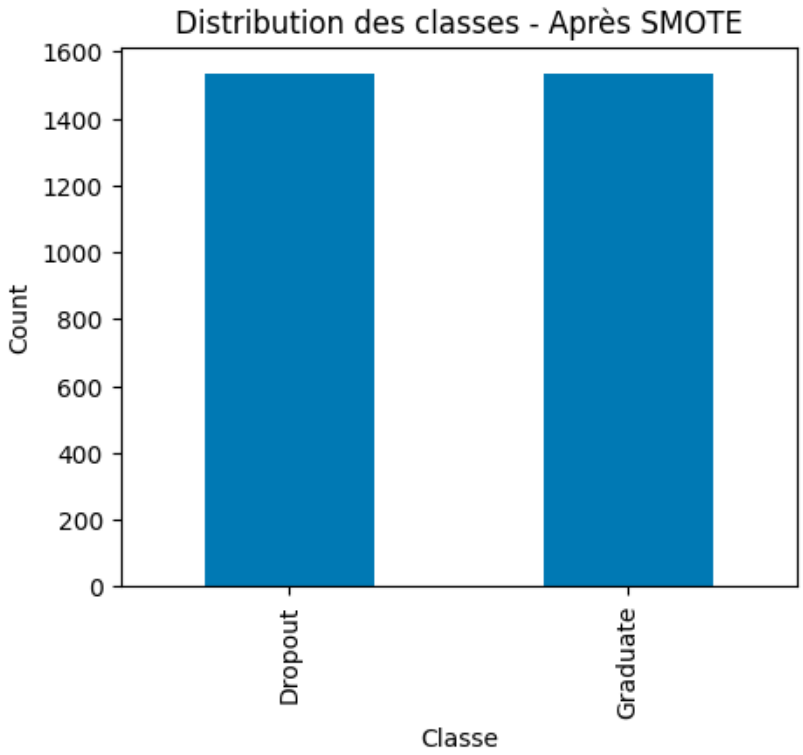


Figure 20: Distribution des classes de la variable cible après application de SMOTE

9. Normalisation des variables numériques

Les variables numériques présentent des échelles différentes, ce qui peut affecter les performances de certains algorithmes sensibles à la distance, tels que la régression logistique ou les k plus proches voisins.

Une standardisation a donc été appliquée à l'aide de la méthode StandardScaler, permettant de ramener les variables à une moyenne nulle et une variance unitaire.

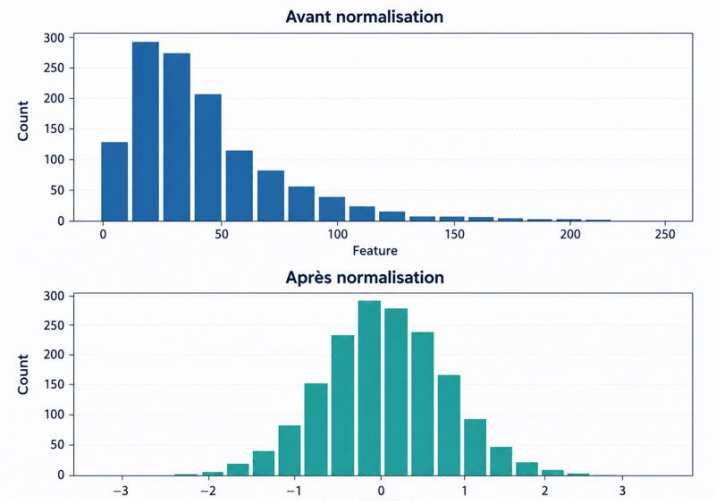


Figure 21: Effet de la normalisation sur la distribution des variables

Cette transformation assure une homogénéité des échelles et améliore la stabilité des modèles.

10. Conclusion

À l'issue des différentes étapes de prétraitement, le jeu de données obtenu est désormais propre, cohérent et exploitable pour la phase de modélisation.

Les transformations appliquées ont permis de structurer les données de manière optimale, notamment à travers le traitement des éventuelles anomalies, l'encodage des variables catégorielles, la normalisation des variables numériques ainsi que la séparation des données en variables explicatives et variable cible.

Dans l'ensemble, ce chapitre a permis de transformer un jeu de données brut en une base de données homogène et fiable, en réduisant les incohérences et en améliorant significativement sa qualité globale.

À l'issue du prétraitement, le dataset final est prêt pour la phase de modélisation. Les opérations appliquées ont permis d'obtenir un ensemble cohérent, normalisé et adapté aux algorithmes retenus.

Le chapitre suivant sera consacré à la phase de modélisation ainsi qu'à l'évaluation comparative des différents algorithmes de classification utilisés pour la prédiction de la réussite académique des étudiants.

Chapitre 6 : Modélisation

1. Introduction

Après la phase de préparation et de prétraitement des données, l'étape suivante consiste à construire des modèles de Machine Learning capables de prédire la réussite académique des étudiants. La modélisation représente une étape essentielle du projet puisqu'elle permet d'exploiter les données disponibles afin d'identifier les relations existantes entre les différentes caractéristiques des étudiants et leur statut académique.

L'objectif principal est de développer des modèles capables d'apprendre à partir des données historiques et de fournir des prédictions fiables concernant la réussite ou l'échec d'un étudiant.

Dans ce projet, trois algorithmes de classification supervisée ont été sélectionnés :

- La Régression Logistique ;
- Le modèle K-Nearest Neighbors (KNN) ;
- L'Arbre de Décision.

Ces modèles ont été choisis en raison de leur popularité dans les tâches de classification, de leur simplicité d'implémentation et de leur capacité à traiter efficacement les données académiques.

2. Modèle de Régression Logistique

La Régression Logistique est un algorithme de classification supervisée largement utilisé pour prédire une variable cible catégorielle. Malgré son nom, il s'agit d'un modèle de classification et non de régression.

Dans le cadre de ce projet, ce modèle est utilisé pour déterminer si un étudiant est susceptible de réussir ou non à partir des caractéristiques académiques disponibles. La Régression Logistique calcule la probabilité d'appartenance à chaque classe en utilisant une fonction logistique qui transforme une combinaison linéaire des variables d'entrée en une valeur comprise entre 0 et 1.

des variables d'entrée en une valeur comprise entre 0 et 1.

Ce modèle présente plusieurs avantages :

- Facilité d'interprétation ;
- Rapidité d'exécution ;
- Bonne capacité de généralisation ;
- Adaptation aux problèmes de classification binaire.

2.1 Optimisation du modèle

des variables d'entrée en une valeur comprise entre 0 et 1.

Ce modèle présente plusieurs avantages :

- Facilité d'interprétation ;
- Rapidité d'exécution ;
- Bonne capacité de généralisation ;
- Adaptation aux problèmes de classification binaire.

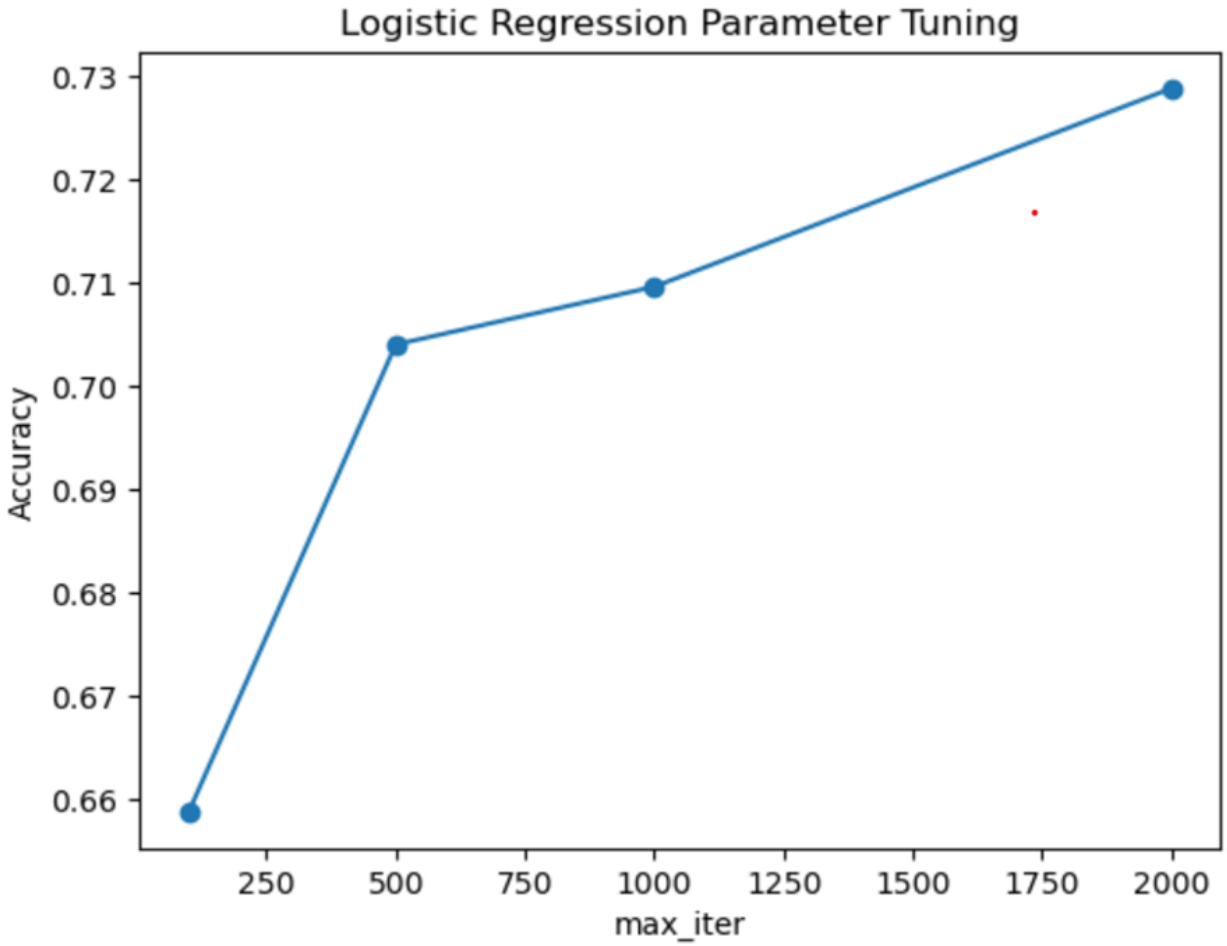


Figure 22: Optimisation du modèle Régression Logistique selon le paramètre max_iter

Interprétation

Le graphique montre que l'accuracy augmente progressivement lorsque le nombre d'itérations augmente.
La meilleure performance a été obtenue avec max_iter = 2000.

2.2 Configuration finale du modèle

À l'issue de cette phase d'optimisation, la valeur la plus appropriée du paramètre max_iter a été retenue pour entraîner le modèle final utilisé dans le système de prédiction.

3. Modèle K-Nearest Neighbors (KNN)

Le modèle K-Nearest Neighbors est un algorithme de classification basé sur la similarité entre les observations. Lorsqu'une nouvelle donnée est présentée au modèle, celui-ci recherche les K voisins les plus proches dans l'espace des caractéristiques puis attribue la classe majoritaire observée parmi ces voisins.

L'idée principale est que des étudiants présentant des caractéristiques similaires ont tendance à obtenir des résultats académiques comparables.

Les principaux avantages du modèle KNN sont :

- Simplicité de mise en œuvre ;
- Absence de phase d'apprentissage complexe ;
- Bonne efficacité sur certains jeux de données structurés.

3.1 Optimisation du modèle KNN

Le paramètre principal du modèle KNN est le nombre de voisins **K** utilisé lors de la classification. Plusieurs valeurs de **K** ont été testées afin de déterminer celle qui permet de mieux représenter les relations entre les étudiants et d'améliorer la qualité de la prédiction.

Pour chaque valeur de **K**, le taux d'erreur a été calculé sur les données de test. La Figure 24 présente l'évolution du taux d'erreur en fonction du nombre de voisins. On observe que le taux d'erreur diminue progressivement lorsque **K** augmente, puis se stabilise à partir d'une certaine valeur. Le taux d'erreur minimal est obtenu pour **K = 18**, avec une valeur proche de **10 %**.

Le choix de **K = 18** permet ainsi d'obtenir un bon compromis entre la capacité de généralisation du modèle et la réduction des erreurs de classification. Cette valeur a donc été retenue pour la construction du modèle KNN final.

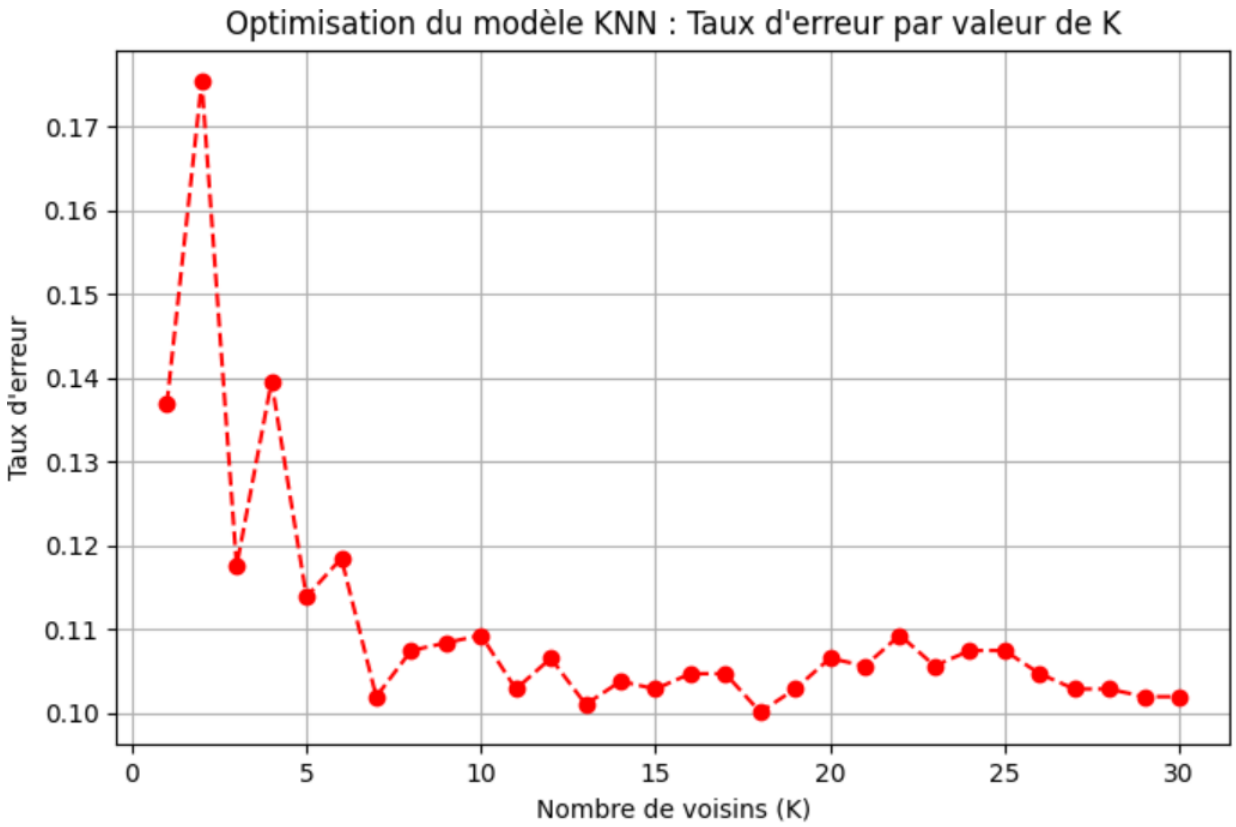


Figure 23: Optimisation du modèle KNN selon le nombre de voisins K.

3.2 Configuration finale du modèle

Après analyse des différentes valeurs testées, le nombre optimal de voisins a été retenu pour construire la version finale du modèle KNN utilisée dans le projet.

4. Modèle Arbre de Décision

L'Arbre de Décision est un modèle de classification qui représente le processus de décision sous forme d'une structure arborescente composée de nœuds et de branches.

Chaque nœud correspond à une condition appliquée à une variable du dataset tandis que chaque branche représente le résultat de cette condition. Le processus se poursuit jusqu'à atteindre une feuille contenant la classe prédite.

Ce modèle présente plusieurs avantages :

Interprétation intuitive ;

Visualisation facile des règles de décision ;

Capacité à gérer différents types de variables ;

Identification automatique des variables importantes.

4.1 Optimisation avec GridSearchCV

Afin d'améliorer les performances du modèle, une recherche automatique des meilleurs hyperparamètres a été réalisée à l'aide de la méthode GridSearchCV.

Cette technique consiste à tester plusieurs combinaisons de paramètres puis à sélectionner celle qui fournit les meilleurs résultats lors de la phase d'apprentissage.

Les paramètres optimisés concernent notamment :

- Le critère de séparation (*criterion*) ;
- La profondeur maximale de l'arbre (*max_depth*) ;
- Le nombre minimal d'échantillons pour effectuer une division (*min_samples_split*) ;
- Le nombre minimal d'échantillons dans une feuille (*min_samples_leaf*).

4.2 Configuration finale du modèle

L'optimisation réalisée avec GridSearchCV a permis de déterminer les paramètres les plus adaptés au problème étudié. Ces paramètres ont ensuite été utilisés pour construire le modèle final d'Arbre de Décision intégré dans le système.

5. Conclusion

Cette phase de modélisation a permis de construire plusieurs modèles de Machine Learning destinés à la prédiction de la réussite académique des étudiants.

Trois approches différentes ont été étudiées : la Régression Logistique, le modèle K-Nearest Neighbors et l'Arbre de Décision. Pour chacun de ces modèles, une étape d'optimisation des paramètres a été réalisée afin d'obtenir une configuration adaptée aux caractéristiques du jeu de données.

Les modèles ainsi construits constituent le cœur du système intelligent développé dans ce projet et serviront à générer des prédictions sur de nouveaux étudiants à partir des informations académiques disponibles.

Chapitre 7 : Évaluation des modèles

1. Introduction

L'évaluation des modèles constitue une étape essentielle dans tout projet de Machine Learning. Son objectif principal est de mesurer la capacité des modèles à produire des prédictions fiables et à généraliser correctement sur des données non utilisées durant la phase d'apprentissage.

Dans le cadre de ce projet, cette étape vise à évaluer l'efficacité des différents algorithmes de classification dans la prédiction du statut académique des étudiants selon une approche de classification binaire distinguant les étudiants susceptibles de réussir leurs études (Graduate) de ceux présentant un risque d'abandon (Dropout).

La comparaison de plusieurs modèles de classification est particulièrement importante, car chaque algorithme repose sur des mécanismes d'apprentissage différents et présente des comportements variables selon la nature des données étudiées. Certains modèles sont plus adaptés aux relations linéaires, tandis que d'autres permettent de mieux capturer des interactions plus complexes entre les variables.

Afin de garantir une évaluation cohérente et équitable, l'ensemble des modèles a été entraîné et testé selon le même protocole expérimental. Les algorithmes retenus dans cette étude sont la Régression Logistique, le K-Nearest Neighbors (KNN), l'Arbre de Décision ainsi que sa version optimisée (Tuned Decision Tree).

Les performances des modèles seront analysées à l'aide de plusieurs métriques d'évaluation, notamment l'Accuracy, la Precision et le Recall, afin de comparer leur capacité de généralisation et d'identifier le modèle le plus adapté au problème étudié.

2. Métriques d'évaluation utilisées

Afin d'évaluer les performances des modèles de classification multi-classes utilisés dans ce projet, plusieurs métriques d'évaluation ont été employées. Ces indicateurs permettent de mesurer la capacité des modèles à produire des prédictions correctes sur les différentes catégories de la variable cible.

2.1 Accuracy (Exactitude)

L'Accuracy représente la proportion de prédictions correctement réalisées par rapport au nombre total d'observations.

$$Accuracy = \frac{VP+VN}{VP+VN+FP+FN} \qquad (6)$$

Importance dans la classification

Cette métrique fournit une mesure globale des performances du modèle. Toutefois, elle peut devenir moins représentative lorsque les classes du dataset présentent un déséquilibre important.

2.2 Precision (Précision)

La Precision mesure la proportion des prédictions positives réellement correctes parmi l'ensemble des prédictions positives effectuées par le modèle.

$$\text{Precision} = \frac{\text{VP}}{\text{VP+FP}} \qquad (7)$$

Importance dans la classification

Dans le cadre de ce projet, une bonne précision pour la classe Dropout permet de limiter les cas où des étudiants sont incorrectement identifiés comme étant en situation d'échec.

2.3 Recall (Rappel)

Le Recall mesure la capacité du modèle à identifier correctement les observations appartenant réellement à une classe donnée.

$$\text{Recall} = \frac{\text{VP}}{\text{VP+FN}} \qquad (8)$$

Importance dans la classification

Un Recall élevé pour la classe *Dropout* indique que le modèle détecte efficacement les étudiants présentant un risque d'abandon, tout en réduisant le nombre de faux négatifs.

2.4 Matrice de confusion

La matrice de confusion est un outil permettant de comparer les classes réelles aux classes prédites par le modèle.

- **True Positive (VP)** : l'observation appartient à la classe considérée et est correctement prédite.
- **False Positive (FP)** : l'observation n'appartient pas à la classe considérée mais est incorrectement prédite comme appartenant à cette classe.
- **False Negative (FN)** : l'observation appartient à la classe considérée mais le modèle prédit une autre classe.
- **True Negative (VN)** : l'observation n'appartient pas à la classe considérée et le modèle la classe correctement en dehors de cette catégorie.

3. Entraînement et évaluation des modèles

Dans cette section, plusieurs modèles de classification ont été entraînés puis évalués afin d'identifier l'algorithme le plus adapté à la prédiction du statut académique des étudiants. Les performances de chaque modèle ont été mesurées à l'aide des métriques présentées précédemment.

3.1 Régression Logistique

Présentation du modèle

La Régression Logistique est un modèle de classification supervisée permettant d'estimer la probabilité d'appartenance d'une observation à une classe donnée. Dans le cadre de ce projet, elle est utilisée pour prédire si un étudiant appartient à la classe « Réussite » ou « Échec ».

Résultats obtenus

Tableau 3: Résultats de performance de la Régression Logistique

Métrique	Valeur
Accuracy	90.72%
Précision	90.69%
Recall	90.72%

La figure suivante présente la matrice de confusion obtenue par la Régression Logistique sur les données de test.

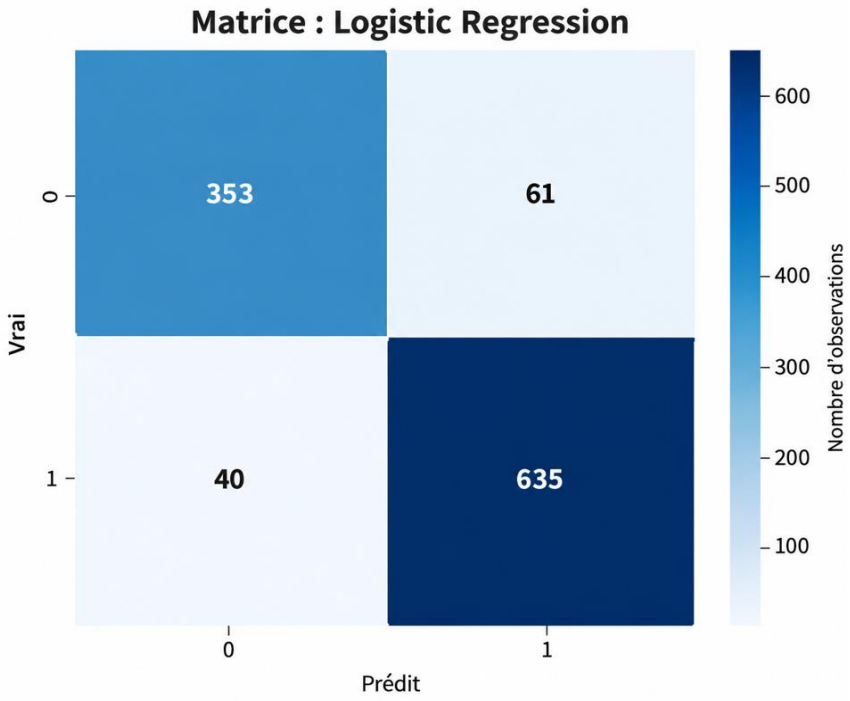


Figure 24: Matrice de confusion de la Régression Logistique

La Régression Logistique présente les meilleures performances parmi les modèles étudiés. Les résultats obtenus montrent un bon équilibre entre la précision et le rappel, ce qui traduit une capacité satisfaisante du modèle à produire des prédictions fiables sur les données de test.

L'analyse de la matrice de confusion confirme également cette efficacité. La majorité des prédictions correctes se concentre sur la diagonale principale, avec 353 vrais négatifs et 635 vrais positifs. Cela indique que le modèle parvient à distinguer correctement les étudiants en situation d'échec de ceux en situation de réussite avec un nombre relativement limité d'erreurs de classification.

Ces résultats montrent enfin que les relations entre les variables explicatives et la variable cible peuvent être correctement représentées à l'aide d'un modèle linéaire comme la Régression Logistique.

3.2 Decision Tree (Arbre de Décision)

Présentation du modèle

L'Arbre de Décision est un modèle de classification basé sur une structure hiérarchique de règles de décision. Il segmente progressivement les données en fonction des variables les plus discriminantes afin de séparer les différentes classes.

Résultats obtenus

Tableau 4: Performances du modèle Decision Tree

Métrique	Valeur
Accuracy	85.58%
Precision	86.02%
Recall	85.58%

La figure suivante présente la matrice de confusion obtenue par l'Arbre de Décision.

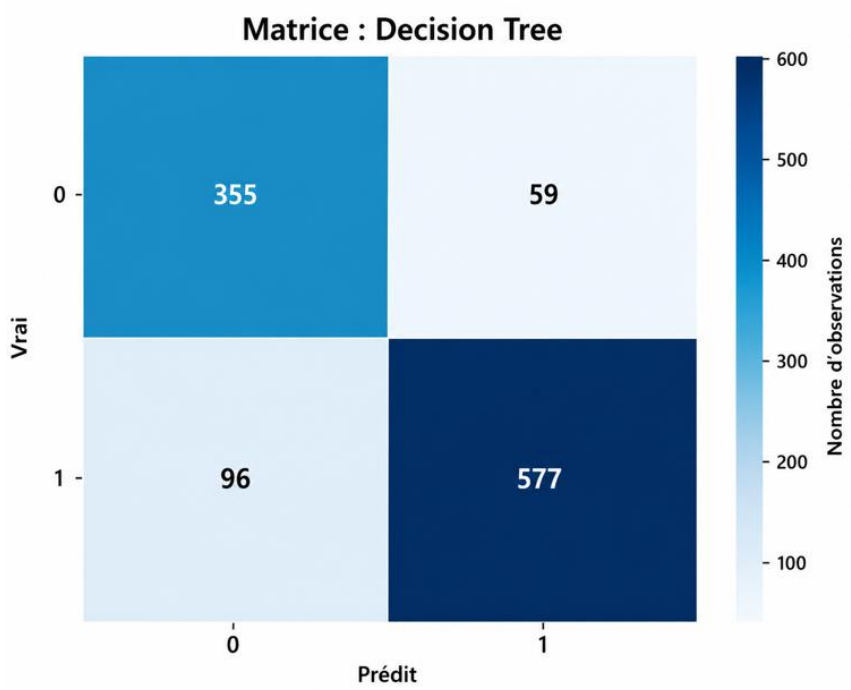


Figure 25: Matrice de confusion du Decision Tree

Le modèle Decision Tree obtient des performances inférieures à celles de la Régression Logistique. Même si ce type d'algorithme est capable de modéliser des relations non linéaires entre les variables, sa version initiale montre davantage de difficultés à généraliser correctement sur les données de test.

L’analyse de la matrice de confusion met en évidence un nombre relativement important d’erreurs de classification, avec 98 faux négatifs et 59 faux positifs. Cela signifie que certains étudiants sont classés dans une catégorie incorrecte, ce qui réduit la fiabilité globale des prédictions.

Ces résultats peuvent s’expliquer par une complexité excessive de l’arbre avant optimisation. En cherchant à s’adapter trop précisément aux données d’entraînement, le modèle finit par mémoriser certains détails spécifiques au lieu d’apprendre des tendances générales, ce qui entraîne un phénomène de surapprentissage (overfitting).

3.3 Decision Tree Tuned (Arbre de Décision optimisé)

Présentation du modèle

Une phase d’optimisation des hyperparamètres a été appliquée à l’Arbre de Décision afin d’améliorer ses performances et de limiter le risque de surapprentissage. Cette optimisation concerne notamment la profondeur maximale de l’arbre ainsi que le nombre minimal d’observations par feuille.

Résultats obtenus

Tableau 5: Performances du modèle Decision Tree Tuned

Métrique	Valeur
Accuracy	90.45%
Precision	90.47%
Recall	90.45%

La figure suivante présente la matrice de confusion du modèle optimisé.

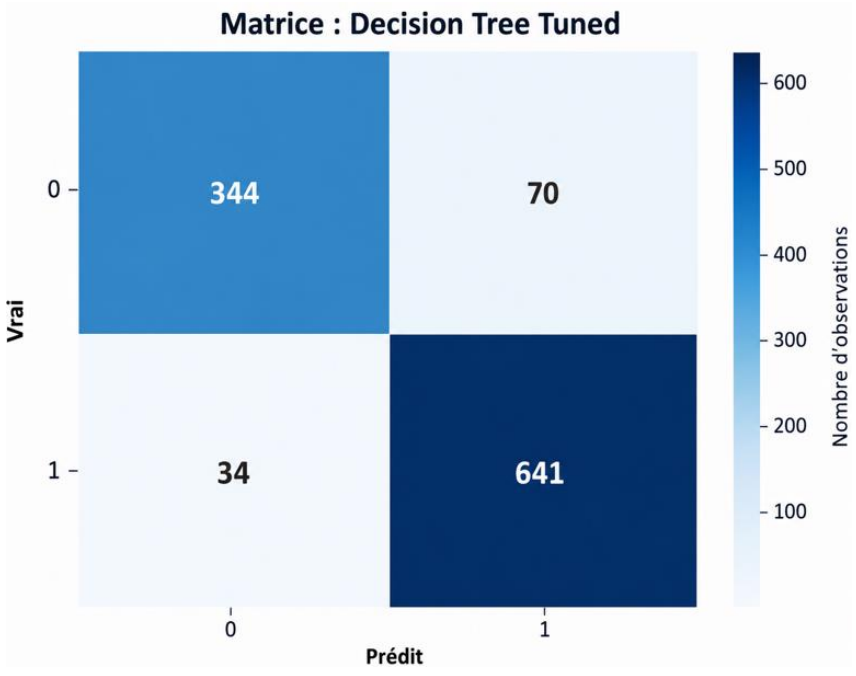


Figure 26: Matrice de confusion du Decision Tree Tuned

L’optimisation des hyperparamètres a permis d’améliorer de manière notable les performances du modèle par rapport à la version initiale de l’Arbre de Décision. L’augmentation de la précision montre que le modèle optimisé génère des prédictions plus fiables tout en réduisant les erreurs de classification.

L’analyse de la matrice de confusion confirme cette amélioration. Le nombre de faux négatifs diminue significativement, passant de 98 à 34, tandis que les valeurs correctes deviennent davantage concentrées sur la diagonale principale. Cela traduit une meilleure capacité du modèle à distinguer correctement les étudiants en situation d’échec et de réussite.

Même si ses performances restent légèrement inférieures à celles de la Régression Logistique, cette version optimisée présente une capacité de généralisation nettement meilleure que l’Arbre de Décision initial, notamment grâce à la réduction du phénomène de surapprentissage.

3.4 K-Nearest Neighbors (KNN)

Présentation du modèle

Le modèle K-Nearest Neighbors (KNN) est un algorithme basé sur la similarité entre les observations. Il classe une nouvelle donnée en fonction des classes majoritaires parmi ses plus proches voisins selon une mesure de distance.

Résultats obtenus

Tableau 6: Performances du modèle KNN

Métrique	Valeur
Accuracy	89.89%
Precision	89.86%
Recall	89.89%

La figure suivante présente la matrice de confusion obtenue par le modèle KNN.

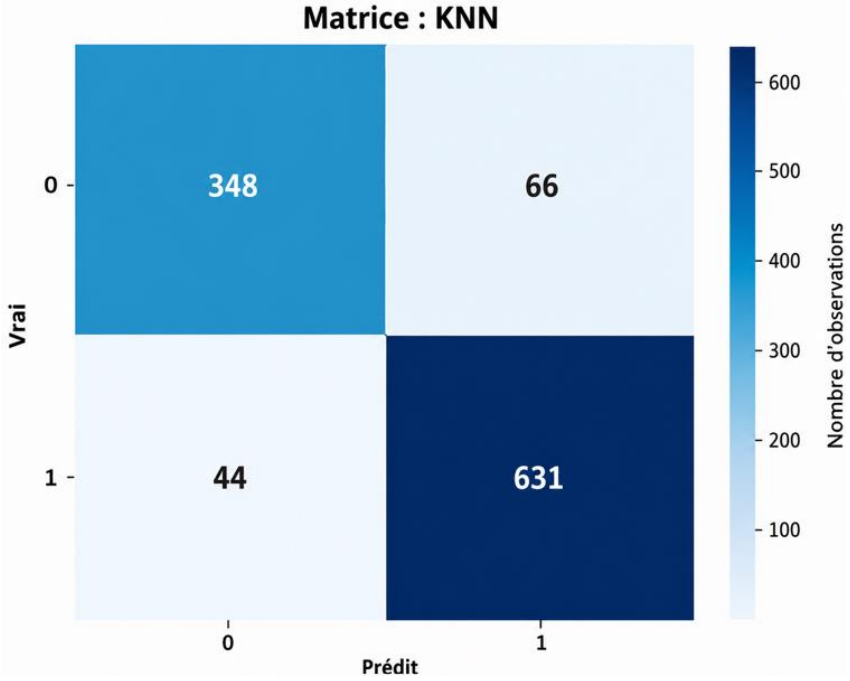


Figure 27:Matrice de confusion du modèle KNN

Le modèle KNN présente les performances les plus faibles parmi les algorithmes évalués dans cette étude. La matrice de confusion met en évidence un nombre important d'erreurs de classification, avec 44 faux négatifs et 66 faux positifs, ainsi qu'une dispersion plus importante des prédictions incorrectes en dehors de la diagonale principale.

Cette baisse de performance peut s'expliquer par la complexité et la multidimensionnalité des données utilisées. Dans des espaces comportant un grand nombre de variables, les distances entre observations deviennent moins discriminantes, ce qui réduit l'efficacité du modèle KNN dans la séparation des différentes classes.

4. Analyse comparative des modèles

4.1 Comparaison des métriques

Le tableau suivant présente une synthèse des performances obtenues par les différents modèles de classification évalués sur l'ensemble de test.

Tableau 7:Comparaison des performances des modèles

Modèle	Accuracy	Precision	Recall
Régression Logistique	90.72%	90.59%	90.72%
Arbre de Décision	85.58%	85.02 %	85.58 %
Arbre de Décision (optimisé)	90.45 %	90.47 %	90.45 %
KNN	89.89%	89.85%	89.89%

Les résultats obtenus montrent que les modèles évalués atteignent globalement de bonnes performances de classification. La Régression Logistique obtient les meilleurs résultats avec une précision de 90,59 %, ce qui témoigne de sa capacité à capturer efficacement les relations entre les variables explicatives et la variable cible. L'Arbre de Décision optimisé présente des performances très proches 90,47 %, ce qui confirme l'impact positif du réglage des hyperparamètres sur la qualité des prédictions. Le modèle KNN affiche également une précision élevée de 89,85 %, démontrant sa pertinence pour cette problématique. En revanche, l'Arbre de Décision dans sa configuration initiale reste moins performant avec une précision de 85,02 %, ce qui met en évidence la nécessité d'une phase d'optimisation. Dans l'ensemble, ces résultats confirment que les données utilisées contiennent une information suffisamment discriminante pour prédire avec fiabilité la réussite académique des étudiants.

4.2 Comparaison graphique des performances

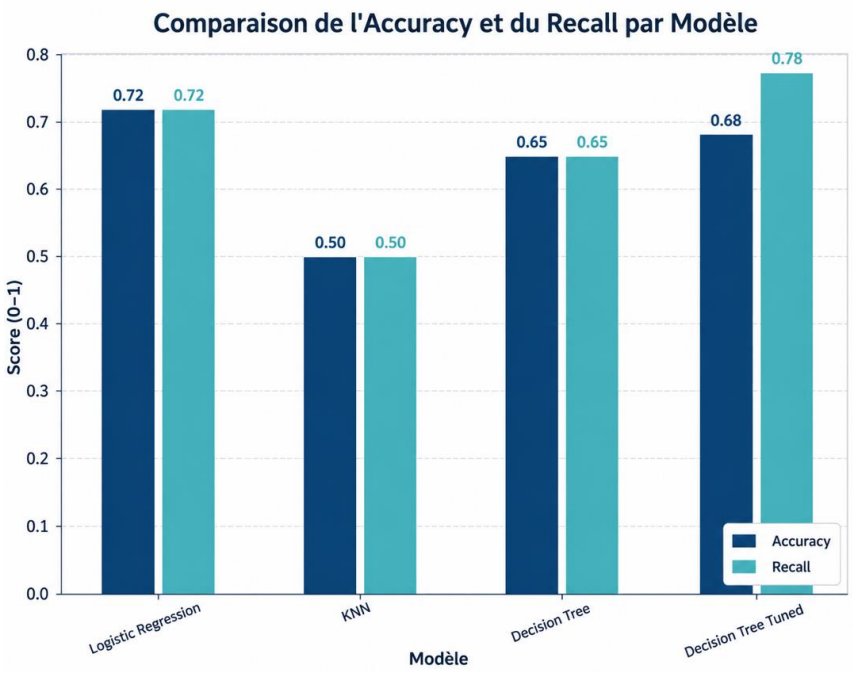


Figure 28: Comparaison de l'Accuracy et du Recall

L'analyse graphique confirme les tendances observées lors de l'évaluation des modèles. La Régression Logistique se distingue par les meilleures performances globales, traduisant une bonne capacité à fournir des prédictions fiables et équilibrées. L'Arbre de Décision optimisé obtient également des résultats très satisfaisants et montre une nette amélioration par rapport à sa version initiale, ce qui met en évidence l'intérêt de l'optimisation des hyperparamètres.

Le modèle KNN reste performant, bien que ses résultats soient légèrement inférieurs à ceux des meilleurs modèles. À l'inverse, l'Arbre de Décision non optimisé présente les performances les plus faibles, confirmant que ses paramètres par défaut ne sont pas les plus adaptés aux caractéristiques du jeu de données.

Par ailleurs, l'analyse des courbes ROC et Precision-Recall permet d'évaluer la capacité des modèles à distinguer correctement les différentes classes. Ces résultats confirment la pertinence des approches retenues pour la prédiction de la réussite académique des étudiants.

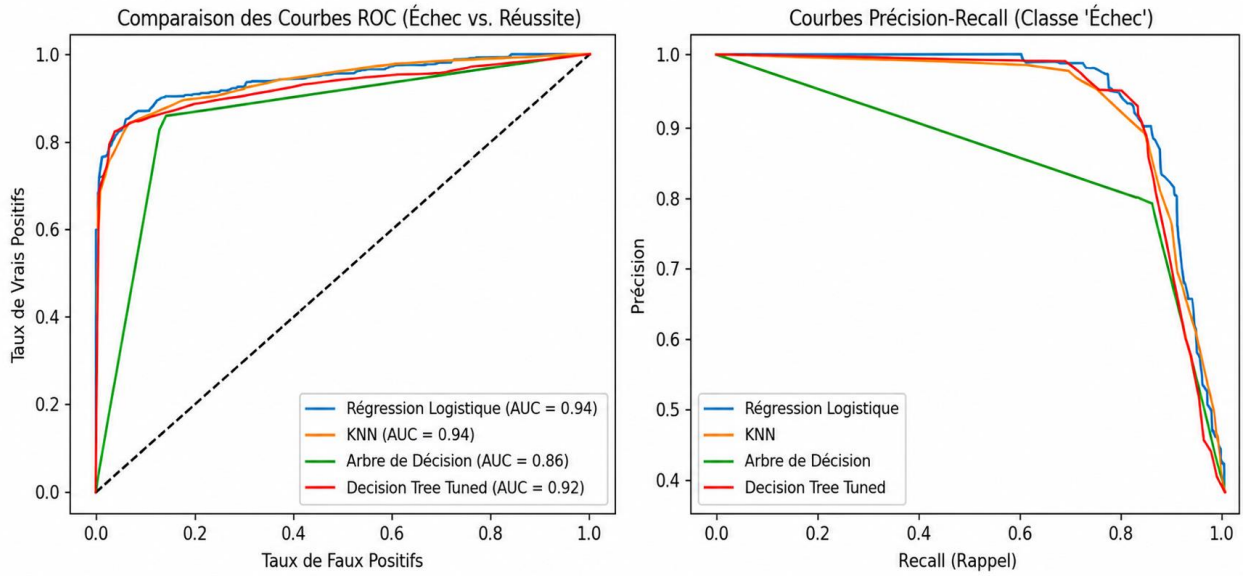


Figure 29: Courbes ROC et Precision-Recall pour la classe Échec

Les résultats montrent que la régression logistique est l'un des modèles les plus performants, avec une AUC de 0,94, ce qui traduit une très bonne capacité à distinguer les étudiants en réussite de ceux en échec. Elle se démarque également par les meilleures performances sur la courbe précision–rappel, notamment pour la classe « Échec », où elle maintient une précision élevée même à fort rappel.

Le modèle KNN obtient également une AUC de 0,94, ce qui indique des performances globales très proches de la régression logistique, bien que sa stabilité en précision–rappel soit légèrement inférieure.

L'arbre de décision optimisé améliore nettement les performances par rapport au modèle de base, avec une AUC de 0,92, montrant que l'optimisation des hyperparamètres a permis une meilleure généralisation.

Enfin, l'arbre de décision classique reste le moins performant avec une AUC de 0,86, confirmant ses limites en termes de généralisation et de compromis précision–rappel.

Globalement, les courbes ROC et précision–rappel confirment que la régression logistique et le KNN offrent les meilleurs résultats globaux, tandis que l'arbre optimisé constitue une alternative solide après tuning, contrairement au modèle de base nettement moins performant.

4.3 Analyse du surapprentissage (Overfitting)

Afin d'évaluer la capacité de généralisation des modèles étudiés, une comparaison entre les performances obtenues sur les données d'entraînement et celles obtenues sur les données de test a été réalisée. Cette analyse permet notamment de détecter d'éventuels phénomènes de surapprentissage.

La figure suivante présente les valeurs de Train Accuracy et de Test Accuracy pour chacun des modèles de classification.

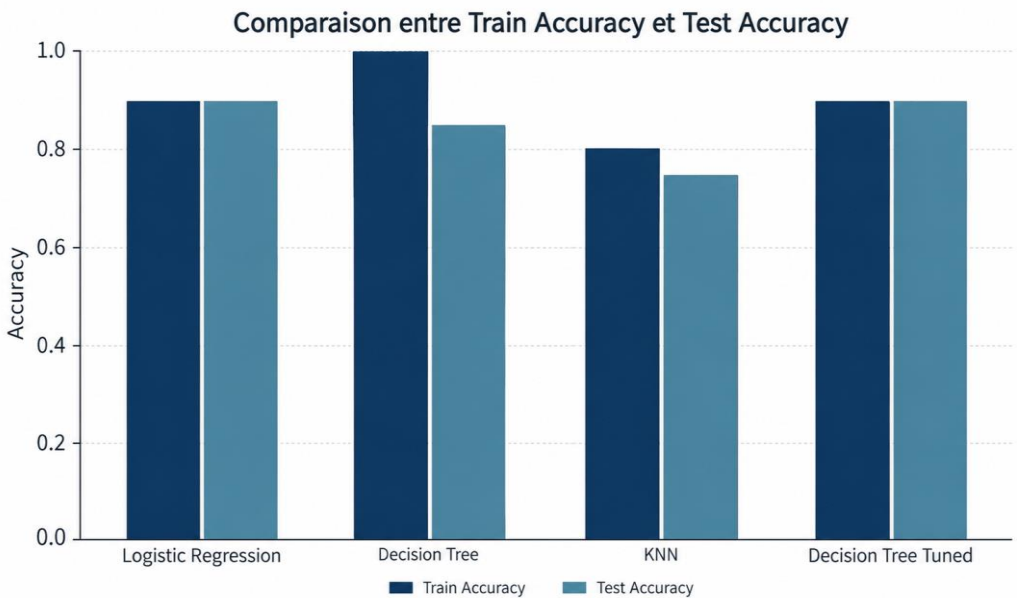


Figure 30: Comparaison entre Train Accuracy et Test Accuracy

La comparaison entre l'accuracy d'entraînement et celle de test permet d'apprécier la capacité de généralisation des modèles et d'identifier d'éventuels cas de surapprentissage.

L'arbre de décision classique présente un cas clair d'overfitting : il atteint une accuracy parfaite de 1,00 sur les données d'entraînement, tandis que ses performances chutent à environ 0,85 sur les données de test. Cela indique que le modèle a tendance à mémoriser les données d'apprentissage sans parvenir à bien généraliser sur des données inconnues.

À l'inverse, la régression logistique affiche des performances très stables entre l'entraînement et le test (environ 0,90 pour les deux), avec un écart négligeable, ce qui traduit une excellente capacité de généralisation.

L'arbre de décision optimisé améliore nettement ce comportement : l'écart entre les performances d'entraînement et de test devient très faible (environ 0,90 contre 0,89), et la performance globale en test s'améliore, confirmant l'efficacité de l'optimisation des hyperparamètres dans la réduction du surapprentissage.

Enfin, le KNN ne présente pas de signe marqué de surapprentissage, l'écart entre train et test restant limité. Toutefois, ses performances globales sont les plus faibles parmi les modèles étudiés, ce qui limite son intérêt pour ce problème de classification.

5. *Sélection du modèle final*

Choix du meilleur modèle

À partir des différentes évaluations réalisées dans ce chapitre, la Régression Logistique a été retenue comme modèle final pour le système de prédiction développé dans ce projet.

Ce choix repose sur l'analyse conjointe des métriques d'évaluation, des matrices de confusion ainsi que des courbes ROC obtenues lors des expérimentations.

La figure suivante présente la matrice de confusion du modèle final sélectionné.

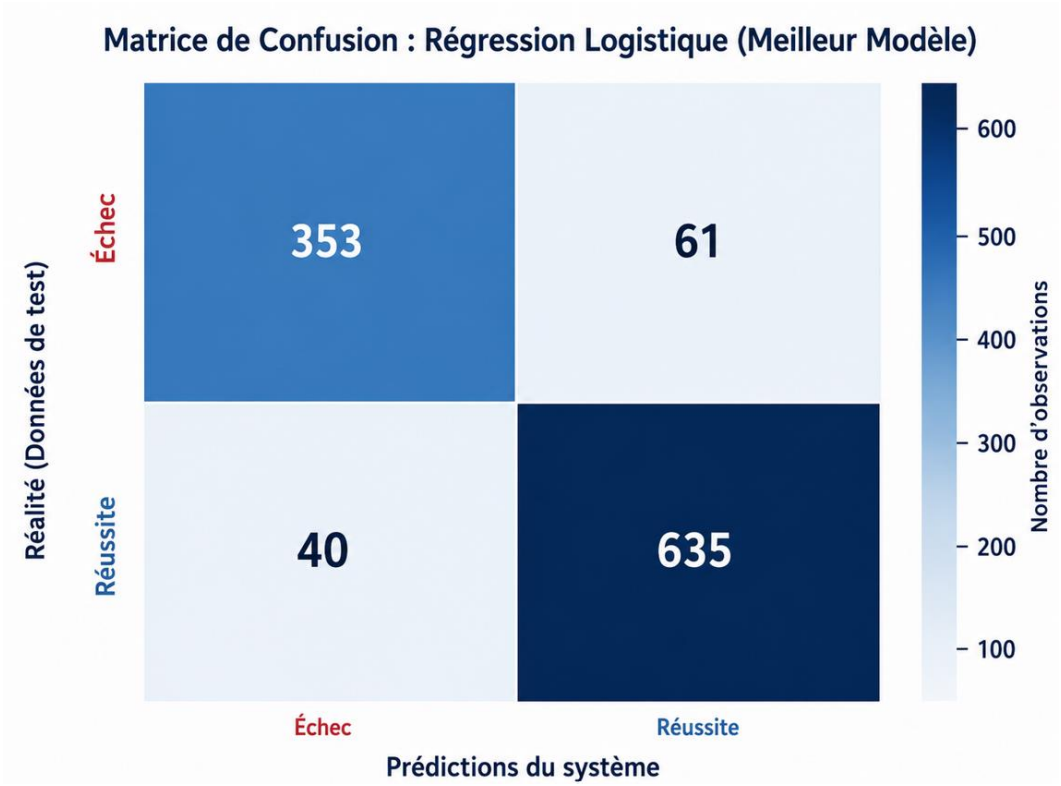


Figure 31:Matrice de confusion de la Régression Logistique

La régression logistique obtient les meilleures performances parmi l'ensemble des modèles étudiés, avec une accuracy de 90,72 % et une précision de 90,69 %. Elle se distingue également par une bonne stabilité entre l'entraînement et le test, ce qui indique une excellente capacité de généralisation.

Les courbes ROC confirment ces résultats, avec une AUC de 0,94, la plus élevée parmi les modèles testés. Cela traduit une très bonne capacité de discrimination entre les étudiants en réussite et en échec.

L'analyse du surapprentissage montre que le modèle reste stable entre les données d'entraînement et de test, sans signe notable d'overfitting, ce qui renforce la fiabilité de ses prédictions.

Enfin, la matrice de confusion met en évidence un bon taux de prédictions correctes, avec 353 cas d'échec et 635 cas de réussite bien classés, confirmant l'efficacité globale du modèle.

Avantages du modèle retenu

Au-delà de ses performances, la régression logistique présente plusieurs avantages dans le cadre de ce projet.

Tout d'abord, elle est simple à interpréter grâce à ses coefficients, ce qui permet d'identifier facilement les variables les plus influentes sur la réussite ou l'échec des étudiants. Cette interprétabilité est particulièrement importante dans un contexte académique, car elle aide à mieux comprendre les facteurs liés au décrochage scolaire.

De plus, le modèle fournit des probabilités de prédiction pour chaque classe, ce qui permet d'évaluer le niveau de confiance des résultats et de repérer plus facilement les étudiants à risque.

6. Conclusion

Ce chapitre consacré à l'évaluation des modèles a permis d'analyser et de comparer différentes approches de Machine Learning appliquées à ce projet. Les expérimentations réalisées ont mis en évidence des performances et une capacité de généralisation variables selon les modèles et leur adéquation aux caractéristiques du dataset.

Les résultats montrent que le modèle KNN présente certaines limites liées à sa sensibilité à la complexité et à la multidimensionnalité des données. L'arbre de décision initial a, quant à lui, montré des signes de surapprentissage, avec une généralisation moins satisfaisante malgré de bonnes performances en apprentissage. L'optimisation de ses hyperparamètres a toutefois permis d'améliorer sa stabilité et sa capacité de généralisation.

Parmi les modèles évalués, la régression logistique se distingue comme la plus performante. Elle démontre une bonne capacité à distinguer les étudiants en situation de réussite de ceux en situation d'échec, tout en offrant des prédictions cohérentes et fiables.

Les analyses réalisées à l'aide des matrices de confusion, des courbes ROC et des différentes méthodes d'évaluation confirment la robustesse globale des modèles testés et la pertinence de la démarche adoptée.

Au terme de cette phase d'évaluation, la régression logistique est retenue comme le modèle le plus adapté pour l'intégration dans le système de prédiction, confirmant la pertinence du pipeline de Machine Learning mis en place et constituant une base solide pour l'intégration dans l'interface applicative.

Chapitre 8 : Résultats et discussion

1. Introduction

Les chapitres précédents ont détaillé la construction du système de prédiction, depuis la préparation des données jusqu'à l'évaluation et la sélection du modèle final. Ce chapitre présente la concrétisation de ce travail sous la forme d'une application web interactive. L'objectif est de rendre le système accessible à un utilisateur non spécialiste et de restituer l'ensemble des résultats du projet à travers une interface graphique unique.

L'application permet de suivre chaque étape du pipeline, de visualiser les indicateurs obtenus et d'effectuer une prédiction pour un nouvel étudiant. Les sections suivantes décrivent l'organisation générale de l'interface, ses principales fonctionnalités, le déroulement d'une prédiction ainsi que l'apport de cette application dans le système proposé.

2. Présentation générale de l'interface

L'application se présente sous la forme d'un tableau de bord web organisé autour d'un menu latéral fixe. Ce menu donne accès à sept modules correspondant aux grandes étapes du projet : l'accueil, l'importation des données, le prétraitement, l'analyse exploratoire, la modélisation, la prédiction et les recommandations. Chaque module regroupe les visualisations et les indicateurs associés à l'étape qu'il représente, ce qui offre une lecture claire et progressive de la démarche suivie.

La page d'accueil joue le rôle de tableau de bord de synthèse. Elle met en avant les indicateurs clés du projet, notamment l'exactitude du meilleur modèle qui atteint 90,73 %, le score AUC de 94,33 %, le nombre de variables retenues fixé à 9 sur 36 et la taille du jeu de données après rééquilibrage qui s'élève à 3 068 observations. Elle rappelle également les six étapes du pipeline ainsi que le classement des modèles testés, et propose des raccourcis vers les différents modules. L'identité visuelle repose sur une palette sobre dominée par le bleu nuit, retenue pour sa lisibilité et son caractère professionnel.

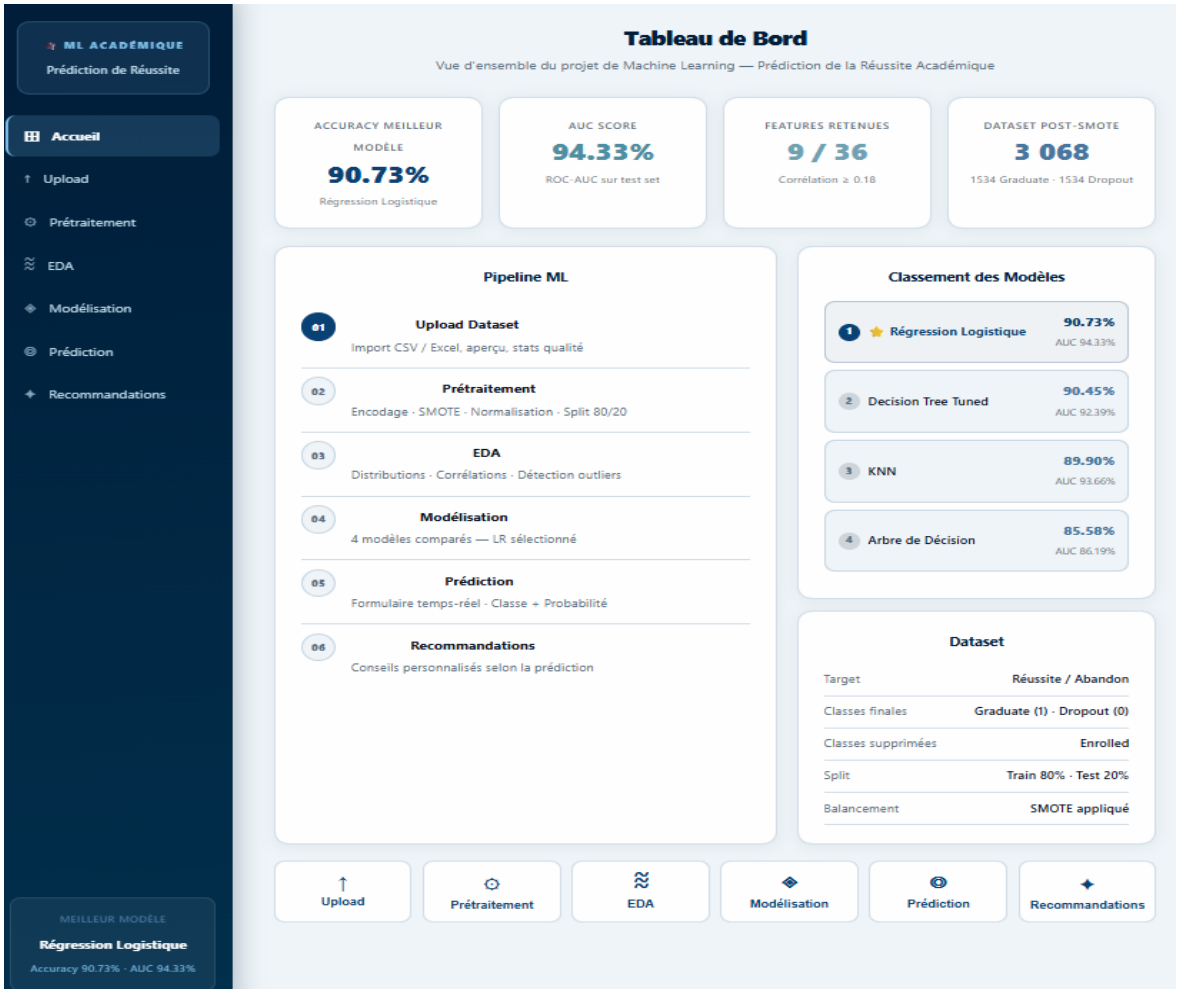


Figure 32: Page d'accueil du tableau de bord de l'application

3. Architecture technique de l'application

L'interface a été développée avec la bibliothèque React et l'outil de construction Vite, qui assurent un rendu rapide et une organisation modulaire du code sous forme de composants réutilisables. Les graphiques interactifs, tels que les histogrammes, les diagrammes comparatifs et les matrices, sont produits à l'aide de la bibliothèque Recharts.

L'application est conçue comme une application monopage. La navigation entre les modules s'effectue sans rechargement de la page, ce qui garantit une expérience fluide et réactive. Les résultats expérimentaux et la logique de prédiction sont intégrés directement dans l'application, ce qui la rend autonome et facilement déployable. Elle a été mise en ligne sur la plateforme Vercel afin d'être consultable depuis un simple navigateur, sans aucune installation préalable.

4. Fonctionnalités principales de l'application

Au-delà de la page d'accueil, l'application regroupe plusieurs modules qui reprennent chacune des étapes du pipeline de Machine Learning. Ces modules restituent de manière visuelle les traitements appliqués aux données et les résultats obtenus tout au long du projet.

Le module d'importation permet de charger un jeu de données au format CSV ou Excel, par glisser-déposer ou par sélection de fichier. Une fois les données chargées, le module affiche les principales caractéristiques du jeu de données, à savoir le nombre de lignes qui s'élève à 4 424, le nombre de colonnes égal à 37, ainsi que l'absence de valeurs manquantes et de doublons. Un aperçu des premières lignes est également présenté afin de vérifier la structure des données importées.

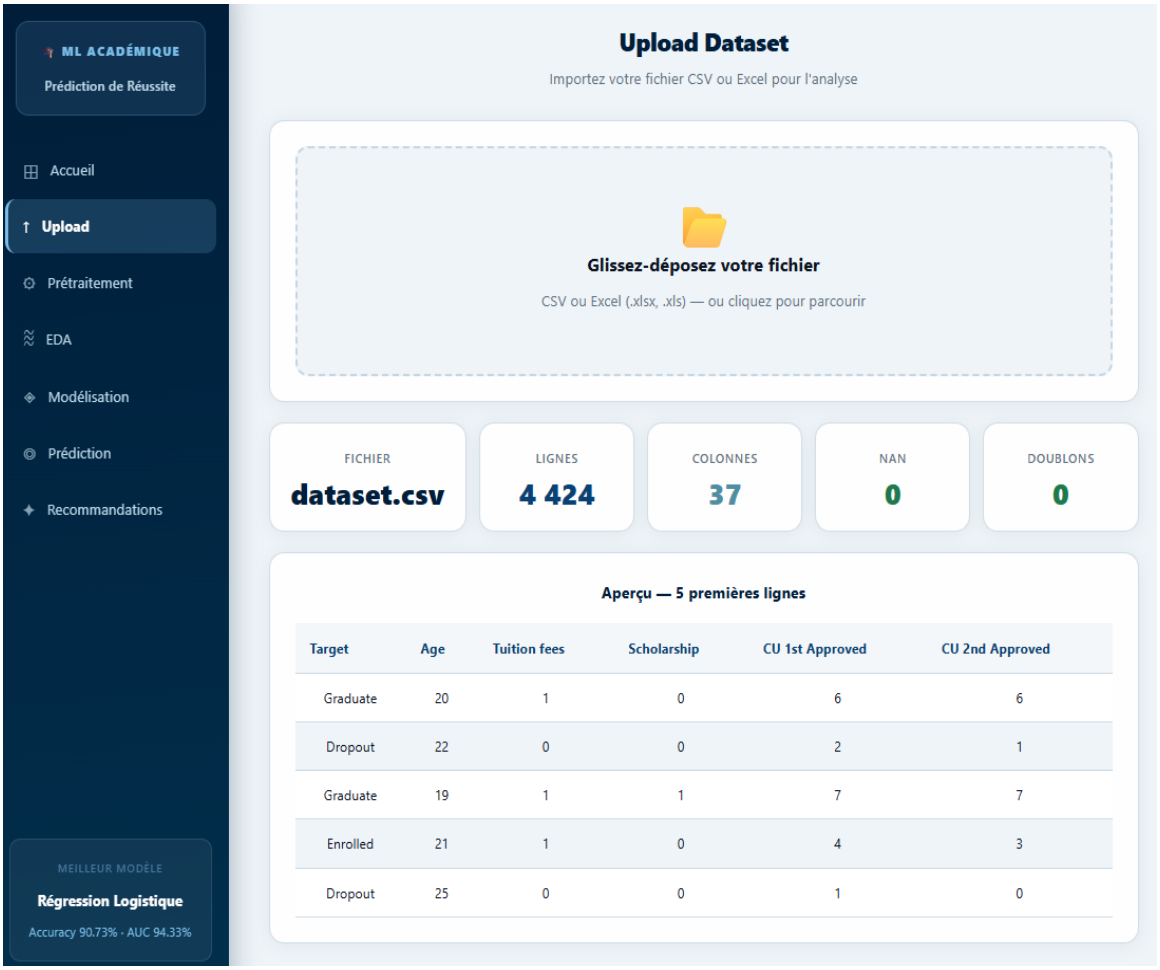


Figure 33: Module d'importation et d'aperçu du jeu de données

Le module de prétraitement présente les transformations appliquées au jeu de données brut. Il illustre l'encodage de la variable cible par la méthode du Label Encoding, la normalisation des 32 variables numériques à l'aide du StandardScaler, ainsi que la réduction de la variable cible à deux classes par la suppression de la modalité Enrolled. Le module met aussi en évidence l'équilibrage des classes par la technique SMOTE, qui fait passer la répartition de 64,1 % et 35,9 % à une distribution parfaitement équilibrée de 1 534 observations par classe. La division des données en 80 % pour l'entraînement et 20 % pour le test ainsi que la sélection des 9 variables les plus corrélées à la cible y sont également représentées.

Figure 34: Module de prétraitement : encodage, équilibrage SMOTE et sélection des variables

Le module d'analyse exploratoire regroupe les principales visualisations issues de l'étude des données. Il présente la distribution de la variable cible, le niveau de corrélation de chaque variable avec la réussite, ainsi que la détection des valeurs aberrantes par la méthode de l'écart interquartile suivie d'un traitement par plafonnement aux percentiles. Une matrice de corrélation portant sur les 9 variables retenues complète cette analyse et permet d'identifier les relations entre les variables.

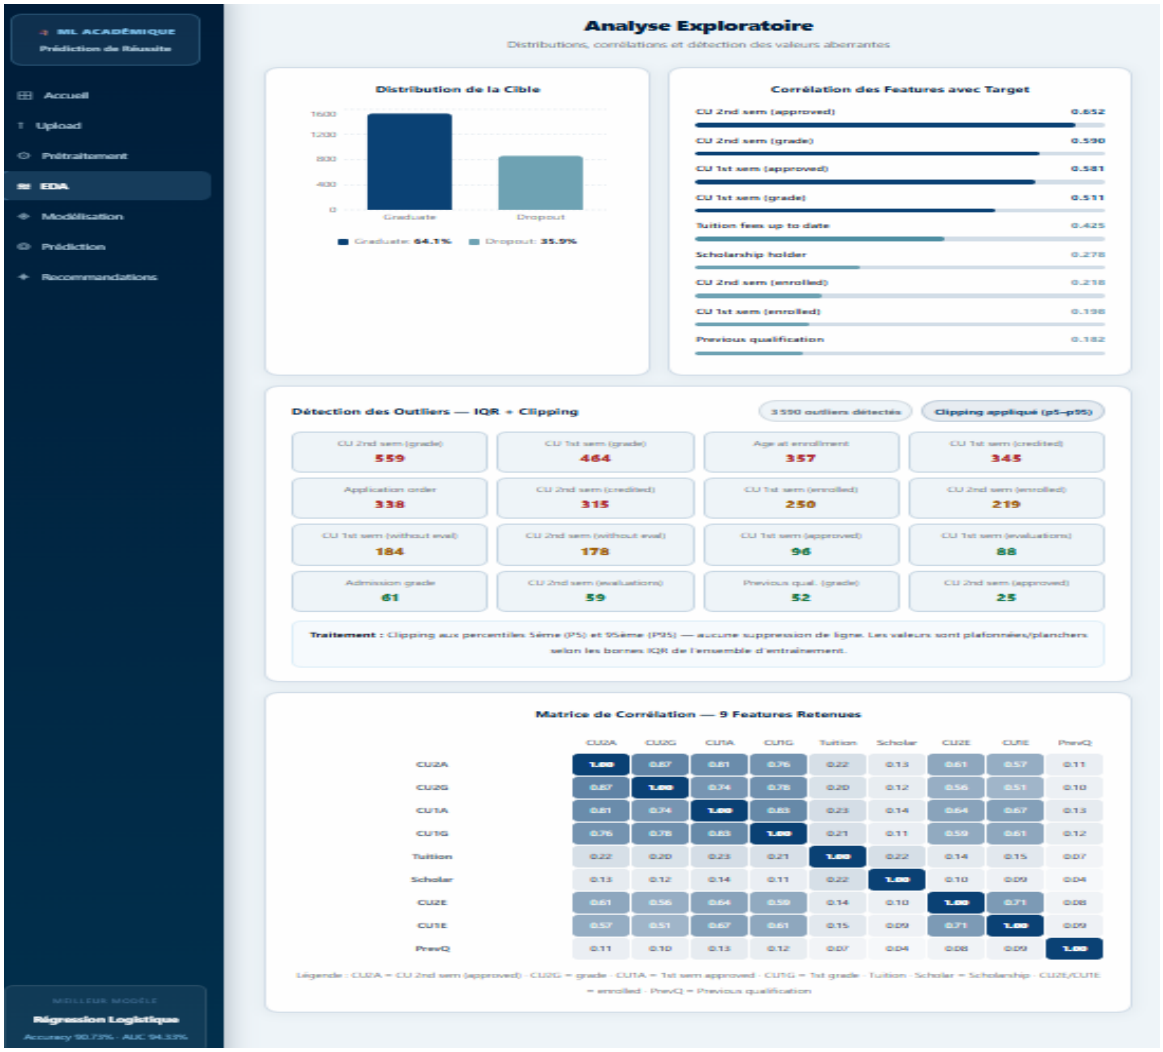


Figure 35: distribution de la cible, corrélations et valeurs aberrantes

Le module de modélisation restitue la comparaison des quatre modèles testés, à savoir la régression logistique, l'arbre de décision optimisé, le K-Nearest Neighbors et l'arbre de décision de base. Il présente un tableau comparatif des différentes métriques, un diagramme mettant en regard l'exactitude et le score AUC, ainsi que la matrice de confusion du modèle retenu. Cette matrice fait apparaître 635 vrais positifs, 353 vrais négatifs, 61 faux positifs et 40 faux négatifs sur l'ensemble de test. L'ensemble confirme la supériorité de la régression logistique, sélectionnée comme modèle final.

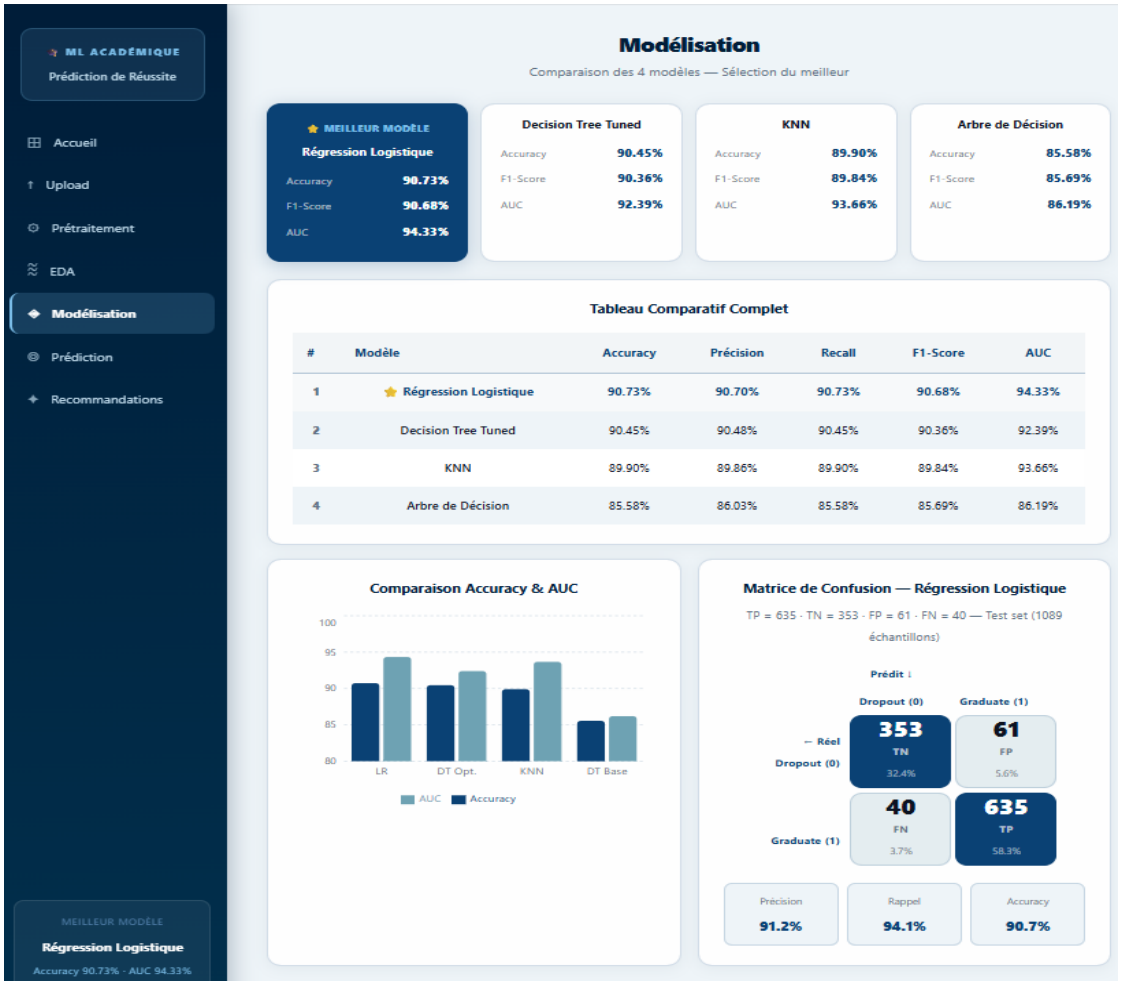


Figure 36: Module de modélisation : comparaison des modèles et matrice de confusion

5. *Simulation d'une prédiction pour un nouvel étudiant*

Le module de prédiction constitue le cœur de l'application. Il met en œuvre le modèle de régression logistique retenu afin d'estimer la réussite ou l'abandon d'un nouvel étudiant. L'utilisateur renseigne les 9 variables sélectionnées au moyen de curseurs pour les variables numériques et de boutons pour les variables binaires. Chaque variable est accompagnée de son coefficient de corrélation avec la cible, ce qui éclaire l'influence relative de chaque facteur.

Une fois le profil de l'étudiant défini, le lancement de la prédiction déclenche le calcul et l'affichage du résultat. La figure suivante illustre un exemple de prédiction réalisée à partir d'un profil présentant des indicateurs académiques favorables.

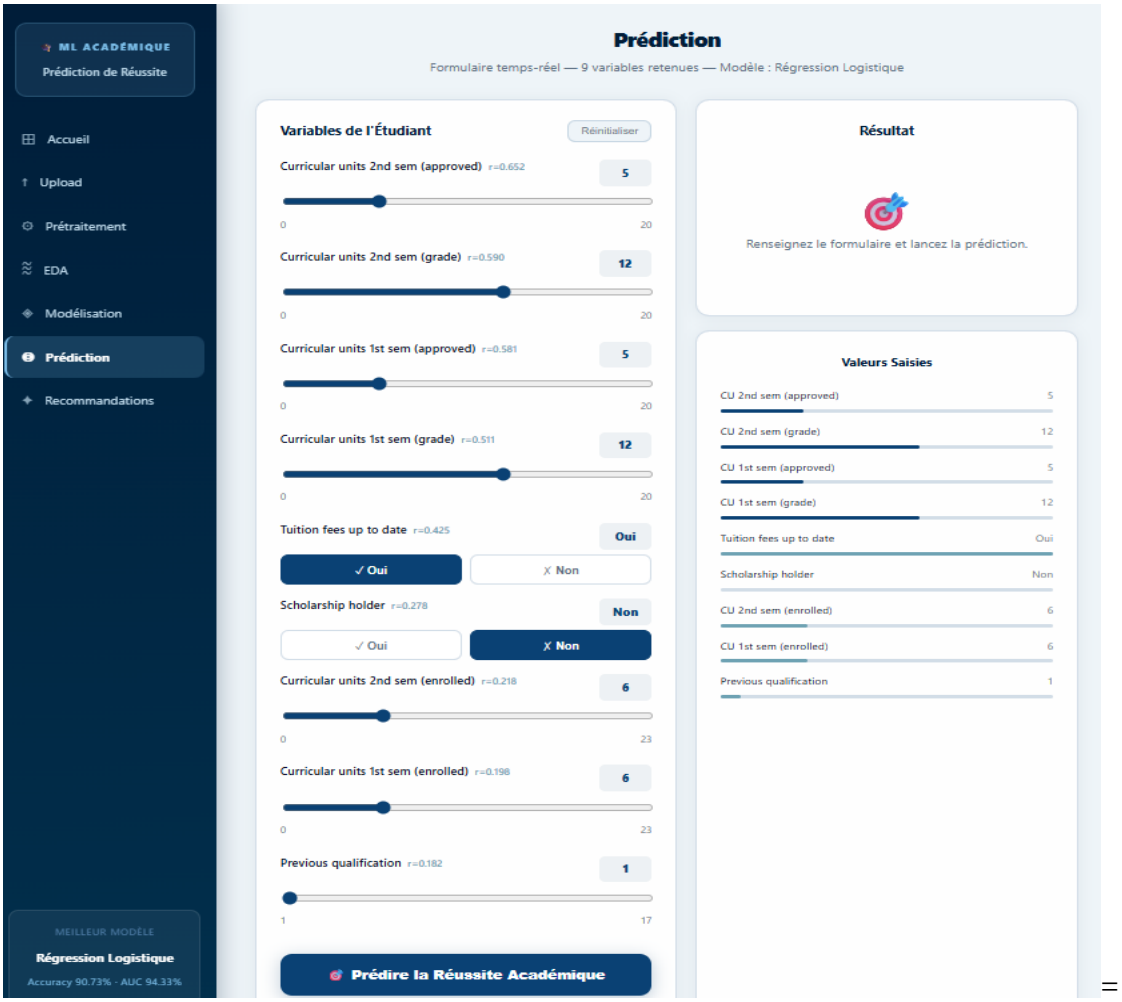


Figure 37: Formulaire de prédiction et résultat obtenu pour un nouvel étudiant

6. Affichage du résultat et du niveau de confiance

Le résultat de la prédiction est présenté de manière claire et immédiatement interprétable. L'application affiche la classe prédite, soit une réussite probable, soit un risque d'abandon, accompagnée d'un niveau de confiance exprimé en pourcentage. Dans l'exemple présenté, le système prédit une réussite avec un niveau de confiance de 89,0 %.

Les probabilités associées à chacune des deux classes sont également indiquées, ce qui permet de mesurer la marge entre les deux issues possibles. Un code couleur renforce la lisibilité, le vert signalant une réussite probable et le rouge un risque d'abandon. Le modèle utilisé ainsi que ses principales métriques sont rappelés sous le résultat, ce qui garantit la transparence de la prédiction.

7. Recommandations personnalisées

À la suite de la prédiction, l'application propose un module de recommandations personnalisées. Les conseils affichés dépendent du résultat obtenu et se distinguent selon que le profil correspond à une réussite probable ou à un risque d'abandon. Chaque recommandation est associée à un niveau de priorité afin de hiérarchiser les actions à entreprendre.

Pour un profil à risque, les recommandations insistent notamment sur l'accompagnement pédagogique, l'allègement de la charge de travail et la régularisation de la situation financière. Pour un profil favorable, elles encouragent le maintien du rythme de validation des unités et la consolidation des résultats. Le module rappelle enfin les variables les plus influentes sur la prédiction, ce qui aide à relier les conseils proposés aux facteurs identifiés par le modèle.

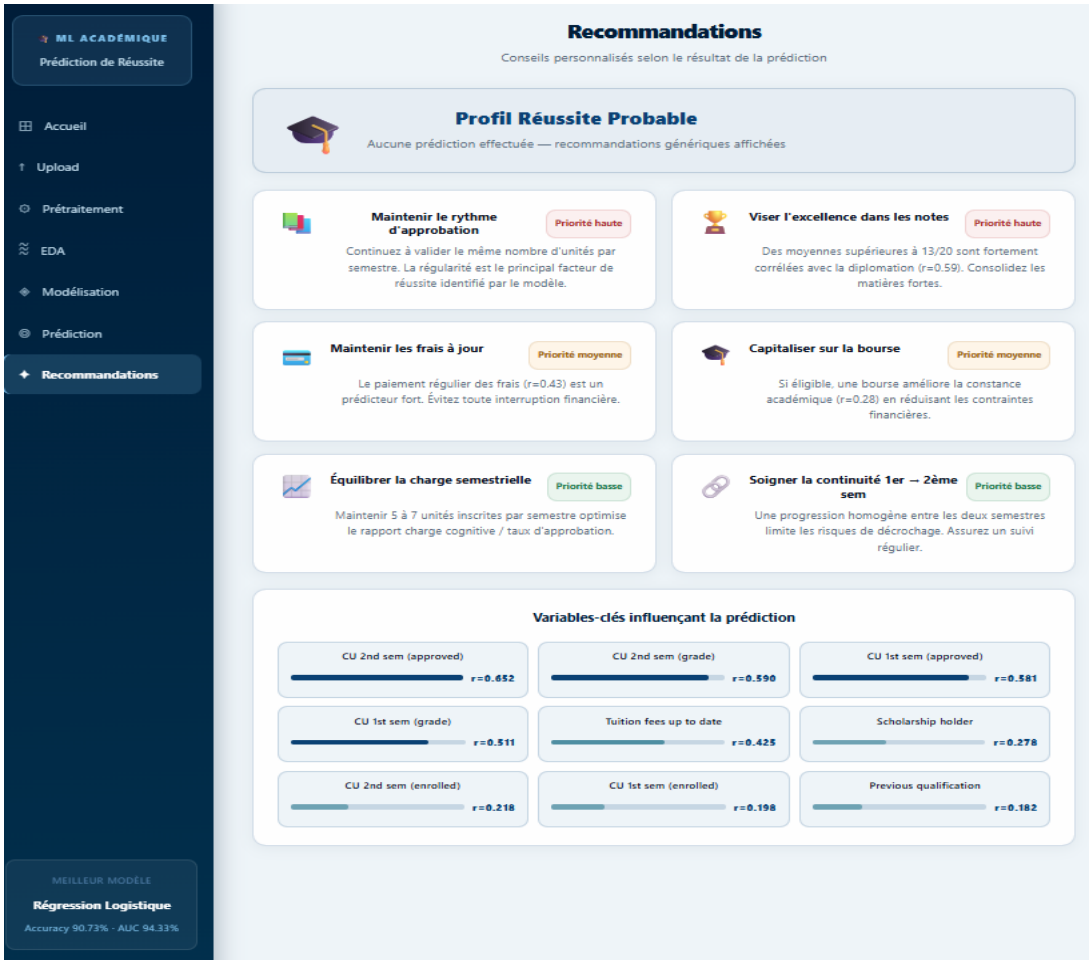


Figure 38: Module de recommandations personnalisées selon le résultat de la prédiction

8. Apport de l'interface dans le système proposé

L'application développée apporte une valeur ajoutée importante au système de prédiction. Elle transforme un pipeline de Machine Learning, par nature technique, en un outil concret et accessible à des utilisateurs non spécialistes tels que les responsables pédagogiques. La centralisation de l'ensemble des étapes au sein d'une même interface facilite la compréhension de la démarche et l'interprétation des résultats.

En restituant les prédictions sous une forme lisible, accompagnées d'un niveau de confiance et de recommandations, l'interface s'inscrit dans une logique d'aide à la décision. Elle permet d'identifier de manière précoce les étudiants en difficulté et d'orienter les actions de suivi, ce qui répond directement à la problématique posée au début de ce projet.

9. Accès à l'application

L'application web développée dans le cadre de ce projet a été déployée afin de permettre sa consultation et son utilisation dans un environnement réel. Les informations relatives à son accès sont fournies dans la section Webographie du rapport.

10. Conclusion

Ce chapitre a présenté l'application web interactive développée pour concrétiser le système de prédiction de la réussite académique. L'interface réunit l'ensemble des étapes du projet, depuis l'importation des données jusqu'à la formulation de recommandations, et rend le modèle directement exploitable. Elle constitue ainsi l'aboutissement opérationnel du travail réalisé et ouvre la voie aux perspectives d'amélioration évoquées dans la conclusion générale.

Conclusion générale

Le présent projet de fin d'études s'est inscrit dans le cadre de la conception, du développement et de l'évaluation d'un système de prédiction de la réussite académique des étudiants à l'aide des techniques de Machine Learning.

Face aux enjeux liés au décrochage universitaire, ce travail a permis de mettre en place une démarche complète d'analyse de données, allant de l'exploration du jeu de données jusqu'à la modélisation et l'évaluation des modèles prédictifs.

Dans un premier temps, l'analyse exploratoire des données (EDA) a permis de mieux comprendre la structure du dataset et de mettre en évidence l'influence des variables académiques et socio-économiques sur le statut des étudiants.

Ensuite, la phase de prétraitement a permis de préparer les données pour la modélisation, notamment à travers l'encodage des variables catégorielles, la normalisation des variables numériques, le traitement des valeurs aberrantes et l'équilibrage des classes.

La phase de modélisation a consisté à comparer plusieurs algorithmes de classification supervisée, notamment la Régression Logistique, les K plus proches voisins (KNN) et les Arbres de Décision. Les résultats obtenus ont montré que la Régression Logistique offre les meilleures performances, avec une accuracy d'environ 90,72 %, tout en assurant une bonne capacité de généralisation et une interprétabilité adaptée au contexte décisionnel.

Afin de rendre cette solution exploitable, une application web interactive a été développée. Elle permet de visualiser les différentes étapes du pipeline et d'utiliser le modèle pour effectuer des prédictions sur de nouveaux profils étudiants.

Limites du système

Malgré les résultats obtenus, ce travail présente certaines limites :

- Le modèle dépend du jeu de données utilisé, ce qui peut limiter sa généralisation à d'autres contextes académiques.
- Certaines variables importantes, notamment d'ordre comportemental ou psychologique, ne sont pas disponibles dans le dataset.
- Le système repose sur des données statiques et ne prend pas en compte l'évolution temporelle des étudiants.

Perspectives

Ce projet ouvre plusieurs perspectives d'amélioration :

- L’utilisation d’algorithmes plus avancés tels que Random Forest ou XGBoost afin d’améliorer les performances de prédiction.
- L’intégration de méthodes d’intelligence artificielle explicable (XAI) afin de mieux interpréter les décisions du modèle.
- L’enrichissement du dataset par des données comportementales issues des plateformes d’apprentissage (Learning Analytics).

Conclusion finale

Ce projet a permis de mobiliser les compétences acquises en intelligence artificielle, en analyse de données et en développement logiciel. Il propose une solution concrète basée sur le Machine Learning pour soutenir la compréhension et la prédiction de la réussite académique des étudiants.

Bibliographie

Aulck, L., Velagapudi, N., Blumenstock, J., & West, J. (2016). Predicting Student Dropout in Higher Education. Proceedings of the 2nd International Conference on Data Science and Advanced Analytics (DSAA 2016), 1–9.

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

Dekker, G., Pechenizkiy, M., & Vleeshouwers, J. (2009). Predicting Students Drop Out: A Case Study. Proceedings of the 2nd International Conference on Educational Data Mining (EDM 2009), 41–50.

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow (3rd ed.). O'Reilly Media.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning. Springer.

Kotsiantis, S., Pierrakeas, C., & Pintelas, P. (2004). Predicting Students' Performance in Distance Learning Using Machine Learning Techniques. Proceedings of the 2nd International Conference on Applied Informatics (ICAI 2004), 67–74.

McKinney, W. (2022). Python for Data Analysis. O'Reilly Media.

Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python. O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media.

Webographie

Scikit-learn Development Team. (2024). Scikit-learn: Machine Learning in Python — Documentation officielle. https://scikit-learn.org

McKinney, W., & Pandas Development Team. (2024). Pandas — Python Data Analysis Library — Documentation officielle. https://pandas.pydata.org

Meta Open Source. (2024). React — Documentation officielle. https://react.dev/learn

Harris, C. R., & NumPy Development Team. (2024). NumPy — Documentation officielle. https://numpy.org

Hunter, J. D., & Matplotlib Development Team. (2024). Matplotlib — Visualization with Python — Documentation officielle. https://matplotlib.org

Waskom, M., & Seaborn Development Team. (2024). Seaborn — Statistical Data Visualization — Documentation officielle. https://seaborn.pydata.org

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Application web de prédiction de la réussite académique, développée dans le cadre de ce projet. https://dist-azure-psi-13.vercel.app/




وآخر دعوانا أن الحمد لله رب العالمين